

Выпускная квалификационная работа

Построение комбинированных моделей на основе алгоритма MODWT при обработке временных рядов

Выполнил:

студент группы КМБО-03-22 — Лыков Д.С.

Научный руководитель:

к.ф.-м.н., доцент кафедры ВМ — Петрусевич Д. А.

Актуальность и место исследования

Раздел 1. Состояние дел в области

Зачем нужно прогнозирование рядов?

- продажи, трафик, потребление ресурсов, цены
- ограниченная история наблюдений
- наличие шума, сезонности, структурных сдвигов
- разнородность поведения рядов

Место настоящего исследования

- универсальной модели не существует (M3, M4)
- статистика стабильна на коротких рядах
- нейросети — на длинных и сложных
- идея: гибрид через декомпозицию ряда
- новизна — конвейер HybridPlus на базе MODWT и STL
- сравнение многошкального (MODWT) и структурного (STL) разложения

Современные подходы к прогнозированию

Обзор: классические vs нейросетевые vs гибридные

Классические

- ARIMA / ARIMA(auto)
- ETS (экспоненциальное сглаживание)
- Prophet (аддитивная регрессия)
- + интерпретируемость
- + доверительные интервалы
- – линейность и стационарность
- – проблемы при сложной структуре

Нейросетевые

- TimesNet — 2D-представление периодов
- N-BEATS — стек базисных блоков
- + нелинейные зависимости
- + автоматический поиск признаков
- – чувствительность к шуму
- – требуют длинной истории

Гибридные (в работе)

- декомпозиционные (STL, MODWT, EWT, VMD)
- остаточные (модели-«вверху» правят остатки)
- ансамблевые (усреднение, стекинг)
- разные модели — разные компоненты
- статистика на деталях/шуме
- нейросеть — на низкочастотной/сложной динамике
- HybridPlus: MODWT-(STL-) + TimesNet/N-BEATS + ARIMA/ETS

Декомпозиция временных рядов

Структурный (STL) vs многошкальный (MODWT/DWT/EWT)

Структурная: STL

ряд = тренд + сезонность + остаток

- явные интерпретируемые компоненты
- LOESS-сглаживание для тренда
- детерминированная сезонность
- плохо при многопериодной структуре
- одна фиксированная сезонная шкала

Многошкальная: MODWT

ряд = низкочастотная часть + детали по уровням

- локализация по времени и частоте
- несколько частотных шкал
- устойчивость к сдвигу (vs DWT)
- длина рядов компонент = длине ряда
- пара фильтров: НЧ + ВЧ

Гипотеза работы:

многошкальное разложение MODWT даёт дополнительные преимущества по сравнению со структурным STL при построении гибридного прогноза, особенно на рядах со сложной сезонностью

Цели и задачи работы

Раздел 1. Окончание

ЦЕЛЬ

Разработать и исследовать гибридный подход к краткосрочному прогнозированию унивариативных рядов на основе многошкальной MODWT-декомпозиции

Задачи:

- 1 Формализация постановки задачи и метрик качества
- 2 Реализация базовых моделей: ARIMA / ETS / Prophet, TimesNet, N-BEATS
- 3 Обоснование MODWT как основного инструмента гибридизации
- 4 Построение гибридной архитектуры с отдельным моделированием компонент
- 5 Сопоставимая STL-гибридная схема для сравнительного анализа
- 6 Экспериментальная оценка на синтетических данных, M3 и M4

Постановка задачи. Метрики качества

Раздел 2. Описание используемых алгоритмов — начало

Постановка задачи прогноза

Дано: $\{y_1, y_2, \dots, y_T\}$ — наблюдения

Найти: $\hat{y}_{T+1}, \dots, \hat{y}_{T+N}$

Унивариативный краткосрочный прогноз

- шаг дискретизации фиксирован
- минимум допущений о структуре
- горизонт $N \ll$ длины обучающей выборки
- тестирование — out-of-sample (rollout)

Метрики качества

RMSE

$$\sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

абсолютная, тот же масштаб

MAPE

$$\frac{100\%}{N} \sum_{i=1}^N \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

относительная, %, плохо при $y_i \approx 0$

sMAPE

$$\frac{100\%}{N} \sum_{i=1}^N \frac{|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|}$$

симметричная, протоколы M3/M4

Преобразование MODWT — идея

Раздел 2. Алгоритмы — продолжение

От преобразования Фурье к вейвлет-анализу

Фурье-анализ

разложение по синусоидам, заданным на всем временном интервале

- хорошо видны частоты
- плохо локализованы во времени

Вейвлет-анализ

базисные функции локализованы и во времени, и по частоте

- разные масштабы
- показывает, когда и на каких масштабах проявляются колебания

$$\text{Семейство вейвлетов: } \psi_{a,b}(t) = \frac{1}{\sqrt{|a|}} \cdot \psi\left(\frac{t-b}{a}\right)$$

- a — масштаб: большой a — низкие частоты; малый a — высокие
- b — сдвиг: положение «окна» во времени

Идея для прогнозирования: MODWT позволяет представить один ряд как набор компонент разных масштабов, которые затем можно прогнозировать разными моделями.

Преобразование MODWT — формулы

Дискретные фильтры, фильтрация без прореживания и реконструкция компонент

Цифровые фильтры с конечным откликом

Свёртка входа $x(t)$ с коэффициентами фильтра $b_0 \dots b_{M-1}$ (M — длина памяти фильтра):

$$z(t) = \sum_{k=0}^{M-1} b_k \cdot x_{t-k}$$

Свёртка — взвешенная сумма текущего и предыдущих значений ряда.
В MODWT она применяется через низкочастотный (h_l) и высокочастотный (g_l) фильтры.

После многоуровневой фильтрации исходного ряда и обратной реконструкции получаем:

$$y(t) = A_J(t) + \sum_{j=1}^J D_j(t)$$

$A_J(t)$ — низкочастотная компонента;
 $D_j(t)$ — детали j -го масштаба.

Сравнение DWT и MODWT

Свойство	DWT	MODWT (применяется в работе)
Прореживание	каждый 2-й коэффициент	не отбрасывается
Длина компонент	сокращается вдвое на уровне	= длине исходного ряда
Чувствительность к сдвигу	высокая	коэффициенты сдвигаются вместе с рядом
Избыточность	критическая (минимум)	избыточное (плата за устойчивость)
Растяжение фильтра	фиксированные	растягиваются по уровням

→ MODWT устойчив к сдвигу и сохраняет одну длину для всех компонент — это критично при построении гибридной модели

STL-декомпозиция

Альтернативный подход — структурное разложение

ряд = тренд + сезонность + остаток

Исходный ряд

Тренд

T_t

медленная составляющая

Сезонность

S_t

периодическая часть

Остаток

R_t

нерегулярная часть

Особенности STL

Каждая компонента оценивается итерационно:

$$T_t \approx LOESS(y_t - S_t)$$

$$S_t \approx LOESS(y_t - T_t)$$

$$R_t = y_t - T_t - S_t$$

LOESS — локальная регрессия: для каждой точки строится сглаженная оценка по соседним наблюдениям с большими весами у ближайших точек

Плюсы

- интерпретируемое разложение: тренд, сезонность, остаток;
- LOESS позволяет гибко выделять нелинейный тренд;
- устойчивость к выбросам при robust-режиме;

Минусы

- требуется заранее заданный сезонный период;
- базовая STL плохо описывает многопериодную структуру;
- хуже учитывает быстро меняющуюся форму сезонности;

Классические модели

ARIMA, ETS, Prophet — базовые модели сравнения

ARIMA(p,d,q)

$$w_t = \Delta^d y_t \rightarrow ARMA(p, q)$$
$$w_t = c + \sum_{i=1}^p \varphi_i w_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

ARIMA = AR + I + MA

- AR — зависимость от прошлых значений:
 $y_t \sim y_{t-1}, \dots, y_{t-p}$
- I — дифференцирование (помогает убрать нестационарность): $\Delta y_t = y_t - y_{t-1}$
- MA — учёт прошлых ошибок: $\varepsilon_{t-1}, \dots, \varepsilon_{t-q}$

В работе:

- ARIMA(auto): подбор по ACF/PACF (порядки ≤ 3)
- защита от вырожденного прогноза
- резервный набор порядков:
(0,1,1), (1,1,0), (0,1,0), (1,0,1)

ETS

$$l_t \leftarrow \alpha y_t + (1 - \alpha) l_{t-1},$$
$$b_t \leftarrow \beta (l_t - l_{t-1}) + (1 - \beta) b_{t-1},$$
$$s_t \leftarrow \gamma (y_t - l_t) + (1 - \gamma) s_{t-m}$$
$$\hat{y}_{t+h} = l_t + h b_t + s_{t+h}$$

ETS = Error + Trend + Seasonality

- **уровень** l_t — текущий базовый уровень ряда
- **тренд** b_t — направление изменения ряда
- **сезонность** s_t — повторяющиеся колебания
- **экспоненциальное сглаживание** — обновление состояний с весами α, β, γ

В работе:

- хорошо работает на коротких рядах
- устойчива для плавной динамики

Prophet

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t$$

Prophet = Trend + Seasonality + Holidays + Error

- $g(t)$ — кусочно-линейный тренд
- $s(t)$ — сезонность через ряд Фурье
- $h(t)$ — календарные события
- ε_t — ошибка


В работе:

- аддитивная модель
- без встроенных календарных сезонностей

Архитектура TimesNet

Превращение 1D-ряда в 2D-представления по периодам

Идея: одномерный ряд $\rightarrow$ набор 2D-«изображений» по доминирующим периодам



FFT / DFT:
$$X_k = \sum_{t=0}^{T-1} x_t e^{-\frac{i2\pi kt}{T}}, \quad k = 0, \dots, T-1$$

$|X_k|$ — амплитуда частоты k , $p_k \approx \frac{T}{k}$, $k > 0$ — соответствующий период (большие амплитуды показывают доминирующие частоты)

Ключевая формула:
$$X_i^{2D} = \text{Reshape}_{p_i, f_i}(\text{Padding}(X^{1D}))$$

столбцы — изменения внутри одного периода (**intra-period variation**);
строки — изменения между соседними периодами (**inter-period variation**);

Softmax:
$$\alpha_i = \frac{e^{a_i}}{\sum_{j=1}^K e^{a_j}}, \quad i = 1, \dots, K$$

a_i — амплитуда или оценка значимости i -го периода;
 α_i — его нормированный вес;

Реализация (TimesNetV2):

- d_model=64, layers=4, top_k=3, dropout=0.1
- MSUnit: ветки 1×1, 3×3, 7×7 + avgpool
- Padding — повторением последнего значения (не нулями — без искусственного скачка на границе окна)
- опция якоря — прогнозируется приращение относительно последнего наблюдения

Архитектура N-BEATS

Стек блоков, остаточное обновление входа и базисное разложение прогноза

Прогноз = сумма вкладов блоков. Каждый блок «объясняет» часть истории и уточняет прогноз



Ключевая формула: $x_i = x_{i-1} - \hat{x}_{i-1}$, $\hat{y} = \sum_i \hat{y}_i$

backcast вычитается из входа (блок работает с той частью ряда, которую предыдущие блоки не объяснили);
forecast суммируется в итоговый прогноз;


Реализация (NBEATSV2)

- width=256, depth=4, n_blocks=4
- share_weights=true (компактнее)
- степень полинома: 3, если $H < 18$, иначе 4
- автовыбор числа гармоник Фурье
- стабилизация первого шага прогноза

Важно: декомпозиции STL/MODWT и базисы N-BEATS не дублируют, а дополняют друг друга. STL/MODWT заранее разделяют исходный ряд на компоненты, а N-BEATS внутри модели раскладывает прогноз отдельной компоненты на вклад блоков.

Концепция HybridPlus

Раздельное моделирование компонент после MODWT-(STL-) разложения



- нейросеть — на компонентах со сложной структурой и долгосрочными зависимостями
- статистика — на регулярных/высокочастотных компонентах, где важна устойчивость
- вклад ВЧ-компонент монотонно уменьшается с ростом шага горизонта
- разность $\hat{y}_{t+1} - y_t$ ограничена робастной оценкой типичного шага ряда

Единый интерфейс класса *HybridPlus* — режим декомпозиции выбирается с помощью конфигурации *.json*

Список построенных моделей

Базовые, нейросетевые, гибридные

Базовые

- ARIMA
- ARIMA (с автоподбором)
- ETS
- Prophet

Нейросетевые

- TimesNet (без MODWT)
- N-BEATS (без MODWT)
- TimesNet+ (MODWT + TimesNet)
- N-BEATS Full (MODWT + N-BEATS)

Гибридные (HybridPlus)

- MODWT (VW) + TimesNet + ARIMA(auto)
- MODWT (VW) + TimesNet + ETS
- MODWT (VW) + N-Beats + ARIMA(auto)
- MODWT (VW) + N-Beats + ETS
- STL + TimesNet + ARIMA(auto)
- STL + N-BEATS + ARIMA(auto)
- STL + TimesNet + ETS
- STL + N-BEATS + ETS

VW — сокращение для MODWT (от англ. wavelet), используется в легендах графиков и таблиц в ВКР

Инженерные меры устойчивости

Где скрыта основная сложность гибридной модели?

Граница окна

Padding повторением последнего значения вместо нулей.
Уменьшает скачки на границе при укладке в матрицу $p \times f$ в TimesNet.

Первый шаг прогноза

Прогноз деталей смешивается с последним наблюдаемым уровнем.
Разность $\hat{y}_{t+1} - y_t$ ограничена робастной оценкой типичного шага.

Горизонт прогноза

Вклад высокочастотных компонент монотонно уменьшается с шагом.
→ не доверяем дальним прогнозам шумоподобных компонент.

Краевые артефакты MODWT

Циклическое продолжение в качестве граничного условия.
Снижает артефакты при разложении синтетических сезонных сигналов.

Данные вычислительных экспериментов

Раздел 3. Эксперименты — начало

Синтетические ряды

- профили: flat, меняющийся тренд, с многопериодной сезонностью НОК = 60, 105
- по 500 рядов на профиль
- обучение — 24 эпохи
- контролируемые условия

M3 Competition

- 100 рядов: yearly / quarterly / monthly
- стандартный набор для сравнения
- ограничение по вычислениям
- акцент на классические vs гибриды


M4 Competition

- 500 рядов на категорию
- yearly / quarterly / daily / hourly
- rollout-симуляции
- ключевая часть эксперимента

Эксперимент: ряд Q2142 (М4, квартальный)

Точечная иллюстрация работы гибридных моделей

Модель	sMAPE	MAPE	RMSE
ARIMA	4.16	4.08	57.69
ARIMA(auto)	4.15	4.07	56.81
ETS	4.12	3.99	61.49
Prophet	23.62	20.92	233.59
MODWT + TimesNet + ARIMA(auto)	4.93	4.86	67.72
MODWT + TimesNet + ETS	3.97	3.91	55.92
MODWT + N-BEATS + ARIMA(auto)	4.74	4.68	59.03
MODWT + N-BEATS + ETS	4.18	4.07	58.25



Прогнозы моделей на ряду Q2142 (H=8, L=16)


Что видно:

- лидер по всем метрикам — MODWT + TimesNet + ETS (sMAPE 3.97)
- Prophet — катастрофически плох (sMAPE 23.62, в ~6 раз хуже)
- выигрыш по абсолютной RMSE по сравнению с классикой

Эксперимент: ряд Q2147 (М4, квартальный)

Второй иллюстративный ряд — ярко выраженный тренд + сезонность

Модель	sMAPE	MAPE	RMSE
ARIMA	5.92	6.16	678.67
ARIMA(auto)	6.51	6.79	734.77
ETS	5.37	5.57	624.36
Prophet	12.84	12.02	1241.16
TimesNet (без MODWT)	5.06	5.24	593.21
N-BEATS (без MODWT)	3.06	3.10	420.79
MODWT + N-BEATS + ETS	2.32	2.33	281.41
MODWT + N-BEATS + ARIMA(auto)	4.49	4.41	502.32
MODWT + TimesNet + ETS	4.45	4.36	499.80
MODWT + TimesNet + ARIMA(auto)	4.49	4.41	502.32



Прогнозы моделей на ряду Q2147 (H=8, L=16)

Что видно:

- лидер с большим отрывом — MODWT + N-BEATS + ETS (sMAPE 2.32, RMSE 281)
- лучшая нейросеть без MODWT (N-BEATS) уступает в ~1.3 раза
- ARIMA/ETS дают sMAPE 5.3–6.5, Prophet снова заметно отстаёт

М4: годовая частотность (500 рядов)

Короткие ряды — преимущество классики и осторожности с гибридами

Модель	sMAPE	MAPE	RMSE
ARIMA	14.66	17.63	812.07
ARIMA(auto)	14.77	18.01	828.43
ETS	17.77	22.64	909.61
Prophet	22.44	35.47	1384.24
TimesNet (без MODWT)	15.68	17.48	1002.51
N-BEATS (без MODWT)	26.55	31.02	1670.70
MODWT + TimesNet + ARIMA(auto)	13.52	15.00	764.00
MODWT + TimesNet + ETS	16.86	19.93	1048.35
MODWT + N-BEATS + ARIMA(auto)	22.72	27.85	1360.15
MODWT + N-BEATS + ETS	20.90	24.97	1275.73

Наблюдения

- лучший — MODWT + TimesNet + ARIMA(auto)
- ряды короткие — нейросети не успевают обучиться
- ARIMA конкурентоспособна по всем метрикам
- N-BEATS без MODWT — самый слабый
- относительный выигрыш гибрида ~8% по sMAPE

М4: квартальная частотность (500 рядов)

Промежуточный случай — лидерство ETS, гибриды близки

Модель	sMAPE	MAPE	RMSE
ARIMA	14.39	19.54	538.91
ARIMA(auto)	14.02	19.59	519.91
ETS	13.15	15.34	505.15
Prophet	30.97	134.20	1104.47
TimesNet (без MODWT)	14.87	30.14	463.86
N-BEATS (без MODWT)	16.49	24.99	599.85
MODWT + TimesNet + ARIMA(auto)	15.60	24.73	570.47
MODWT + TimesNet + ETS	13.70	21.98	570.98
MODWT + N-BEATS + ARIMA(auto)	15.85	22.13	848.81
MODWT + N-BEATS + ETS	16.20	23.46	872.35

Наблюдения

- относит. метрики: ETS впереди
- абсолютная RMSE: TimesNet (чистый)
- гладкая динамика + слабая сезонность
- гибриды отстают незначительно
- сложность гибридов не окупается

М4: дневная частотность (500 рядов) — главный результат

Где разложение работает лучше всего

Модель	sMAPE	MAPE	RMSE
ARIMA	3.10	3.00	170.19
ARIMA(auto)	3.08	2.98	168.26
ETS	3.09	2.99	165.87
Prophet	12.46	16.54	963.78
TimesNet (без MODWT)	3.81	3.64	185.84
N-BEATS (без MODWT)	3.90	3.80	236.41
MODWT + TimesNet + ARIMA(auto)	2.13	2.15	128.94
MODWT + TimesNet + ETS	2.05	2.06	111.61
MODWT + N-BEATS + ARIMA(auto)	2.67	2.63	169.99
MODWT + N-BEATS + ETS	2.70	2.66	168.89

Главный результат

- MODWT + TimesNet + ETS — лучший
- sMAPE снижается с 3.08 → 2.05 ($\approx \times 1.5$)
- RMSE снижается на ~33%
- выигрыш на всех метриках одновременно
- тренд, календарные эффекты, шум

Гипотеза MODWT > STL: проверка

Многопериодная сезонность с НОК = 60 (500 синтетических рядов с меняющимся шумом)

Модель	sMAPE	MAPE	RMSE
TimesNet+	7.49	7.54	0.89
N-BEATS Full	7.58	7.64	0.92
MODWT + TimesNet + ARIMA(auto)	6.65	7.02	0.84
MODWT + N-BEATS + ARIMA(auto)	6.96	7.34	0.85
MODWT + TimesNet + ETS	7.15	7.49	0.88
MODWT + N-BEATS + ETS	6.63	6.98	0.82
STL + TimesNet + ARIMA(auto)	7.53	7.52	0.89
STL + N-BEATS + ARIMA(auto)	9.00	8.58	1.00
STL + TimesNet + ETS	8.94	8.51	0.99
STL + N-BEATS + ETS	9.10	8.65	1.01
ARIMA	17.99	16.54	2.06
ETS	12.79	12.23	1.43
Prophet	13.68	14.24	1.64


Гипотеза подтверждена

- MODWT-гибриды стабильно лучше STL
- лидер: MODWT + N-BEATS + ETS
- STL-гибриды (7.5–9.1) уступают MODWT (6.6–7.2)
- при НОК = 105: разрыв до 2.2 пункта sMAPE (для НОК = 105 результат приведен в тексте ВКР; здесь показан профиль НОК = 60)
- MSE у STL почти вдвое выше


Компонентные прогнозы: MODWT vs STL

Ряд со сложной сезонностью (НОК = 60, $p_1 = 12$, $p_2 = 20$)

MODWT-разложение: $A_J + \sum_{j=1}^3 D_j$



STL-разложение: тренд + сезонность + остаток



- MODWT: модели уверенно восстанавливают аппроксимацию A_J и среднечастотную D_1 ; D_2 – D_3 сглажены и тяготеют к нулю
- STL: трендовая компонента STL воспроизводится хуже, а высокочастотные колебания прячутся в остатке и плохо предсказываются

Выводы (1/2)

Раздел 4. Основные результаты работы

1

Реализован полный конвейер HybridPlus

MODWT-(STL-) декомпозиция + отдельное моделирование нейросетью (TimesNet / N-BEATS) и статистикой (ARIMA / ETS)

2

Проведено систематическое сравнение на M3, M4 и синтетических рядах

16 моделей × 4 категории частот × сценарии простой и сложной сезонности

3

На дневной частоте M4 достигнут наибольший выигрыш

sMAPE 2.05 у MODWT + TimesNet + ETS против 3.08 у лучшей классики ($\approx \times 1.5$ улучшение, RMSE -33%)

4

Гипотеза MODWT > STL подтверждена на сложной сезонности

MODWT-гибриды стабильно опережают STL-аналоги на 0.9–2.5 пунктов sMAPE; MSE у STL почти вдвое выше

Выводы (2/2). Практические рекомендации

Когда выбирать какую модель?

Сценарий	Что выбрать	Почему
Дневные / недельные ряды, метрика sMAPE/MAPE	MODWT + TimesNet/N-BEATS + ETS	разложение разделяет компоненты
Месячные / годовые (короткие) ряды	Классические ETS / ARIMA	нейросети не успевают обучиться
Сложная многопериодная сезонность	MODWT-гибриды (не STL!)	одна сезонная шкала STL недостаточна
Шумный неоднозначный тренд без сезонности	ETS	сглаживание устойчиво на шуме
Часовая частотность (предварит. результат)	Классические модели	разложение даёт фазовые искажения на ВЧ

Перспективы исследования

- автоматический выбор глубины MODWT-разложения
- адаптивное распределение моделей между компонентами
- оптимизация весов при реконструкции прогноза
- устойчивость к выбросам и структурным сдвигам

Список литературы (избранное)

Раздел 5. Полный список — 43 источника в ВКР

1. Hyndman R.J., Athanasopoulos G. Forecasting: principles and practice. — Melbourne: OTexts, 2021.
2. Box G.E.P. et al. Time series analysis: forecasting and control. — 5th ed. — Wiley, 2015.
3. Makridakis S., Spiliotis E., Assimakopoulos V. The M4 Competition // Int. J. Forecasting. — 2018. — Vol. 34(4). — P. 802–808.
4. Mallat S.G. A theory for multiresolution signal decomposition // IEEE TPAMI. — 1989. — Vol. 11(7).
5. Daubechies I. Ten lectures on wavelets. — SIAM, 1992. — 357 p.
6. Percival D.B., Walden A.T. Wavelet methods for time series analysis. — Cambridge University Press, 2000. — 594 p.
7. Cleveland R.B. et al. STL: A Seasonal-Trend Decomposition Procedure Based on LOESS.
8. Taylor S.J., Letham B. Forecasting at scale // The American Statistician. — 2018. — Vol. 72(1).
9. Wu H. et al. TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis. — arXiv:2210.02186.
10. Oreshkin B. et al. N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. — arXiv:1905.10437.
11. Olivares K.G. et al. NBEATSx // Int. J. Forecasting. — 2023.
12. Bakulin D.V. et al. Hybrid Models of Time Series Using Wavelet Transform // JCTE. — 2025. — Vol. 70.
13. Petrusevich D.A. Time series forecasting using high order ARIMA functions // SGEM. — 2019.
14. Beletskaya N.V., Petrusevich D.A. Linear Combinations of Time Series Models with Minimal Forecast Variance // JCTE. — 2022.
15. Gilles J. Empirical Wavelet Transform // IEEE TSP. — 2013.
16. Dragomiretskiy K., Zosso D. Variational Mode Decomposition // IEEE TSP. — 2014.