

МИРЭА — Российский технологический университет

Институт искусственного интеллекта

Текст выступления к защите ВКР

Построение комбинированных моделей на основе алгоритма MODWT при обработке временных рядов

Выполнил: студент КМБО-03-22 Лыков Д.С.

Научный руководитель: к.ф.-м.н., доцент ВМ Петрусевич Д.А.

Рекомендуемое распределение времени

Этап	Слайды	Время
Введение, актуальность, цель	1–5	~1:30
Постановка и алгоритмы	6–12	~3:30
HybridPlus и набор моделей	13–15	~1:30
Эксперименты и результаты	16–23	~4:00
Выводы и литература	24–26	~1:00

Текст по слайдам

Слайд 1. Титульный слайд

Добрый день, уважаемые члены комиссии! Меня зовут Лыков Даниил, и сегодня я представляю выпускную квалификационную работу на тему «Построение комбинированных моделей на основе алгоритма **MODWT** при обработке временных рядов».

Работа выполнена под руководством кандидата физико-математических наук, доцента Петрусевича Дениса Андреевича.

Слайд 2. Актуальность и место исследования

Краткосрочное прогнозирование временных рядов востребовано в задачах планирования: это продажи, трафик, потребление ресурсов и цены. На практике такие ряды часто имеют ограниченную историю, шум, сезонность и структурные сдвиги.

Главная сложность состоит в том, что универсальной модели не существует: статистические методы устойчивы на коротких рядах, а нейросетевые архитектуры лучше работают на длинных и сложных. Поэтому актуальны гибридные схемы, где ряд сначала декомпозируется, а разные компоненты прогнозируются разными моделями.

В моей работе исследуется конвейер **HybridPlus** на базе **MODWT** и **STL**, а основной вопрос состоит в сравнении многошкального разложения **MODWT** со структурным разложением **STL**.

Слайд 3. Современные подходы к прогнозированию

Все подходы можно условно разделить на три группы. Первая — классические модели: **ARIMA**, **ETS** и **Prophet**. Они интерпретируемы, часто устойчивы на короткой истории и позволяют получать доверительные интервалы, но ограничены линейностью и предположениями о структуре ряда.

Вторая группа — нейросетевые модели, в работе это **TimesNet** и **N-BEATS**. Они способны извлекать нелинейные зависимости и сложные паттерны, но чувствительны к шуму и обычно требуют более длинной истории.

Третья группа — гибридные модели. В них используются разные модели для разных компонент ряда: статистика — для деталей и шумоподобных частей, нейросеть — для низкочастотной или более сложной динамики. Именно эта идея лежит в основе **HybridPlus**.

Слайд 4. Декомпозиция временных рядов

В работе сравниваются два подхода к декомпозиции. **STL** — это структурное разложение: ряд представляется как сумма тренда, сезонности и остатка. Оно хорошо интерпретируется, но обычно опирается на одну заранее заданную сезонную шкалу.

MODWT — это многошкальное разложение: ряд представляется как низкочастотная часть и набор деталей по уровням. Важные преимущества **MODWT** — локализация во времени и по частоте, устойчивость к сдвигу и сохранение длины компонент.

Гипотеза работы заключается в том, что на рядах со сложной сезонностью многошкальное разложение **MODWT** даст преимущество перед структурным **STL** при построении гибридного прогноза.

Слайд 5. Цели и задачи работы

Цель работы — разработать и исследовать гибридный подход к краткосрочному прогнозированию унивариативных временных рядов на основе многошкальной **MODWT**-декомпозиции.

Для достижения цели решались шесть задач: формализовать постановку задачи и метрики качества; реализовать базовые модели ARIMA, ETS, Prophet, TimesNet и N-BEATS; обосновать **MODWT** как основной инструмент гибридизации; построить гибридную архитектуру с отдельным моделированием компонент; реализовать сопоставимую **STL**-гибридную схему; и провести экспериментальную оценку на синтетических данных, M3 и M4.

Далее перейду к постановке задачи и используемым алгоритмам.

Слайд 6. Постановка задачи. Метрики качества

Формально задача состоит в том, чтобы по наблюдениям временного ряда $y_1, \dots, y_T$ построить прогноз будущих значений на горизонт H : от $T + 1$ до $T + H$. В работе рассматривается унивариативный краткосрочный прогноз при фиксированном шаге дискретизации.

Качество прогноза оценивается тремя метриками. **RMSE** измеряет абсолютную ошибку в масштабе исходного ряда. **MAPE** показывает среднюю процентную ошибку, но нестабилен, если фактические значения близки к нулю. **sMAPE** — симметричная процентная ошибка, которая используется в протоколах M3 и M4.

Тестирование проводится вне обучающей выборки, в формате rollout-симуляции.

Слайд 7. Преобразование MODWT — идея

Идея **MODWT** связана с ограничением классического Фурье-анализа. Синусоиды хорошо показывают, какие частоты присутствуют в ряде, но плохо отвечают на вопрос, когда именно эти частоты проявляются.

Вейвлет-анализ решает эту проблему за счёт базисных функций, локализованных и во времени, и по частоте. Масштаб a отвечает за уровень детализации: большие масштабы описывают медленную динамику и низкие частоты, малые — быстрые колебания и высокие частоты. Сдвиг b задаёт положение окна во времени.

Для прогнозирования это важно потому, что один ряд можно представить как набор компонент разных масштабов и затем прогнозировать эти компоненты разными моделями.

Слайд 8. Преобразование MODWT — формулы

Технически **MODWT** строится как многоуровневая фильтрация временного ряда. На каждом уровне используются низкочастотный и высокочастотный фильтры: первый выделяет сглаженную часть ряда, второй — детали.

В отличие от DWT, **MODWT** не выполняет прореживание, то есть не отбрасывает каждый второй коэффициент. Поэтому все компоненты сохраняют длину исходного ряда. Это удобно для гибридной модели: компоненты можно подавать в прогнозные модели и затем суммировать обратно.

Итоговое представление имеет вид $y(t) = A_J(t) + \text{сумма } D_j(t)$, где $A_J(t)$ — низкочастотная компонента, а $D_j(t)$ — детали разных масштабов. Именно это свойство используется дальше в **HybridPlus**.

Слайд 9. STL-декомпозиция

STL — это сезонно-трендовая декомпозиция на основе LOESS-сглаживания. В этом подходе ряд раскладывается на три интерпретируемые компоненты: тренд, сезонность и остаток.

Преимущество **STL** — наглядность и гибкое выделение нелинейного тренда. Кроме того, robust-режим позволяет снижать влияние выбросов.

Ограничение состоит в том, что базовый STL требует заранее заданного сезонного периода и хуже работает при многопериодной сезонности. Поэтому STL в работе используется как важная структурная альтернатива **MODWT**.

Слайд 10. Классические модели

Классическими моделями сравнения являются **ARIMA**, **ETS** и **Prophet**.

ARIMA строит линейную модель для стационарной версии ряда: авторегрессия учитывает прошлые значения, дифференцирование помогает убрать нестационарность, а MA-компонента учитывает прошлые ошибки. В работе используется ARIMA с автоподбором по ACF/PACF, защитой от вырожденного прогноза и резервным набором порядков.

ETS описывает ряд через уровень, тренд и сезонность, которые обновляются экспоненциальным сглаживанием с весами alpha, beta и gamma. Поэтому ETS хорошо подходит для коротких рядов и плавной динамики. **Prophet** — аддитивная модель: тренд плюс сезонность плюс календарные эффекты и ошибка. В работе Prophet используется без встроенных календарных сезонностей как базовая модель сравнения.

Слайд 11. Архитектура TimesNet

TimesNet превращает одномерный временной ряд в набор двумерных представлений. Сначала применяется **FFT** — быстрое преобразование Фурье, которое показывает доминирующие частоты ряда. Затем эти частоты переводятся в соответствующие периоды.

Для каждого найденного периода ряд укладывается в двумерную матрицу: столбцы описывают изменения внутри одного периода, а строки — изменения между соседними периодами. После этого 2D-представления обрабатываются свёртками, которые учитывают оба типа зависимостей.

Результаты по периодам объединяются через softmax-агрегацию: периоды с большей амплитудой получают больший вес. В моей реализации **TimesNetV2** используется $\text{top}_k = 3$, четыре слоя, $d_{\text{model}} = 64$, MSUnit с несколькими размерами ядер, padding повторением

последнего значения и anchor-механизм, при котором модель прогнозирует приращение относительно последнего наблюдения.

Слайд 12. Архитектура N-BEATS

N-BEATS строит прогноз как сумму вкладов последовательных блоков. Блоки объединяются в стеки: трендовый стек использует полиномиальный базис, сезонный стек — базис Фурье, а generic-стек использует обучаемый базис и нужен для более гибкого описания остаточных паттернов.

Каждый блок состоит из полносвязных слоёв с ReLU и выдаёт два результата: **backcast** и **forecast**. Backcast — это часть входной истории, которую блок смог объяснить; она вычитается из входа, поэтому следующий блок работает уже с остатком. Forecast — это частичный прогноз блока, и все такие прогнозы суммируются в итоговый прогноз.

Важно не путать это с **MODWT** или **STL**. STL и MODWT заранее разделяют исходный ряд на компоненты, а **N-BEATS** уже внутри модели раскладывает прогноз отдельной компоненты на вклад блоков.

Слайд 13. Концепция HybridPlus

Концепция **HybridPlus** состоит в раздельном моделировании компонент после декомпозиции. В **MODWT**-схеме исходный ряд раскладывается на низкочастотную часть и высокочастотные детали. Низкочастотная часть содержит тренд и медленно меняющуюся динамику, поэтому для неё используются **TimesNet** или **N-BEATS**.

Высокочастотные детали содержат быстрые колебания и шумоподобные компоненты, поэтому для них применяются более устойчивые **ARIMA** или **ETS**. После раздельного прогнозирования прогнозы компонент суммируются в итоговый прогноз.

В STL-схеме логика аналогична: отдельно моделируются тренд, сезонность и остаток. В реализации используется единый класс **HybridPlus**, где режим декомпозиции выбирается через конфигурацию.

Слайд 14. Список построенных моделей

В работе реализовано шестнадцать моделей.

Первая группа — четыре базовые модели: ARIMA, ARIMA с автоподбором, ETS и Prophet. Вторая группа — нейросетевые модели: TimesNet и N-BEATS без декомпозиции, а также TimesNet+ и N-BEATS Full, где сеть применяется к компонентам **MODWT**.

Третья группа — восемь гибридных моделей **HybridPlus**: четыре на основе **MODWT** и четыре на основе **STL**. В каждой группе комбинируются **TimesNet** или **N-BEATS** с **ARIMA** или **ETS**. Такой симметричный набор позволяет аккуратно сравнить не только модели, но и сами типы декомпозиции.

Слайд 15. Инженерные меры устойчивости

Основная сложность гибридной модели скрыта не только в выборе моделей, но и в обработке границ и стабилизации прогноза.

Первая мера — padding повторением последнего значения вместо нулей. Это уменьшает искусственный скачок на границе окна при укладке ряда в матрицу **TimesNet**. Вторая мера — стабилизация первого шага прогноза: прогноз деталей смешивается с последним наблюдаемым уровнем, а разность ограничивается робастной оценкой типичного шага ряда.

Третья мера — вклад высокочастотных компонент монотонно уменьшается с шагом горизонта, потому что дальним прогнозам шумоподобных компонент нельзя доверять. Четвёртая — циклическое граничное условие для **MODWT**, снижающее артефакты при разложении синтетических сезонных сигналов.

Слайд 16. Данные вычислительных экспериментов

Эксперименты проведены на трёх типах данных.

Первый тип — синтетические ряды с контролируемой структурой: плоские ряды, ряды с меняющимся трендом и ряды со сложной многопериодной сезонностью с НОК 60 и 105. На каждый профиль использовалось по 500 рядов.

Второй и третий типы — эталонные наборы M3 и M4. Для M3 использовалось по 100 рядов в категориях yearly, quarterly и monthly. Для M4 — по 500 рядов на категорию: yearly, quarterly, daily и hourly. Основной акцент сделан на M4, потому что там ярче проявляются различия между моделями.

Слайд 17. Эксперимент: ряд Q2142

Первый иллюстративный пример — квартальный ряд Q2142 из M4. Здесь лучший результат показывает гибрид **MODWT + TimesNet + ETS**: sMAPE равна 3.97, что лучше всех классических моделей на этом ряде.

Prophet, напротив, даёт катастрофически плохой результат: sMAPE 23.62, то есть примерно в шесть раз хуже лидера. По абсолютной **RMSE** гибрид также показывает выигрыш относительно классики.

Этот пример показывает, что даже на коротком квартальном ряде декомпозиция может дать практический выигрыш.

Слайд 18. Эксперимент: ряд Q2147

Второй иллюстративный пример — квартальный ряд Q2147 с выраженным растущим трендом и заметной сезонностью.

На нём лучшим оказался гибрид **MODWT + N-BEATS + ETS**: sMAPE 2.32 и **RMSE** 281. Чистый N-BEATS без декомпозиции даёт sMAPE 3.06, то есть гибрид выигрывает примерно в 1.3 раза.

Этот пример дополняет предыдущий: на разных рядах лидируют разные гибриды, но в целом семейство **MODWT**-гибридов показывает устойчивое преимущество над базовыми подходами.

Слайд 19. M4: годовая частотность

На 500 годовых рядах M4 лучшим оказался гибрид **MODWT + TimesNet + ARIMA** с автоподбором: sMAPE 13.52. Это лучше классических моделей, но выигрыш умеренный.

Причина в том, что годовые ряды короткие, и нейросетевые модели не успевают полноценно обучиться. Поэтому ARIMA остаётся конкурентоспособной, а N-BEATS без **MODWT** оказывается самым слабым вариантом.

Практический вывод: для очень коротких рядов сложность гибридизации нужно использовать осторожно.

Слайд 20. M4: квартальная частотность

На квартальных рядах картина промежуточная. По относительным метрикам впереди ETS: sMAPE 13.15. По абсолютной RMSE лучший чистый **TimesNet** без декомпозиции.

Гибриды отстают незначительно, но дополнительная сложность их построения здесь не окупается. Это важный результат: гибридизация полезна не всегда, а прежде всего там, где в данных есть выраженная многомасштабная структура.

Для квартальных рядов с гладкой динамикой и слабой сезонностью классические модели остаются очень сильным ориентиром.

Слайд 21. M4: дневная частотность — главный результат

Это ключевой результат работы. На 500 дневных рядах M4 гибрид **MODWT + TimesNet + ETS** уверенно обходит все классические модели по всем трём метрикам.

sMAPE снижается с **3.08** у лучшей классики до 2.05 у гибрида, то есть примерно в полтора раза. **RMSE** также снижается примерно на 33 процента.

Именно на дневных рядах присутствуют тренд, календарные эффекты, локальные всплески и шум. Поэтому многошкальная декомпозиция здесь работает наиболее эффективно.

Слайд 22. Проверка гипотезы MODWT > STL

Этот эксперимент проверяет основную гипотезу работы: даёт ли **MODWT** преимущество перед **STL** на сложной многопериодной сезонности.

На синтетических рядах с НОК 60 **MODWT**-гибриды стабильно лучше **STL**-гибридов. Лучший результат показывает **MODWT + N-BEATS + ETS**: sMAPE **6.63**. **STL**-гибриды находятся в диапазоне от 7.5 до 9.1, тогда как **MODWT**-гибриды — примерно от 6.6 до 7.2.

Для профиля с НОК 105 разрыв достигает 2.2 пункта sMAPE, а MSE у **STL** почти вдвое выше. Это подтверждает, что на сложной сезонности многошкальное разложение лучше сохраняет полезную структуру сигнала.

Слайд 23. Компонентные прогнозы: MODWT vs STL

На этом слайде показано, почему **MODWT**-гибриды выигрывают на сложной сезонности. Слева — **MODWT**-разложение: аппроксимация A_J и детали разных уровней. Справа — **STL**-разложение на тренд, сезонность и остаток.

В **MODWT**-компонентах модели уверенно восстанавливают аппроксимацию и среднечастотную компоненту, а более высокочастотные детали сглаживаются и тяготеют к нулю. Это соответствует логике гибридизации: не усиливать шум на дальнем горизонте.

В **STL** часть высокочастотных колебаний попадает в остаток и хуже предсказывается. Поэтому итоговый прогноз STL-гибридов оказывается менее устойчивым.

Слайд 24. Выводы — основные результаты

Основные результаты следующие.

Во-первых, реализован полный конвейер **HybridPlus: MODWT** или **STL**-декомпозиция, отдельное моделирование компонент нейросетевыми и статистическими моделями и последующая реконструкция прогноза.

Во-вторых, проведено систематическое сравнение шестнадцати моделей на МЗ, М4 и синтетических рядах. В-третьих, на дневной частоте М4 получен наибольший выигрыш: sMAPE 2.05 у **MODWT** + TimesNet + ETS против 3.08 у лучшей классической модели, а RMSE снижается примерно на 33 процента. В-четвёртых, гипотеза **MODWT** > **STL** подтверждена на сложной сезонности.

Слайд 25. Выводы — практические рекомендации

По результатам экспериментов можно сформулировать практические рекомендации.

Для дневных и недельных рядов, особенно при оценке по sMAPE и MAPE, стоит использовать **MODWT**-гибриды. Для коротких месячных и годовых рядов чаще достаточно ETS или **ARIMA**, потому что нейросети не успевают обучиться.

При сложной многопериодной сезонности лучше выбирать **MODWT**-гибриды, а не **STL**, потому что одной сезонной шкалы STL недостаточно. Для шумного неоднозначного тренда без сезонности устойчивым выбором остаётся **ETS**. Перспективы дальнейшей работы — автоматический выбор глубины **MODWT**, адаптивное распределение моделей между компонентами и оптимизация весов при реконструкции.

Слайд 26. Список литературы и заключение

На последнем слайде приведена избранная литература: базовые источники по прогнозированию временных рядов, МЗ и М4, теории вейвлетов, **STL**, Prophet, TimesNet и N-BEATS.

По теме работы подготовлена публикация совместно с научным руководителем: «Построение гибридных моделей временных рядов на основе нейронных сетей, вейвлет-преобразования и **STL**».

Спасибо за внимание! Готов ответить на ваши вопросы.

Приложение. Возможные вопросы комиссии и ответы

В1. Почему именно MODWT, а не DWT?

DWT выполняет прореживание: на каждом уровне число коэффициентов уменьшается, и преобразование становится чувствительным к сдвигу ряда. MODWT не отбрасывает коэффициенты, сохраняет длину компонент и устойчивее при сдвиге. Для гибридной модели это важно, потому что компоненты можно напрямую подавать в прогнозные модели и затем суммировать обратно.

В2. Зачем сравнивать MODWT именно со STL?

STL — естественная структурная альтернатива: она явно выделяет тренд, сезонность и остаток. MODWT выделяет компоненты по частотным масштабам. Сравнение STL и MODWT позволяет проверить не просто качество конкретной модели, а преимущество многошкального подхода над структурной декомпозицией.

В3. Почему N-BEATS не заменяет MODWT, если у него есть свои базисы?

Это разные уровни разложения. MODWT или STL заранее разделяют исходный ряд на компоненты. N-BEATS внутри модели раскладывает прогноз отдельной компоненты на вклад блоков через полиномиальный, Фурье- или обучаемый базис. Поэтому они не дублируют, а дополняют друг друга.

В4. Почему нейросеть используется на низкочастотной части, а ARIMA/ETS — на деталях?

Низкочастотная часть содержит тренд и более устойчивую динамику, где нейросеть может извлекать сложные нелинейные зависимости. Высокочастотные детали часто содержат шум и быстрые колебания; сложная модель может начать прогнозировать шум. ARIMA и ETS на таких компонентах ведут себя устойчивее.

В5. Что означает убывание вклада высокочастотных компонент с горизонтом?

Это инженерная мера устойчивости: чем дальше шаг прогноза, тем меньше доверие к прогнозу шумоподобных деталей. Поэтому при реконструкции их вклад постепенно уменьшается, что снижает риск ухудшить общий прогноз дальними высокочастотными колебаниями.

В6. Почему лучший результат получен на дневной частоте M4?

Дневные ряды достаточно длинные для обучения нейросетей и одновременно содержат тренд, локальные всплески, календарные эффекты и шум. Поэтому именно на них есть смысл разделять ряд по масштабам и назначать разные модели на разные компоненты.

В7. Почему Prophet иногда даёт плохие результаты?

В работе Prophet используется без встроенных календарных сезонностей, чтобы сравнение было ближе к общей постановке. Но Prophet изначально хорошо работает именно там, где есть выраженные календарные признаки: праздники, выходные, специальные события. Без них и на коротких рядах он может уступать ARIMA и ETS.

В8. Что нового именно в работе?

Новизна состоит в практической реализации HybridPlus с отдельным прогнозированием компонент, инженерными мерами устойчивости и симметричным сравнением MODWT- и STL-гибридов. Также показано, что на сложной многопериодной сезонности MODWT-гибриды устойчиво превосходят STL-аналоги.

В9. Какие ограничения есть у подхода?

Основные ограничения — короткие ряды, где нейросети не успевают обучиться; часовая частотность, где возможны фазовые искажения высокочастотных компонент; и необходимость подбирать глубину MODWT-разложения. Эти пункты вынесены в перспективы развития.

В10. Как обучались модели?

На синтетических данных использовалось по 500 рядов на профиль и обучение в течение 24 эпох. На М3 и М4 оценка проводилась по выбранным категориям рядов в формате rollout, то есть прогноз строился вне обучающей выборки на последовательных окнах.