

МИРЭА — Российский технологический университет

Институт искусственного интеллекта · Кафедра высшей математики

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

# Прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей

---

Выполнил: студент группы КМБО-03-22 — Лазарев А.К.

Научный руководитель: к.ф.-м.н., доцент кафедры ВМ — Петрусевич Д.А.

Москва · 2026

## Проблематика

- **Прикладная значимость.** Краткосрочный прогноз применяется в планировании спроса, трафика и ресурсов.
- **Отсутствие универсальной модели.** Статистические методы устойчивы на коротких рядах, нейросетевые — на длинных и сложных.
- **Открытый вопрос.** Оправдывают ли обучаемая декомпозиция и механизмы долгосрочных зависимостей свою сложность?

## ЦЕЛЬ РАБОТЫ

Установить условия, при которых обучаемая декомпозиция временных рядов и нейросетевые механизмы учёта долгосрочных зависимостей обеспечивают практическое преимущество над классическими статистическими моделями, и определить области, где более простые методы остаются предпочтительными.

Раздел 1. Четыре эталонные модели сравнения


| Seasonal Naive                                                                               | Auto-ARIMA                                                                                                                                                                        | ETS                                                                                                                                                 | Prophet                                                                                                                     |
|----------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------|
| Прогноз воспроизводит значения предыдущего сезонного периода. Не имеет обучаемых параметров. | Линейная модель стационаризованного ряда: авторегрессия, интегрирование (разности) и скользящее среднее. Порядки (p, d, q) подбираются автоматически по информационному критерию. | Экспоненциальное сглаживание уровня, тренда и сезонности в пространстве состояний. Веса $\alpha$ , $\beta$ , $\gamma$ оцениваются по правдоподобию. | Аддитивная декомпозиция: кусочно-линейный тренд, сезонные гармоники и календарные эффекты с байесовской оценкой параметров. |
| Роль: эталон для метрики MASE и нижняя граница качества.                                     | Сильная сторона: устойчивость на коротких рядах.                                                                                                                                  | Сильная сторона: плавная динамика и сезонность.                                                                                                     | Особенность: гибкая настройка сезонных компонент.                                                                           |

Вывод

Классические модели интерпретируемы и устойчивы при ограниченной истории наблюдений — это сильная база сравнения.

## Раздел 1. Семь моделей: от линейных до гибридных

### DLinear — линейная модель с декомпозицией



### N-BEATS — обучаемое базисное разложение



### TimesNet — 2D-моделирование периодов



### Helformer — гибрид: Холт-Уинтерс + нейросеть



### Семейства

- **Линейные:** DLinear
- **Базисные:** N-BEATS
- **Свёрточные:** TimesNet
- **Трансформеры:** Autoformer, FEDformer, PatchTST
- **Гибридные:** Helformer

### ВЫВОД

Модели различаются способом выделения компонент ряда и механизмом учёта зависимостей — это и есть предмет сравнения.

## Раздел 2. Данные, режимы, тип декомпозиции

### Данные

- **M3 Competition.** Полный набор — 2829 рядов: 645 годовых, 756 квартальных, 1428 месячных.
- **M4 Competition.** 3000 рядов: 1000 квартальных, 1000 месячных, 1000 ежедневных.
- **Итого** 6 частотных категорий, 5829 рядов.
- **Метрики.** sMAPE, MASE, RMSE — для устойчивости выводов к выбору меры.

### Три режима прогнозирования

- **Прямой.** Весь горизонт прогнозируется за один проход модели.
- **Итеративный.** Пошаговое продвижение с подстановкой собственных прогнозов; ошибка накапливается.
- **С предобучением.** Обучение на корпусе рядов с последующим дообучением на целевом ряде.


### Тип декомпозиции

- **Фиксированная.** Правило задано заранее — ETS, DLinear, Helformer.
- **Обучаемая.** Компоненты выделяет сеть — Autoformer, FEDformer, TimesNet.
- **Без декомпозиции.** Прямое моделирование — Auto-ARIMA, PatchTST.

### ВЫВОД

Сопоставление по трём осям — длина ряда, режим обучения и тип декомпозиции — формирует структуру анализа.

## Раздел 3. Сравнительная позиция моделей по частотам



### Наблюдения

- **Лидерство классики.** Auto-ARIMA, ETS, Seasonal Naive — верхние ранги на всех частотах.
- **Лучшая нейросеть.** TimesNet, средний ранг  $\approx 4$ .
- **Отставание трансформеров** в режиме обучения на одном ряде.


### Вывод

В режиме обучения на одном ряде классические модели сохраняют лидерство, однако разрыв убывает с ростом длины ряда.

# Длина обучающей выборки как фактор

07 / 14

Раздел 3. Пороговая зависимость качества от длины ряда




## Пороговый эффект ( $\approx 50-100$ набл.)

- **Короткие ряды.** Уверенное преимущество классических моделей.
- **Длинные ряды M4 daily.** Нейросети конкурентоспособны.
- **TimesNet (3.62)** сопоставим с Auto-ARIMA (3.22) и ETS (3.46).

## ВЫВОД

Существует пороговая длина обучающей выборки: ниже неё лидирует классика, выше — нейросетевые модели выходят на её уровень.



СРЕДНИЙ ВЫИГРЫШ sMAPE

**+31.5 %**

DLinear

**+25.5 %**

Autoformer

**+18.2 %**

Heforner

## ВЫВОД

Предобучение на корпусе рядов выводит ранее слабые нейросетевые модели на конкурентоспособный уровень.



# Предобучение: эффект на прогнозе ряда

09 / 14

Раздел 3. Одна модель: обучение с нуля против предобучения



## Что показывает график

- **Серая линия** — обучающая история, чёрная — фактические значения.
- **Пунктир (с нуля)**. Прогноз Autoformer без предобучения, sMAPE 3.8 %.
- **Сплошная (предобучен)**. После предобучения sMAPE 1.0 % — прогноз плотно следует факту.

## ВЫВОД

Предобучение на корпусе рядов существенно повышает точность прогноза одной и той же модели.

# Сводное сравнение: sMAPE по категориям

Раздел 3. Предобученные нейросети и классические модели

| Модель                                | M3-Y | M3-Q | M3-M | M4-Q | M4-M | M4-D | Ср.  |
|---------------------------------------|------|------|------|------|------|------|------|
| Классические модели (per-series)      |      |      |      |      |      |      |      |
| Auto-ARIMA                            | 17.9 | 10.9 | 18.1 | 10.2 | 14.7 | 3.22 | 12.5 |
| ETS                                   | 19.1 | 10.8 | 17.4 | 9.7  | 15.1 | 3.46 | 12.6 |
| Seasonal Naive                        | 17.9 | 11.1 | 17.2 | 12.2 | 15.9 | 4.05 | 13.0 |
| Нейросетевые модели (с предобучением) |      |      |      |      |      |      |      |
| DLinear                               | 23.7 | 12.7 | 14.0 | 15.4 | 17.2 | 2.44 | 14.2 |
| TimesNet                              | 25.1 | 12.4 | 13.7 | 22.5 | 17.2 | 2.46 | 15.6 |
| PatchTST                              | 23.1 | 15.1 | 15.2 | 19.6 | 17.5 | 2.36 | 15.5 |
| Autoformer                            | 23.4 | 13.8 | 15.1 | 20.1 | 16.3 | 2.81 | 15.3 |
| FEDformer                             | 22.8 | 15.8 | 16.3 | 19.6 | 15.6 | 4.16 | 15.7 |
| N-BEATS                               | 23.8 | 14.4 | 17.3 | 21.5 | 18.3 | 3.20 | 16.4 |
| Helformer                             | 29.8 | 21.4 | 23.0 | 20.5 | 46.3 | 2.87 | 24.0 |


## Вывод

На M3 monthly и M4 daily предобученные нейросети превосходят лучшую классику; на коротких рядах классика сохраняет преимущество.

# Анализ отдельных временных рядов

11 / 14

## Раздел 3. Массовый характер преимущества нейросетей



517

из 1000 ежедневных рядов M4 —  
нейросеть точнее классики


295

рядов, где побеждают 3 и более  
нейросетевых модели

### ВЫВОД

Преимущество нейросетевых моделей на длинных рядах носит массовый, а не единичный характер.

## Раздел 3. Устойчивость моделей к накоплению ошибки



### Прямой против итеративного

- На графике пунктир — прямой прогноз, сплошная — итеративный.
- Обучаемая декомпозиция уязвима. FEDformer и TimesNet теряют около 5 п.п. sMAPE.
- PatchTST устойчив. Наименьшая деградация среди трансформеров.
- Классика стабильна. ETS и Auto-ARIMA нечувствительны к режиму.

### ВЫВОД

Сложная обучаемая декомпозиция повышает риск накопления ошибки; тип декомпозиции должен соответствовать режиму прогнозирования.

1

### Длина обучающей выборки

Определяющий фактор. Ниже  $\approx 50$ –100 наблюдений предпочтительны ETS и Auto-ARIMA; выше — нейросети конкурентоспособны.

2

### TimesNet — лучшая нейросеть

В режиме обучения на одном ряде; обучаемая 2D-декомпозиция эффективна при достаточном объёме данных.

3

### Предобучение

Повышает качество нейросетей на 18–32 % и выводит их на уровень и выше классики на M3 monthly и M4 daily.

4

### Тип декомпозиции и режим

Фиксированная декомпозиция устойчивее, обучаемая адаптивнее, но хрупка при итеративном прогнозировании.

5

### Общий вывод

Эффективность нейросетевых механизмов не абсолютна — она определяется длиной ряда, режимом обучения и объёмом данных.

# Спасибо за внимание

---

*Прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей*

Лазарев А.К. · КМБО-03-22 · Научный руководитель — Петрусевич Д.А.

*Готов ответить на вопросы комиссии*