

МИРЭА — Российский технологический университет

Институт искусственного интеллекта · Кафедра высшей математики

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей

Выполнил: студент группы КМБО-03-22 — Лазарев А.К.

Научный руководитель: к.ф.-м.н., доцент кафедры ВМ — Петрусевич Д.А.

Москва · 2026

Проблематика

- **Прикладная значимость.** Краткосрочный прогноз — основа планирования спроса, трафика, нагрузки и ресурсов.
- **Нет универсальной модели.** Классика устойчива на коротких рядах, нейросети — на длинных и сложных.
- **Открытый вопрос.** Оправдывают ли обучаемая декомпозиция и механизмы долгосрочных зависимостей свою сложность?

ЦЕЛЬ РАБОТЫ

Установить условия, при которых обучаемая декомпозиция и нейросетевые механизмы учёта долгосрочных зависимостей дают практическое преимущество над классическими моделями — и определить, где более простые методы остаются предпочтительными.

Задача прогноза

- **Дано:** ряд наблюдений $y_1, y_2, \dots, y_T$.
- **Найти:** значения $\hat{y}_{T+1}, \dots, \hat{y}_{T+N}$ на горизонте N .
- **Условия.** Одномерный краткосрочный прогноз, $N \ll T$, минимум допущений о структуре.
- **Оценка.** Out-of-sample: модель не видит тестовый отрезок при обучении.

RMSE

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

абсолютная ошибка, тот же масштаб

MASE

$$\text{MASE} = \frac{\frac{1}{N} \sum_i |y_i - \hat{y}_i|}{\frac{1}{T-m} \sum_t |y_t - y_{t-m}|}$$

относительно Seasonal Naive, безразмерна

sMAPE

$$\text{sMAPE} = \frac{100\%}{N} \sum_{i=1}^N \frac{|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|}$$

симметричная, %, стандарт протоколов M3/M4

ARIMA

$$w_t = \Delta^d y_t, \quad w_t = c + \sum_{i=1}^p \phi_i w_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

AR + интегрирование + MA; порядки (p,d,q) по ACF/PACF.

Сильная сторона: устойчивость на коротких рядах

ETS

$$\hat{y}_{t+h} = l_t + h b_t + s_{t+h}$$

Экспоненциальное сглаживание уровня, тренда и сезона.

Сильная сторона: плавная динамика и сезонность

Prophet

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t$$

Аддитивная модель: тренд + сезон Фурье + календарь.

Сильная сторона: гибкая настройка сезонных компонент

Четвёртая модель

- **Seasonal Naive** — прогноз = значение предыдущего сезонного периода; нижняя граница качества и база метрики MASE.

Раздел 2. В чём смысл различия и почему это главный вопрос работы

Фиксированная декомпозиция

Правило разложения задано человеком **заранее**: период сезонности, скользящее среднее, формулы Холта–Уинтерса. Прозрачно и устойчиво, но не подстраивается под данные.

Примеры: *ETS, DLinear, Helformer, классическая STL.*

Обучаемая декомпозиция

Компоненты выделяет **сама сеть** в процессе обучения: автокорреляция, частотные фильтры, 2D-свёртки. Гибко и адаптивно, но сложнее и рискует переобучиться.


Примеры: *Autoformer, FEDformer, TimesNet, N-BEATS.*

ЗАЧЕМ ЭТО РАЗЛИЧИЕ

Обучаемость даёт гибкость, но повышает требования к объёму данных и вычислениям. Центральный вопрос работы — **когда эта дополнительная свобода окупается, а когда фиксированное правило надёжнее.**

Раздел 2. DLinear и N-BEATS — разложение прогноза


DLinear — линейная модель с явной декомпозицией



Смысл: разделяет ряд на тренд и колебания и предсказывает их двумя простыми линейными слоями — сильный и дешёвый бейзлайн.

$$X = X_{trend} + X_{seasonal}, \quad \hat{Y} = W_t X_{trend} + W_s X_{seasonal}$$

N-BEATS — обучаемое базисное разложение с двойным остатком



Смысл: стек блоков, каждый «объясняет» часть истории (backcast) и уточняет прогноз (forecast); итог — сумма вкладов.

$$x_\ell = x_{\ell-1} - \hat{x}_{\ell-1}, \quad \hat{y} = \sum_\ell \hat{y}_\ell$$

ВЫВОД

Обе модели раскладывают прогноз на простые составляющие — но DLinear делает это фиксированно, а N-BEATS обучает базис.

Раздел 2. TimesNet и Autoformer — периодичность и дальние зависимости


TimesNet — 1D-ряд → 2D-представления по доминирующим периодам



Смысл: находит периоды через Фурье и сворачивает ряд в 2D-«картинки» — видит и внутри-, и меж-периодные изменения.

$$X^{1D} \rightarrow \text{FFT} \rightarrow p_k = \frac{T}{K}, \quad X_k^{2D} = \text{Reshape}_{p_k, f_k}(X^{1D})$$

Autoformer — обучаемая декомпозиция + авто-корреляция (ядро темы работы)




Смысл: раскладывает ряд внутри сети и заменяет внимание авто-корреляцией — ищет похожие участки на больших лагах.

$$\mathcal{R}_{xx}(\tau) = \frac{1}{L} \sum_t x_t x_{t-\tau}, \quad X = \mathcal{T} + \mathcal{S} \text{ (SeriesDecomp)}$$

ВЫВОД

Autoformer объединяет обе идеи темы: обучаемую декомпозицию и механизм учёта долгосрочных зависимостей.



$$y_t = HW(y) + \text{Attention}(Q, K, V)$$

Что делает модель

- **Холт–Уинтерс** снимает тренд и сезон — фиксированная база.
- **Внимание + LSTM** моделируют остаток и дальние зависимости.

ПОЧЕМУ В НАЗВАНИИ РАБОТЫ

Helformer сочетает обе исследуемые идеи в одной модели — это прямой тест гипотезы работы на флагманской архитектуре.

Раздел 3. Данные, режимы обучения, тип декомпозиции

Данные

- **M3 Competition.** Полный набор — 2829 рядов: годовые, квартальные, месячные.
- **M4 Competition.** 3000 рядов: квартальные, месячные, ежедневные.
- **Итого** 6 частотных категорий, 5829 рядов.
- **Метрики.** sMAPE, MASE, RMSE.

Три режима прогноза


- **Прямой.** Весь горизонт за один проход модели.
- **Итеративный.** Пошагово, с подстановкой своих прогнозов; ошибка копится.
- **С предобучением.** Обучение на корпусе рядов + дообучение на целевом.

Тип декомпозиции

- **Фиксированная.** ETS, DLinear, Helformer.
- **Обучаемая.** Autoformer, FEDformer, TimesNet.
- **Без декомпозиции.** Auto-ARIMA, PatchTST.

ВЫВОД

Анализ ведётся по трём осям — длина ряда, режим обучения и тип декомпозиции.



Что такое ранг

- На каждом ряде модели сортируются по sMAPE: 1-е место — лучшая.
- Ранги усредняются по всем рядам категории → средний ранг модели.
- Цвет:** зелёный — точнее, красный — хуже.


Как читать карту

- Верхние строки** — классика (Auto-ARIMA, ETS, S. Naive) в топе.
- TimesNet** — единственная нейросеть рядом с лидерами.

ВЫВОД

При обучении на одном ряде классика устойчиво лидирует во всех категориях; среди нейросетей выделяется только TimesNet.

Раздел 3. Пороговая зависимость качества от длины ряда



Пороговый эффект ($\approx 50-100$ набл.)


- **Короткие ряды.** Уверенно лидирует классика.
- **Длинные M4 daily.** Нейросети догоняют классику.

Значения sMAPE на диаграмме

- **Auto-ARIMA 3.22 • ETS 3.46** — классика (лидеры).
- **TimesNet 3.62** — уже на уровне классики.
- **PatchTST, N-BEATS, Helformer ≈ 4.5** — близкая группа.

ВЫВОД

Есть пороговая длина выборки: ниже неё лидирует классика, выше — нейросети выходят на её уровень.



СРЕДНИЙ ВЫИГРЫШ sMAPE

+31.5 %

DLinear

+25.5 %


Autoformer

+18.2 %

HeliFormer

ВЫВОД

Предобучение на корпусе рядов выводит ранее слабые нейросетевые модели на конкурентоспособный уровень.



Линии на графике

- Серая — обучающая история.
- Чёрная — фактические значения.
- Оранжевый пунктир — Autoformer с нуля, sMAPE 3.8 %.
- Оранжевая сплошная — Autoformer предобучен, sMAPE 1.0 %.

Обратите внимание

- Прогноз начинается от последней точки обучения — без разрыва.

Вывод

Предобучение существенно повышает точность одной и той же модели — прогноз плотно следует факту.



Модели и sMAPE

- Факт — чёрная жирная линия.
- PatchTST — 0.3 %
- FEDformer — 0.6 %
- Helformer — 0.7 %
- Autoformer — 1.1 %
- Auto-ARIMA — 1.3 % (пунктир)
- ETS — 1.3 % (пунктир)

ВЫВОД Предобученные нейросети (сплошные) точнее классических ARIMA и ETS (пунктир) и плотно повторяют факт.


Сводное сравнение: sMAPE по категориям

Раздел 3. Предобученные нейросети и классические модели

Модель	M3-Y	M3-Q	M3-M	M4-Q	M4-M	M4-D	Ср.
Классические модели (per-series)							
Auto-ARIMA	17.9	10.9	18.1	10.2	14.7	3.22	12.5
ETS	19.1	10.8	17.4	9.7	15.1	3.46	12.6
Seasonal Naive	17.9	11.1	17.2	12.2	15.9	4.05	13.0
Нейросетевые модели (с предобучением)							
DLinear	23.7	12.7	14.0	15.4	17.2	2.44	14.2
TimesNet	25.1	12.4	13.7	22.5	17.2	2.46	15.6
PatchTST	23.1	15.1	15.2	19.6	17.5	2.36	15.5
Autoformer	23.4	13.8	15.1	20.1	16.3	2.81	15.3
FEDformer	22.8	15.8	16.3	19.6	15.6	4.16	15.7
N-BEATS	23.8	14.4	17.3	21.5	18.3	3.20	16.4
Helformer	29.8	21.4	23.0	20.5	46.3	2.87	24.0

ВЫВОД

На M3 monthly и M4 daily (выделено) предобученные нейросети превосходят лучшую классику; на коротких рядах классика сохраняет преимущество.



Линии на графике

- Факт — чёрная линия.
- N-BEATS — 3.1 %
- PatchTST — 4.5 %
- DLinear — 6.0 %
- Auto-ARIMA — 11.2 % (пунктир)

517

из 1000 ежедневных рядов
M4 — нейросеть точнее
классики

295

рядов — побеждают 3+
нейросетевые модели

ВЫВОД

Преимущество нейросетей на длинных рядах носит массовый, а не единичный характер.

Деградация при переходе от прямого режима к итеративному

- **Обучаемая декомпозиция уязвима.** FEDformer и TimesNet теряют ~5 п.п. sMAPE — компоненты искажаются на собственных прогнозах.
- **PatchTST устойчив.** Наименьшая деградация: работает с патчами без явного разделения на компоненты.
- **Классика стабильна.** ETS и Auto-ARIMA почти нечувствительны — рекуррентность заложена в модель.
- **Закономерность.** Чем сложнее обучаемое разложение, тем сильнее копится ошибка.


СЛЕДСТВИЕ

Сложная обучаемая декомпозиция повышает риск накопления ошибки при многошаговом прогнозе. Для итеративных задач простые и классические модели предпочтительнее.

Рекомендация: выбор модели учитывает не только точность, но и режим её применения.

ВЫВОД

Тип декомпозиции должен соответствовать режиму прогнозирования.



Столбцы на диаграмме

- Синий — прямой прогноз.
- Оранжевый — итеративный прогноз.

Что видно

- Классика (S. Naive, ARIMA, ETS) — деградации нет.
- FEDformer, Autoformer, TimesNet теряют 4–6 п.п. sMAPE.

ВЫВОД

Чем сложнее обучаемая декомпозиция, тем сильнее накопление ошибки; классика к режиму нечувствительна.

1

Длина обучающей выборки

Определяющий фактор. Ниже ≈ 50 –100 наблюдений — ETS и Auto-ARIMA; выше — нейросети конкурентоспособны.

2

TimesNet — лучшая нейросеть

В режиме обучения на одном ряде: обучаемая 2D-декомпозиция эффективна при достаточном объёме данных.

3

Предобучение

Повышает качество нейросетей на 18–32 % и выводит их на уровень и выше классики на M3 monthly и M4 daily.

4

Тип декомпозиции и режим

Фиксированная устойчивее, обучаемая адаптивнее, но хрупка при итеративном прогнозе.

5

Общий вывод

Эффективность нейросетевых механизмов не абсолютна — её определяют длина ряда, режим обучения и объём данных.

Сценарий	Что выбрать	Почему
Короткие ряды (годовые, месячные)	Классика: ETS / Auto-ARIMA	Нейросети не успевают обучиться на малой истории
Длинные ряды (ежедневные, недельные)	Нейросети с предобучением	Длина раскрывает обучаемую декомпозицию и дальние зависимости
Есть корпус похожих рядов	Предобучение + дообучение	Перенос знаний даёт +18–32 % к качеству
Итеративный (rollout) прогноз	Простые / классические модели	Сложная обучаемая декомпозиция копит ошибку на горизонте
Гладкий тренд без сезонности	ETS	Сглаживание устойчиво к шуму

Вывод

Сложная модель оправдана при длинных рядах, доступном корпусе для предобучения и прямом (не итеративном) режиме.

Раздел 5. Полный список — 51 источник в ВКР

1. Hyndman R.J., Athanasopoulos G. Forecasting: principles and practice. — OTexts, 2021.
2. Makridakis S. et al. The M4 Competition // Int. J. Forecasting. — 2020. — Vol. 36(1).
3. Makridakis S., Hibon M. The M3-Competition // Int. J. Forecasting. — 2000. — Vol. 16(4).
4. Cleveland R.B. et al. STL: A Seasonal-Trend Decomposition Procedure. — 1990.
5. Hyndman R.J. et al. A state space framework for automatic forecasting. — 2002.
6. Taylor S.J., Letham B. Forecasting at scale // The American Statistician. — 2018.
7. Zeng A. et al. Are Transformers Effective for Time Series Forecasting? (DLinear) // AAAI. — 2023.
8. Oreshkin B.N. et al. N-BEATS. — arXiv:1905.10437, 2020.
9. Wu H. et al. TimesNet: Temporal 2D-Variation Modeling. — ICLR, 2023.
10. Wu H. et al. Autoformer: Decomposition Transformers with Auto-Correlation. — NeurIPS, 2021.
11. Zhou T. et al. FEDformer // ICML. — 2022.
12. Nie Y. et al. A Time Series is Worth 64 Words (PatchTST). — ICLR, 2023.
13. Kehinde T.O. et al. Helformer // J. Big Data. — 2025.
14. Vaswani A. et al. Attention Is All You Need. — NeurIPS, 2017.

ВЫВОД

Полный пронумерованный список из 51 источника по ГОСТ Р 7.0.5-2008 приведён в тексте ВКР.

Спасибо за внимание

Прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей

Лазарев А.К. · КМБО-03-22 · Научный руководитель — Петрусевич Д.А.

Готов ответить на вопросы комиссии

Себестоимость проекта

Доп. 1

Экономическая часть · калькуляция разработки сервиса «ГМ-ПВР»

Статья затрат	Затраты, Р	Доля
Материалы и расходники	5 210	0,6 %
Спец. оборудование (GPU, хранение)	27 000	3,0 %
Основная заработная плата	240 830	27,1 %
Дополнительная ЗП (20 %)	48 166	5,4 %
Страховые взносы (30,2 %)	87 276,8	9,8 %
Накладные расходы (200 %)	481 660	54,1 %
Итого	890 142,8	100 %

890 142,8 Р

полная себестоимость (метод калькулирования)

60 000 Р

оклад руководителя · 25 раб. дней

50 000 Р

оклад разработчика · 90 раб. дней

ВЫВОД Большая часть бюджета — накладные расходы (54,1 %) и основная зарплата (27,1 %): главный ресурс — труд исполнителей.

Окупаемость и эффективность проекта

Доп. 2

Экономическая часть · NPV, PI, срок окупаемости при ставке 22 %

890 142,8 ₺

IC — инвестиции

≈ 48,0 млн ₺

NPV — чистая прив. стоимость

≈ 54,93

PI — индекс рентабельности

≈ 2,4 мес.

DPP — диск. окупаемость

Период	CF, тыс. ₺	$k = 1/(1+r)^i$	PV, тыс. ₺
Год 0 (инвестиции)	-890,1	1,0000	-890,1
Год 1	5 345,9	0,8197	4 381,9
Год 2	26 239,8	0,6719	17 629,5
Год 3	48 818,7	0,5507	26 884,8
NPV			48 006,1

Консервативный сценарий

Прирост клиентской базы по 1 в месяц:

$$S = 85\,000 \cdot \frac{N(N+1)}{2} \geq 890\,142,8$$


N = 4 → 850 000 ₺ — не покрывает; N = 5 → 1 275 000 ₺ — покрывает.

Полная окупаемость — к концу 5-го месяца продаж.

План продаж и эффект для клиента

Доп. 3

Экономическая часть · 3-летний P&L и экономия потребителя «ГМ-ПВР»



Экономия клиента, ₽/мес

≈ 815 000

≈ 9,78 млн ₽/ год на одного клиента

Снижение потерь (25 %) +750 000 · экономия на специалистах +150 000 · подписка –85 000

Модель	B2B SaaS, REST API
Тариф	85 000 ₽/мес
ОПФ	ООО · УСН 6 %
SOM	≈ 60 млн ₽/год

ВЫВОД

Подписочная SaaS-модель: предельные издержки на нового клиента малы, основные инвестиции уже понесены.