

МИРЭА — Российский технологический университет

Институт искусственного интеллекта · Кафедра высшей математики

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей

Выполнил: студент группы КМБО-03-22 — Лазарев А.К.

Научный руководитель: к.ф.-м.н., доцент кафедры ВМ — Петрусевич Д.А.

Москва, 2026

Актуальность и цель работы

Раздел 1. Постановка исследования

- **Краткосрочный прогноз** временных рядов нужен в планировании: продажи, трафик, спрос, ресурсы.
- **Универсальной модели нет:** классика устойчива на коротких рядах, нейросети сильнее на длинных и сложных.
- **Современные архитектуры** включают обучаемую декомпозицию и механизмы долгосрочных зависимостей — но дают ли они реальный выигрыш?

ЦЕЛЬ РАБОТЫ

Определить условия, при которых обучаемая декомпозиция и нейросетевые механизмы учёта долгосрочных зависимостей дают практическое преимущество над классическими статистическими моделями — и когда более простые методы предпочтительнее.

Модели и масштаб эксперимента

Раздел 1. Что и на чём сравнивалось

Классические модели (4)

- Seasonal Naive · Auto-ARIMA
- ETS · Prophet

Нейросетевые модели (7)

- DLinear · N-BEATS · TimesNet
- Autoformer · FEDformer · PatchTST
- Helformer (гибрид: HW-декомпозиция + нейросеть)

ДАННЫЕ

- **M3 Competition** — 2829 рядов (полный набор)
- **M4 Competition** — 3000 рядов (Q + M + D)
- 6 частотных категорий, 5829 рядов


ТРИ РЕЖИМА

- Прямое прогнозирование
- Итеративное прогнозирование
- Предобучение на корпусе рядов

Методология: декомпозиция и зависимости

Раздел 2. Два ключевых механизма


- **Фиксированная декомпозиция** — ETS, DLinear, Helformer: тренд и сезонность выделяются заранее заданным правилом.
- **Обучаемая декомпозиция** — Autoformer, FEDformer, TimesNet: компоненты выделяет сама сеть в ходе обучения.
- **Долгосрочные зависимости** — внимание, свёртки, линейные проекции.



Средний sMAPE и MASE по типу декомпозиции — обучаемая выигрывает только при достатке данных.

Прямое прогнозирование: общая картина

Раздел 3. Кто лидирует по частотам




- Классика (ARIMA, ETS, S. Naive) стабильно лидирует
- TimesNet — лучшая нейросеть, средний ранг ≈ 4
- Трансформеры в per-series режиме отстают
- С ростом частоты разрыв сокращается

Длина ряда — ключевой фактор

Раздел 3. Где нейросети догоняют классику


Порог ≈ 50 –100 наблюдений



- Короткие ряды — преимущество классики
- Длинные ежедневные ряды M4 — нейросети конкурентоспособны
- TimesNet вплотную к Auto-ARIMA

Предобучение — главный результат

Раздел 3. Эффект переноса знаний



+31.5%

DLinear — наибольший выигрыш

+25.5%

Autoformer

+18.2%

Heforner

Предобученные нейросети обходят классику


Раздел 3. M3 monthly и M4 daily



- M3 monthly: предобученный TimesNet точнее ETS
- M4 daily: предобученный PatchTST обходит Auto-ARIMA и ETS
- Предобучение сдвигает порог конкурентоспособности вниз

Анализ отдельных рядов

Раздел 3. Где нейросети явно точнее



517

из 1000 ежедневных рядов
нейросеть лучше классики

295

рядов, где побеждают
3+ нейросетевых модели

Итеративное прогнозирование

Раздел 3. Хрупкость обучаемой декомпозиции

- При накоплении ошибки сильнее всего деградируют модели с обучаемой декомпозицией.
- **FEDformer** и **TimesNet** теряют около +5 п.п. sMAPE при переходе к итеративному режиму.
- **PatchTST** (без явной декомпозиции) — наиболее устойчивый трансформер.
- **Классические модели** (ETS, Auto-ARIMA) практически нечувствительны к режиму.

Вывод: сложная обучаемая декомпозиция — это риск при многошаговом прогнозе. Простые и классические модели предпочтительнее, если нужен итеративный режим.

Выводы и практические рекомендации

Раздел 4. Основные результаты

- **Длина ряда решает.** Ниже ≈ 50 –100 наблюдений лидирует классика (ETS, Auto-ARIMA); выше — нейросети конкурентоспособны.
- **TimesNet — лучшая нейросеть** в per-series режиме; обучаемая 2D-декомпозиция эффективна при недостатке данных.
- **Предобучение кардинально усиливает нейросети** (+18...32 %) и выводит их на уровень и выше классики (M3 monthly, M4 daily).
- **Тип декомпозиции должен соответствовать режиму:** фиксированная — устойчивее, обучаемая — адаптивнее, но хрупка при итеративном прогнозе.
- **Ответ не бинарный:** эффективность нейросетевых механизмов зависит от длины ряда, режима обучения и объёма данных.

Спасибо за внимание!

Прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей

Лазарев А.К. · КМБО-03-22 · Научный руководитель Петрусевич Д.А.