

МИРЭА — Российский технологический университет

Институт искусственного интеллекта · Кафедра высшей математики

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА**

# Прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей

---

Выполнил: студент группы КМБО-03-22 — Лазарев А.К.

Научный руководитель: к.ф.-м.н., доцент кафедры ВМ — Петрусевич Д.А.

Москва · 2026

## Проблематика

- **Прикладная значимость.** Краткосрочный прогноз применяется в планировании спроса, трафика и ресурсов.
- **Отсутствие универсальной модели.** Статистические методы устойчивы на коротких рядах, нейросетевые — на длинных и сложных.
- **Открытый вопрос.** Оправдывают ли обучаемая декомпозиция и механизмы долгосрочных зависимостей свою сложность?

## ЦЕЛЬ РАБОТЫ

Установить условия, при которых обучаемая декомпозиция временных рядов и нейросетевые механизмы учёта долгосрочных зависимостей обеспечивают практическое преимущество над классическими статистическими моделями, и определить области, где более простые методы остаются предпочтительными.

Раздел 1. Четыре эталонные модели сравнения


| Seasonal Naive                                                                               | Auto-ARIMA                                                                                                                                                                        | ETS                                                                                                                                                 | Prophet                                                                                                                     |
|----------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------|
| Прогноз воспроизводит значения предыдущего сезонного периода. Не имеет обучаемых параметров. | Линейная модель стационаризованного ряда: авторегрессия, интегрирование (разности) и скользящее среднее. Порядки (p, d, q) подбираются автоматически по информационному критерию. | Экспоненциальное сглаживание уровня, тренда и сезонности в пространстве состояний. Веса $\alpha$ , $\beta$ , $\gamma$ оцениваются по правдоподобию. | Аддитивная декомпозиция: кусочно-линейный тренд, сезонные гармоники и календарные эффекты с байесовской оценкой параметров. |
| Роль: эталон для метрики MASE и нижняя граница качества.                                     | Сильная сторона: устойчивость на коротких рядах.                                                                                                                                  | Сильная сторона: плавная динамика и сезонность.                                                                                                     | Особенность: гибкая настройка сезонных компонент.                                                                           |

ВЫВОД


Классические модели интерпретируемы и устойчивы при ограниченной истории наблюдений — это сильная база сравнения.

## Раздел 1. Семь моделей: от линейных до гибридных

### DLinear — линейная модель с декомпозицией



### N-BEATS — обучаемое базисное разложение



### TimesNet — 2D-моделирование периодов



### Helformer — гибридный: Холт-Уинтерс + нейросеть



### Семейства

- **Линейные:** DLinear
- **Базисные:** N-BEATS
- **Свёрточные:** TimesNet
- **Трансформеры:** Autoformer, FEDformer, PatchTST
- **Гибридные:** Helformer

### ВЫВОД

Модели различаются способом выделения компонент ряда и механизмом учёта зависимостей — это и есть предмет сравнения.

## Раздел 2. Данные, режимы, тип декомпозиции

### Данные

- **M3 Competition.** Полный набор — 2829 рядов: 645 годовых, 756 квартальных, 1428 месячных.
- **M4 Competition.** 3000 рядов: 1000 квартальных, 1000 месячных, 1000 ежедневных.
- **Итого** 6 частотных категорий, 5829 рядов.
- **Метрики.** sMAPE, MASE, RMSE — для устойчивости выводов к выбору меры.

### Три режима прогнозирования


- **Прямой.** Весь горизонт прогнозируется за один проход модели.
- **Итеративный.** Пошаговое продвижение с подстановкой собственных прогнозов; ошибка накапливается.
- **С предобучением.** Обучение на корпусе рядов с последующим дообучением на целевом ряде.

### Тип декомпозиции

- **Фиксированная.** Правило задано заранее — ETS, DLinear, Helformer.
- **Обучаемая.** Компоненты выделяет сеть — Autoformer, FEDformer, TimesNet.
- **Без декомпозиции.** Прямое моделирование — Auto-ARIMA, PatchTST.

### ВЫВОД

Сопоставление по трём осям — длина ряда, режим обучения и тип декомпозиции — формирует структуру анализа.




## Как читать карту

- **Строка** — модель, столбец — частотная категория.
- **Цвет** — ранг: зелёный = лучше, красный = хуже.
- **Зелёная полоса сверху** — классика (Auto-ARIMA, ETS, S. Naive) стабильно в топе.
- **TimesNet** — единственная нейросеть рядом с лидерами.

## Вывод

В режиме обучения на одном ряде классика устойчиво лидирует во всех категориях; среди нейросетей выделяется только TimesNet.




### Пороговый эффект ( $\approx 50-100$ набл.)

- **Короткие ряды.** Уверенное преимущество классических моделей.
- **Длинные ряды M4 daily.** Нейросети конкурентоспособны.
- **TimesNet (3.62)** сопоставим с Auto-ARIMA (3.22) и ETS (3.46).

### ВЫВОД

Существует пороговая длина обучающей выборки: ниже неё лидирует классика, выше — нейросетевые модели выходят на её уровень.



СРЕДНИЙ ВЫИГРЫШ sMAPE

**+31.5 %**

DLinear

**+25.5 %**

Autoformer

**+18.2 %**

HeliFormer

## ВЫВОД

Предобучение на корпусе рядов выводит ранее слабые нейросетевые модели на конкурентоспособный уровень.



# Предобучение: эффект на прогнозе ряда

09 / 16

Раздел 3. Одна модель: обучение с нуля против предобучения



## Что показывает график

- **Серая линия** — обучающая история, чёрная — фактические значения.
- **Пунктир (с нуля)**. Прогноз Autoformer без предобучения, sMAPE 3.8 %.
- **Сплошная (предобучен)**. После предобучения sMAPE 1.0 % — прогноз плотно следует факту.

## ВЫВОД

Предобучение на корпусе рядов существенно повышает точность прогноза одной и той же модели.

# Сводное сравнение: sMAPE по категориям

Раздел 3. Предобученные нейросети и классические модели

| Модель                                | M3-Y | M3-Q | M3-M | M4-Q | M4-M | M4-D | Ср.  |
|---------------------------------------|------|------|------|------|------|------|------|
| Классические модели (per-series)      |      |      |      |      |      |      |      |
| Auto-ARIMA                            | 17.9 | 10.9 | 18.1 | 10.2 | 14.7 | 3.22 | 12.5 |
| ETS                                   | 19.1 | 10.8 | 17.4 | 9.7  | 15.1 | 3.46 | 12.6 |
| Seasonal Naive                        | 17.9 | 11.1 | 17.2 | 12.2 | 15.9 | 4.05 | 13.0 |
| Нейросетевые модели (с предобучением) |      |      |      |      |      |      |      |
| DLinear                               | 23.7 | 12.7 | 14.0 | 15.4 | 17.2 | 2.44 | 14.2 |
| TimesNet                              | 25.1 | 12.4 | 13.7 | 22.5 | 17.2 | 2.46 | 15.6 |
| PatchTST                              | 23.1 | 15.1 | 15.2 | 19.6 | 17.5 | 2.36 | 15.5 |
| Autoformer                            | 23.4 | 13.8 | 15.1 | 20.1 | 16.3 | 2.81 | 15.3 |
| FEDformer                             | 22.8 | 15.8 | 16.3 | 19.6 | 15.6 | 4.16 | 15.7 |
| N-BEATS                               | 23.8 | 14.4 | 17.3 | 21.5 | 18.3 | 3.20 | 16.4 |
| Helformer                             | 29.8 | 21.4 | 23.0 | 20.5 | 46.3 | 2.87 | 24.0 |


ВЫВОД

На M3 monthly и M4 daily предобученные нейросети превосходят лучшую классику; на коротких рядах классика сохраняет преимущество.

# Анализ отдельных временных рядов

11 / 16

## Раздел 3. Массовый характер преимуществ нейросетей



517

из 1000 ежедневных рядов M4 —  
нейросеть точнее классики

295

рядов, где побеждают 3 и более  
нейросетевых модели

### ВЫВОД

Преимущество нейросетевых моделей на длинных рядах носит массовый, а не единичный характер.

### Деградация при переходе от прямого режима к итеративному

- **Обучаемая декомпозиция уязвима.** FEDformer и TimesNet теряют около 5 п.п. sMAPE — выделенные компоненты искажаются на собственных прогнозах.
- **PatchTST устойчив.** Наименьшая деградация среди трансформеров: модель работает с патчами без явного разделения на компоненты.
- **Классические модели стабильны.** ETS и Auto-ARIMA практически нечувствительны к режиму — рекуррентная структура заложена в самой модели.
- **Закономерность.** Чем сложнее обучаемое разложение, тем сильнее накопление ошибки на горизонте.

### СЛЕДСТВИЕ

Сложная обучаемая декомпозиция повышает риск накопления ошибки при многошаговом прогнозе. В задачах с итеративным прогнозированием простые и классические модели предпочтительнее.


---

**Рекомендация:** выбор модели должен учитывать не только точность, но и режим её применения.

### ВЫВОД

Тип декомпозиции должен соответствовать режиму прогнозирования.

## Раздел 3. Прямой vs итеративный sMAPE по моделям (M3)



### Что показывает диаграмма

- **Синий** — прямой прогноз, оранжевый — итеративный.
- **Классика** (S. Naive, ARIMA, ETS) — деградации практически нет.
- **Обучаемая декомпозиция** (FEDformer, Autoformer, TimesNet) теряет 4–6 п.п. sMAPE.
- **Модели упорядочены** по росту деградации слева направо.

### ВЫВОД

Чем сложнее обучаемая декомпозиция, тем сильнее накопление ошибки в итеративном режиме; классика к режиму нечувствительна.

1

### Длина обучающей выборки

Определяющий фактор. Ниже  $\approx 50$ –100 наблюдений предпочтительны ETS и Auto-ARIMA; выше — нейросети конкурентоспособны.

2

### TimesNet — лучшая нейросеть

В режиме обучения на одном ряде; обучаемая 2D-декомпозиция эффективна при достаточном объёме данных.

3

### Предобучение

Повышает качество нейросетей на 18–32 % и выводит их на уровень и выше классики на M3 monthly и M4 daily.

4

### Тип декомпозиции и режим

Фиксированная декомпозиция устойчивее, обучаемая адаптивнее, но хрупка при итеративном прогнозировании.

5

### Общий вывод

Эффективность нейросетевых механизмов не абсолютна — она определяется длиной ряда, режимом обучения и объёмом данных.

1. Hyndman R.J., Athanasopoulos G. Forecasting: principles and practice. — Melbourne: OTexts, 2021.
2. Box G.E.P., Jenkins G.M. Time series analysis: forecasting and control. — Holden-Day, 1970.
3. Makridakis S., Spiliotis E., Assimakopoulos V. The M4 Competition // Int. J. Forecasting. — 2020. — Vol. 36(1).
4. Makridakis S., Hibon M. The M3-Competition // Int. J. Forecasting. — 2000. — Vol. 16(4).
5. Cleveland R.B. et al. STL: A Seasonal-Trend Decomposition Procedure Based on Loess // J. Official Statistics. — 1990.
6. Hyndman R.J. et al. A state space framework for automatic forecasting // Int. J. Forecasting. — 2002.
7. Taylor S.J., Letham B. Forecasting at scale // The American Statistician. — 2018. — Vol. 72(1).
8. Zeng A. et al. Are Transformers Effective for Time Series Forecasting? (DLinear) // AAAI. — 2023.
9. Oreshkin B.N. et al. N-BEATS: Neural basis expansion analysis. — arXiv:1905.10437, 2020.
10. Wu H. et al. TimesNet: Temporal 2D-Variation Modeling. — ICLR, 2023.
11. Wu H. et al. Autoformer: Decomposition Transformers with Auto-Correlation. — NeurIPS, 2021.
12. Zhou T. et al. FEDformer: Frequency Enhanced Decomposed Transformer // ICML. — 2022.
13. Nie Y. et al. A Time Series is Worth 64 Words (PatchTST). — ICLR, 2023.
14. Kehinde T.O. et al. Helformer: An Attention-Based Deep Learning Model // J. Big Data. — 2025.
15. Vaswani A. et al. Attention Is All You Need. — NeurIPS, 2017.
16. Wen Q. et al. Transformers in Time Series: A Survey // IJCAI. — 2023.

## ВЫВОД

Полный пронумерованный список из 49 источников по ГОСТ Р 7.0.5-2008 приведён в тексте ВКР.

# Спасибо за внимание

---

*Прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей*

Лазарев А.К. · КМБО-03-22 · Научный руководитель — Петрусевич Д.А.

*Готов ответить на вопросы комиссии*