

МИРЭА — Российский технологический университет

Институт искусственного интеллекта · Кафедра высшей математики

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей

Выполнил: студент группы КМБО-03-22 — Лазарев А.К.

Научный руководитель: к.ф.-м.н., доцент кафедры ВМ — Петрусевич Д.А.

Москва, 2026

Актуальность и цель работы

Раздел 1. Постановка исследования

- **Краткосрочный прогноз** временных рядов нужен в планировании: продажи, трафик, спрос, ресурсы.
- **Универсальной модели нет:** классика устойчива на коротких рядах, нейросети сильнее на длинных и сложных.
- **Современные архитектуры** включают обучаемую декомпозицию и механизмы долгосрочных зависимостей — но дают ли они реальный выигрыш?

ЦЕЛЬ РАБОТЫ

Определить условия, при которых обучаемая декомпозиция и нейросетевые механизмы учёта долгосрочных зависимостей дают практическое преимущество над классическими статистическими моделями — и когда более простые методы предпочтительнее.

Модели и масштаб эксперимента

Раздел 1. Состав моделей и экспериментальная база

Классические модели (4)

- Seasonal Naive · Auto-ARIMA
- ETS · Prophet

Нейросетевые модели (7)

- DLinear · N-BEATS · TimesNet
- Autoformer · FEDformer · PatchTST
- Helformer (гибрид: HW-декомпозиция + нейросеть)

ДАННЫЕ

- **M3 Competition** — 2829 рядов (полный набор)
- **M4 Competition** — 3000 рядов (Q + M + D)
- 6 частотных категорий, 5829 рядов


ТРИ РЕЖИМА

- Прямое прогнозирование
- Итеративное прогнозирование
- Предобучение на корпусе рядов

Методология: декомпозиция и зависимости

Раздел 2. Два ключевых механизма


- **Фиксированная декомпозиция** — ETS, DLinear, Helformer: тренд и сезонность выделяются заранее заданным правилом.
- **Обучаемая декомпозиция** — Autoformer, FEDformer, TimesNet: компоненты выделяет сама сеть в ходе обучения.
- **Долгосрочные зависимости** — внимание, свёртки, линейные проекции.



Главное: сама по себе обучаемая декомпозиция не гарантирует выигрыша — решает объём данных и режим обучения.

Прямое прогнозирование: общая картина

Раздел 3. Классика устойчиво впереди, TimesNet — лучшая нейросеть




- **Классика впереди.** Auto-ARIMA, ETS и Seasonal Naive занимают верхние ранги на всех шести частотах.
- **TimesNet — лучшая нейросеть**, средний ранг ≈ 4 , вплотную к классике.
- **Трансформеры** (Autoformer, FEDformer) в режиме обучения на одном ряде заметно отстают.
- **Тенденция:** чем длиннее ряды, тем выше поднимаются нейросети.

Главное: в обычном режиме классика побеждает, но разрыв сокращается с ростом длины ряда.

Длина ряда — ключевой фактор

Раздел 3. Порог длины ряда определяет исход сравнения




Порог ≈ 50 –100 наблюдений

- **Короткие ряды** — уверенное преимущество классики.
- **Длинные ежедневные ряды M4** — нейросети конкурентоспособны.
- **TimesNet (3.62)** вплотную к Auto-ARIMA (3.22) и ETS (3.46).
- **Prophet** стоит особняком — слаб на недельной сезонности.

Главное: ниже порога длины лидирует классика, выше — нейросети выходят на её уровень.

Предобучение — главный результат

Раздел 3. Эффект переноса знаний



+31.5%

DLinear — наибольший выигрыш от предобучения

+25.5%

Autoformer

+18.2%

Helformer

Главное: предобучение на корпусе рядов превращает слабые в обычном режиме нейросети в сильные.

Предобученные нейросети обходят классику

Раздел 3. Превосходство на среднечастотных и длинных рядах



- **M3 monthly:** предобученный TimesNet (13.68) точнее ETS (17.42).
- **M4 daily:** предобученный PatchTST (2.36) обходит Auto-ARIMA (3.22) и ETS (3.46).
- **На графике** цветные линии предобученных нейросетей идут плотно к чёрной фактической линии, пунктир классики — дальше.

Главное: при достатке данных предобученные нейросети не догоняют, а превосходят лучшую классику.

Предобученные нейросети vs классические модели

Раздел 3. Сравнение sMAPE по шести частотным категориям

Модель	M3-Y	M3-Q	M3-M	M4-Q	M4-M	M4-D	Ср.
Классические модели (per-series)							
Auto-ARIMA	17.9	10.9	18.1	10.2	14.7	3.22	12.5
ETS	19.1	10.8	17.4	9.7	15.1	3.46	12.6
Seasonal Naive	17.9	11.1	17.2	12.2	15.9	4.05	13.0
Нейросетевые модели (с предобучением)							
DLinear	23.7	12.7	14.0	15.4	17.2	2.44	14.2
TimesNet	25.1	12.4	13.7	22.5	17.2	2.46	15.6
PatchTST	23.1	15.1	15.2	19.6	17.5	2.36	15.5
Autoformer	23.4	13.8	15.1	20.1	16.3	2.81	15.3
FEDformer	22.8	15.8	16.3	19.6	15.6	4.16	15.7

Главное: на M3 monthly и M4 daily предобученные нейросети уверенно точнее лучшей классики; на коротких рядах классика впереди.

Анализ отдельных рядов

Раздел 3. Преимущество нейросетей носит массовый характер



517

из 1000 ежедневных рядов
нейросеть точнее классики

295

рядов, где побеждают
3+ нейросетевых модели

Главное: нейросети выигрывают не точечно, а на большинстве длинных ежедневных рядов M4.

Итеративное прогнозирование

Раздел 3. Хрупкость обучаемой декомпозиции

- При накоплении ошибки сильнее всего деградируют модели с обучаемой декомпозицией.
- **FEDformer** и **TimesNet** теряют около +5 п.п. sMAPE при переходе к итеративному режиму.
- **PatchTST** (без явной декомпозиции) — наиболее устойчивый трансформер.
- **Классические модели** (ETS, Auto-ARIMA) практически нечувствительны к режиму.

Вывод: сложная обучаемая декомпозиция — это риск при многошаговом прогнозе. Простые и классические модели предпочтительнее, если нужен итеративный режим.

Выводы и практические рекомендации

Раздел 4. Основные результаты

- **Длина ряда решает.** Ниже ≈ 50 –100 наблюдений лидирует классика (ETS, Auto-ARIMA); выше — нейросети конкурентоспособны.
- **TimesNet — лучшая нейросеть** в per-series режиме; обучаемая 2D-декомпозиция эффективна при недостатке данных.
- **Предобучение кардинально усиливает нейросети** (+18...32 %) и выводит их на уровень и выше классики (M3 monthly, M4 daily).
- **Тип декомпозиции должен соответствовать режиму:** фиксированная — устойчивее, обучаемая — адаптивнее, но хрупка при итеративном прогнозе.
- **Ответ не бинарный:** эффективность нейросетевых механизмов зависит от длины ряда, режима обучения и объёма данных.

Спасибо за внимание!

Прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей

Лазарев А.К. · КМБО-03-22 · Научный руководитель Петрусевич Д.А.