

МИРЭА — Российский технологический университет

Институт искусственного интеллекта · Кафедра высшей математики

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей

Выполнил: студент группы КМБО-03-22 — Лазарев А.К.

Научный руководитель: к.ф.-м.н., доцент кафедры ВМ — Петрусевич Д.А.

Москва · 2026

Проблематика

- **Прикладная значимость.** Краткосрочный прогноз применяется в планировании спроса, трафика и ресурсов.
- **Отсутствие универсальной модели.** Статистические методы устойчивы на коротких рядах, нейросетевые — на длинных и сложных.
- **Открытый вопрос.** Оправдывают ли обучаемая декомпозиция и механизмы долгосрочных зависимостей свою сложность?

ЦЕЛЬ РАБОТЫ

Установить условия, при которых обучаемая декомпозиция временных рядов и нейросетевые механизмы учёта долгосрочных зависимостей обеспечивают практическое преимущество над классическими статистическими моделями, и определить области, где более простые методы остаются предпочтительными.

Раздел 1. Четыре эталонные модели сравнения


Seasonal Naive	Auto-ARIMA	ETS	Prophet
Прогноз воспроизводит значения предыдущего сезонного периода. Не имеет обучаемых параметров.	Линейная модель стационаризованного ряда: авторегрессия, интегрирование (разности) и скользящее среднее. Порядки (p, d, q) подбираются автоматически по информационному критерию.	Экспоненциальное сглаживание уровня, тренда и сезонности в пространстве состояний. Веса α , β , γ оцениваются по правдоподобию.	Аддитивная декомпозиция: кусочно-линейный тренд, сезонные гармоники и календарные эффекты с байесовской оценкой параметров.
Роль: эталон для метрики MASE и нижняя граница качества.	Сильная сторона: устойчивость на коротких рядах.	Сильная сторона: плавная динамика и сезонность.	Особенность: гибкая настройка сезонных компонент.

Вывод

Классические модели интерпретируемы и устойчивы при ограниченной истории наблюдений — это сильная база сравнения.

Раздел 1. Семь моделей: от линейных до гибридных

DLinear — линейная модель с декомпозицией



N-BEATS — обучаемое базисное разложение



TimesNet — 2D-моделирование периодов



Helformer — гибрид: Холт-Уинтерс + нейросеть



Семейства

- **Линейные:** DLinear
- **Базисные:** N-BEATS
- **Свёрточные:** TimesNet
- **Трансформеры:** Autoformer, FEDformer, PatchTST
- **Гибридные:** Helformer

ВЫВОД

Модели различаются способом выделения компонент ряда и механизмом учёта зависимостей — это и есть предмет сравнения.

Раздел 2. Данные, режимы, тип декомпозиции

Данные

- **M3 Competition.** Полный набор — 2829 рядов: 645 годовых, 756 квартальных, 1428 месячных.
- **M4 Competition.** 3000 рядов: 1000 квартальных, 1000 месячных, 1000 ежедневных.
- **Итого** 6 частотных категорий, 5829 рядов.
- **Метрики.** sMAPE, MASE, RMSE — для устойчивости выводов к выбору меры.

Три режима прогнозирования

- **Прямой.** Весь горизонт прогнозируется за один проход модели.
- **Итеративный.** Пошаговое продвижение с подстановкой собственных прогнозов; ошибка накапливается.
- **С предобучением.** Обучение на корпусе рядов с последующим дообучением на целевом ряде.


Тип декомпозиции

- **Фиксированная.** Правило задано заранее — ETS, DLinear, Helformer.
- **Обучаемая.** Компоненты выделяет сеть — Autoformer, FEDformer, TimesNet.
- **Без декомпозиции.** Прямое моделирование — Auto-ARIMA, PatchTST.

ВЫВОД

Сопоставление по трём осям — длина ряда, режим обучения и тип декомпозиции — формирует структуру анализа.

Раздел 3. Сравнительная позиция моделей по частотам



Наблюдения

- **Лидерство классики.** Auto-ARIMA, ETS, Seasonal Naive — верхние ранги на всех частотах.
- **Лучшая нейросеть.** TimesNet, средний ранг ≈ 4 .
- **Отставание трансформеров** в режиме обучения на одном ряде.


ВЫВОД

В режиме обучения на одном ряде классические модели сохраняют лидерство, однако разрыв убывает с ростом длины ряда.

Длина обучающей выборки как фактор

07 / 14

Раздел 3. Пороговая зависимость качества от длины ряда



Пороговый эффект ($\approx 50-100$ набл.)


- **Короткие ряды.** Уверенное преимущество классических моделей.
- **Длинные ряды M4 daily.** Нейросети конкурентоспособны.
- **TimesNet (3.62)** сопоставим с Auto-ARIMA (3.22) и ETS (3.46).

ВЫВОД

Существует пороговая длина обучающей выборки: ниже неё лидирует классика, выше — нейросетевые модели выходят на её уровень.

Предобучение: эффект переноса знаний

Раздел 3. Относительное улучшение по частотам и моделям



СРЕДНИЙ ВЫИГРЫШ sMAPE

+31.5 %

DLinear

+25.5 %

Autoformer


+18.2 %

Helformer

ВЫВОД

Предобучение на корпусе рядов выводит ранее слабые нейросетевые модели на конкурентоспособный уровень.

Раздел 3. Превосходство на среднечастотных и длинных рядах



Ключевые сопоставления

- **M3 monthly.** Предобученный TimesNet (13.68) точнее ETS (17.42).
- **M4 daily.** Предобученный PatchTST (2.36) точнее Auto-ARIMA (3.22) и ETS (3.46).
- **Прогнозы нейросетей** плотно следуют фактической траектории.

ВЫВОД

При достаточном объёме данных предобученные нейросетевые модели обеспечивают точность выше лучших классических моделей.

Сводное сравнение: sMAPE по категориям

Раздел 3. Предобученные нейросети и классические модели

Модель	M3-Y	M3-Q	M3-M	M4-Q	M4-M	M4-D	Ср.
Классические модели (per-series)							
Auto-ARIMA	17.9	10.9	18.1	10.2	14.7	3.22	12.5
ETS	19.1	10.8	17.4	9.7	15.1	3.46	12.6
Seasonal Naive	17.9	11.1	17.2	12.2	15.9	4.05	13.0
Нейросетевые модели (с предобучением)							
DLinear	23.7	12.7	14.0	15.4	17.2	2.44	14.2
TimesNet	25.1	12.4	13.7	22.5	17.2	2.46	15.6
PatchTST	23.1	15.1	15.2	19.6	17.5	2.36	15.5
Autoformer	23.4	13.8	15.1	20.1	16.3	2.81	15.3
FEDformer	22.8	15.8	16.3	19.6	15.6	4.16	15.7

ВЫВОД

На M3 monthly и M4 daily предобученные нейросети превосходят лучшую классику; на коротких рядах классика сохраняет преимущество.

Анализ отдельных временных рядов

11 / 14

Раздел 3. Массовый характер преимущества нейросетей



517

из 1000 ежедневных рядов M4 —
нейросеть точнее классики

295

рядов, где побеждают 3 и более
нейросетевых модели

ВЫВОД

Преимущество нейросетевых моделей на длинных рядах носит массовый, а не единичный характер.

Деградация при переходе от прямого режима к итеративному

- **Обучаемая декомпозиция уязвима.** FEDformer и TimesNet теряют около 5 п.п. sMAPE — выделенные компоненты искажаются на собственных прогнозах.
- **PatchTST устойчив.** Наименьшая деградация среди трансформеров: модель работает с патчами без явного разделения на компоненты.
- **Классические модели стабильны.** ETS и Auto-ARIMA практически нечувствительны к режиму — рекуррентная структура заложена в самой модели.
- **Закономерность.** Чем сложнее обучаемое разложение, тем сильнее накопление ошибки на горизонте.

СЛЕДСТВИЕ

Сложная обучаемая декомпозиция повышает риск накопления ошибки при многошаговом прогнозе. В задачах с итеративным прогнозированием простые и классические модели предпочтительнее.

Рекомендация: выбор модели должен учитывать не только точность, но и режим её применения.

ВЫВОД

Тип декомпозиции должен соответствовать режиму прогнозирования.

1

Длина обучающей выборки

Определяющий фактор. Ниже ≈ 50 –100 наблюдений предпочтительны ETS и Auto-ARIMA; выше — нейросети конкурентоспособны.

2

TimesNet — лучшая нейросеть

В режиме обучения на одном ряде; обучаемая 2D-декомпозиция эффективна при достаточном объёме данных.

3

Предобучение

Повышает качество нейросетей на 18–32 % и выводит их на уровень и выше классики на M3 monthly и M4 daily.

4

Тип декомпозиции и режим

Фиксированная декомпозиция устойчивее, обучаемая адаптивнее, но хрупка при итеративном прогнозировании.

5

Общий вывод

Эффективность нейросетевых механизмов не абсолютна — она определяется длиной ряда, режимом обучения и объёмом данных.

Спасибо за внимание

Прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей

Лазарев А.К. · КМБО-03-22 · Научный руководитель — Петрусевич Д.А.

Готов ответить на вопросы комиссии