

**МИРЭА — Российский технологический университет**

*Институт искусственного интеллекта*

**Текст выступления к защите выпускной квалификационной  
работы**

*Прогнозирование временных рядов за счёт обучаемой декомпозиции и  
нейросетевых механизмов учёта долгосрочных зависимостей*

Выполнил: студент группы КМБО-03-22 Лазарев А.К.

Научный руководитель: к.ф.-м.н., доцент кафедры ВМ Петрусевич Д.А.

**Регламент выступления (ориентировочно 8–9 минут)**

- Слайды 1–2 — тема, актуальность, цель (40 с).
- Слайды 3–5 — постановка, метрики, классика, смысл декомпозиции (1 мин 30 с).
- Слайды 6–8 — архитектуры нейросетей: DLinear, N-BEATS, TimesNet, Autoformer, Hefformer (2 мин).
- Слайд 9 — экспериментальная база и протокол (30 с).
- Слайды 10–11 — прямое прогнозирование и роль длины ряда (1 мин).
- Слайды 12–14 — предобучение и крупный прогноз (1 мин 30 с).
- Слайды 15–16 — сводная таблица и анализ рядов (50 с).
- Слайды 17–18 — итеративное прогнозирование (40 с).
- Слайды 19–20 — выводы и рекомендации (50 с).
- Слайды 21–22 — литература, заключение (15 с).
- Доп. 1–3 — экономическая часть: резервные слайды для вопросов.

*Совет: текст выучить и рассказывать энергично, держа контакт с комиссией; графики не зачитывать, а объяснять.*

## **Текст выступления по слайдам**

### **Слайд 1. Тема**

Уважаемые члены комиссии! Тема моей работы — прогнозирование временных рядов за счёт обучаемой декомпозиции и нейросетевых механизмов учёта долгосрочных зависимостей. Научный руководитель — Денис Андреевич Петрусеви́ч. Сразу обозначу главный вопрос работы: когда сложные нейросетевые модели действительно нужны, а когда выигрывает классика.

### **Слайд 2. Актуальность и цель**

Краткосрочный прогноз нужен везде — спрос, трафик, нагрузка, ресурсы. Проблема одна: универсальной модели не существует. На коротких рядах сильнее классика, на длинных и сложных — нейросети. Современные сети умеют сами раскладывать ряд на компоненты и ловить дальние зависимости, но это дорого и сложно.

Поэтому цель работы я ставлю честно: не доказать превосходство трансформеров, а установить условия, при которых обучаемая декомпозиция и механизмы дальних зависимостей реально окупаются — и где более простые методы остаются лучше.

### **Слайд 3. Постановка задачи и метрики**

Формально задача простая: дан ряд наблюдений, нужно предсказать его продолжение на горизонте  $H$ . Прогноз одномерный и краткосрочный, тестирование — строго вне обучающей выборки. Качество я измеряю тремя метриками: RMSE — абсолютная ошибка,

MASE — относительно наивного прогноза, и sMAPE — симметричная процентная ошибка, стандарт соревнований M3 и M4. Три метрики нужны, чтобы выводы не зависели от выбора одной меры.

#### **Слайд 4. Классические модели**

База сравнения — четыре классические модели. ARIMA описывает ряд через авторегрессию, разности и прошлые ошибки. ETS — это экспоненциальное сглаживание уровня, тренда и сезона. Prophet раскладывает ряд на тренд, сезон и календарь. И Seasonal Naive — простейший прогноз по прошлому сезону, наша нижняя планка. Все они интерпретируемы и очень устойчивы на коротких рядах — недооценивать их нельзя.

#### **Слайд 5. Смысл обучаемой и фиксированной декомпозиции**

Теперь ключевое различие, о котором спрашивала комиссия. Декомпозиция — это разложение ряда на простые части: тренд, сезон, остаток. Вопрос — кто задаёт правило разложения.

В фиксированной декомпозиции правило задаёт человек заранее: период сезонности, скользящее среднее, формулы Холта–Уинтерса. Это прозрачно и устойчиво. В обучаемой декомпозиции компоненты выделяет сама сеть в процессе обучения. Это гибче, но сложнее и легко переобучается. И вот смысл всей работы: обучаемость даёт свободу, но требует данных и вычислений. Я проверяю, когда эта свобода окупается, а когда надёжнее жёсткое правило.

#### **Слайд 6. Архитектуры нейросетей, часть первая**

Дальше — как устроены модели; объясню коротко и по сути. На схемах оранжевым выделен шаг декомпозиции.

DLinear — самый простой случай: ряд раскладывается скользящим средним на тренд и колебания, и каждую часть предсказывает отдельный линейный слой. Дёшево и на удивление сильно. N-BEATS идёт дальше: это стек блоков, и каждый блок объясняет часть истории и добавляет свой вклад в прогноз. Итог — сумма вкладов всех блоков. Разница принципиальная: DLinear раскладывает ряд фиксированно, а N-BEATS обучает само разложение.

### **Слайд 7. Архитектуры нейросетей, часть вторая**

TimesNet — красивая идея: через преобразование Фурье он находит главные периоды ряда и сворачивает одномерный ряд в двумерные «картинки». Тогда обычные свёртки видят и колебания внутри периода, и переходы между периодами.

Autoformer для моей темы — центральная модель. Он делает сразу две вещи: раскладывает ряд на тренд и сезон прямо внутри сети и заменяет обычное внимание на авто-корреляцию — то есть ищет похожие участки на больших лагах. Это ровно то, что вынесено в название работы: обучаемая декомпозиция плюс механизм дальних зависимостей в одной архитектуре.

### **Слайд 8. Helformer — основная гибридная модель**

Helformer — флагман работы. Сначала декомпозиция Холта–Уинтерса снимает тренд и сезон — это фиксированная, надёжная база. А дальше трансформер с блоком памяти моделирует остаток и дальнейшие зависимости через внимание. По сути Helformer объединяет обе исследуемые идеи в одной модели, поэтому он и вынесен в название работы — это прямой тест нашей гипотезы.

## **Слайд 9. Экспериментальная база и протокол**

Эксперимент крупный. Полный набор M3 — почти три тысячи рядов — и три тысячи рядов из M4; всего шесть частотных категорий и почти шесть тысяч рядов. Каждую модель я гоняю в трёх режимах: прямой прогноз, итеративный и с предобучением. И третья ось анализа — тип декомпозиции: фиксированная, обучаемая или её отсутствие. Эти три оси и держат всю структуру выводов.

## **Слайд 10. Прямое прогнозирование и что такое ранг**

Сначала отвечаю на вопрос комиссии, что такое ранг. На каждом отдельном ряде я выстраиваю модели по sMAPE: лучшая получает первое место, и так далее. Потом усредняю эти места по всем рядам категории — получается средний ранг модели. На карте зелёный — низкий ранг, то есть точнее; красный — хуже.

И картина однозначная: верхние строки — классика, Auto-ARIMA, ETS и Seasonal Naïve — зелёные во всех столбцах. Среди нейросетей зелёная только одна строка — TimesNet. Вывод честный: когда модель учится на одном ряде, классика лидирует везде, а из сетей держится только TimesNet.

## **Слайд 11. Длина обучающей выборки**

Почему так? Главная причина — длина ряда. На диаграмме — sMAPE на ежедневных рядах M4, самых длинных. Здесь картина переворачивается: TimesNet с результатом 3,6 уже на уровне Auto-ARIMA и ETS, а PatchTST, N-BEATS и Helformer идут плотной группой рядом. Prophet ожидаемо в стороне — он слаб на недельной

сезонности. Главный вывод слайда: есть порог длины, примерно 50–100 наблюдений. Ниже него правит классика, выше — сети догоняют.

### **Слайд 12. Предобучение**

А теперь самый важный результат работы — предобучение. Идея простая: сначала учим модель на большом корпусе рядов, а потом дообучаем на конкретном. На диаграмме — относительное улучшение sMAPE; почти всё положительное. В среднем плюс 31 процент у DLinear, плюс 25 у Autoformer, плюс 18 у Helformer. Предобучение буквально вытаскивает слабые модели на конкурентный уровень.

### **Слайд 13. Эффект предобучения на прогнозе**

Покажу это на одном ряде. Серая линия — история обучения, чёрная — факт, оранжевые — прогнозы Autoformer. И сразу отвечу на замечание с предзащиты: прогноз теперь начинается ровно от последней точки обучения, без разрыва — это видно по подписи на границе.

Пунктир — модель с нуля, ошибка 3,8 процента, она уходит вверх от факта. Сплошная линия — та же модель после предобучения, ошибка всего 1 процент, и она плотно повторяет факт. Один и тот же Autoformer — разница в три раза.

### **Слайд 14. Крупный прогноз**

Этот слайд — по просьбе комиссии, только прогнозы и крупно. Ежедневный ряд, все модели на одном горизонте. Чёрная жирная — факт. Сплошные линии — предобученные нейросети: PatchTST даёт 0,3 процента, FEDformer — 0,6, Helformer — 0,7. Пунктиром — классика: Auto-ARIMA и ETS по 1,3 процента. Видно невооружённым

глазом: сети идут прямо по факту, классика заметно выше. Все обозначения я продублировал текстом справа.

### **Слайд 15. Сводная таблица**

Сведём всё в таблицу sMAPE по шести категориям. Сверху — классика, снизу — предобученные сети. Смотрите не на отдельные числа, а на два выделенных столбца: месячные ряды M3 и ежедневные M4. Здесь предобученные сети уже точнее лучшей классики. Слева, на коротких рядах, классика по-прежнему впереди. То есть предобучение смещает баланс в пользу сетей, но только там, где хватает данных.

### **Слайд 16. Анализ отдельных рядов**

Важно показать, что это не один удачный ряд. На графике сети чётко повторяют динамику факта, классика отстаёт. А в цифрах: на 517 из тысячи ежедневных рядов хотя бы одна сеть точнее лучшей классики, и на 295 рядах выигрывают сразу три и более сетей. Преимущество массовое, а не случайное.

### **Слайд 17. Итеративное прогнозирование**

Теперь обратная сторона. В итеративном режиме модель кормит сама себя своими же прогнозами, и ошибка накапливается. Сильнее всех страдают модели с обучаемой декомпозицией — FEDformer и TimesNet теряют около пяти пунктов sMAPE: их компоненты искажаются на собственных прогнозах. PatchTST устойчив — он не делит ряд на компоненты. Классика почти нечувствительна. Вывод: тип декомпозиции должен соответствовать режиму.

### **Слайд 18. Масштаб деградации**

На диаграмме это в цифрах: синий столбец — прямой прогноз, оранжевый — итеративный. У классики столбцы одинаковые — деградации нет. У FEDformer, Autoformer и TimesNet оранжевый заметно выше — потеря от четырёх до шести пунктов. Чем сложнее обучаемое разложение, тем дороже обходится многошаговый режим.

### **Слайд 19. Выводы**

Собираю результаты. Первое: длина ряда — определяющий фактор; ниже порога правит классика, выше — сети конкурентоспособны. Второе: лучшая сеть при обучении на одном ряде — TimesNet. Третье, главное: предобучение даёт плюс 18–32 процента и выводит сети на уровень и выше классики на месячных M3 и ежедневных M4. Четвёртое: обучаемая декомпозиция гибче, но хрупка в итеративном режиме. Общий вывод: сила нейросетей не абсолютна — её определяют длина ряда, режим обучения и объём данных.

### **Слайд 20. Когда строить сложные модели**

И прямой ответ на вопрос, который наверняка прозвучит: когда вообще стоит браться за сложные модели. Если ряды короткие — берите классику, ETS или ARIMA, сети просто не успеют обучиться. Если ряды длинные и есть корпус похожих рядов — сложная сеть с предобучением окупается, это плюс 18–32 процента. Если прогноз итеративный — снова простые модели, сложная декомпозиция накопит ошибку. Короче: сложная модель оправдана при длинных рядах, доступном корпусе для предобучения и прямом режиме прогноза.

### **Слайд 21. Список литературы**



На слайде — ключевые источники. Полный список из 51 источника по ГОСТ приведён в тексте работы.

## **Слайд 22. Заключение**

На этом доклад завершён. Спасибо за внимание — готов ответить на вопросы.

## **Доп. 1–3. Экономическая часть (резервные слайды)**

Экономическая часть выполнена в рамках общего стартапа «ГМ-ПВР». Полная себестоимость разработки — 890 тысяч рублей, основные статьи — накладные расходы и зарплата. По бизнес-плану: чистая приведённая стоимость около 48 миллионов рублей, индекс рентабельности около 55, окупаемость — в пределах первого квартала, а в консервативном сценарии — к концу пятого месяца продаж. Экономия для клиента — порядка 815 тысяч рублей в месяц. Эти слайды держу как резервные на случай вопросов по экономике.