

Оглавление

Введение	4
Глава 1. Обзор подходов к прогнозированию временных рядов . . .	5
1.1 Временные ряды и задача прогнозирования	5
1.1.1 Основные определения	5
1.1.2 Постановка задачи прогнозирования	6
1.1.3 Метрики качества прогноза	7
1.2 Классические статистические модели	8
1.2.1 Модели ARIMA и SARIMA	8
1.2.2 Модели экспоненциального сглаживания (ETS)	10
1.2.3 Модель Prophet	11
1.3 Декомпозиция временных рядов	12
1.3.1 Фиксированная декомпозиция	12
1.3.2 Обучаемая декомпозиция	13
1.4 Нейросетевые модели для временных рядов	15
1.4.1 Механизм внимания и архитектура трансформера . . .	15
1.4.2 Autoformer	16
1.4.3 FEDformer	17
1.4.4 PatchTST	18
1.4.5 DLinear	19
1.4.6 N-BEATS	20
1.4.7 TimesNet	21
1.4.8 Helformer	22
1.4.9 Итоги сравнительного анализа моделей	23
1.5 Соревнования по прогнозированию временных рядов	26
1.6 Выводы по обзору и обоснование структуры эксперимента . .	27
Глава 2. Экспериментальное исследование	30
2.1 Постановка эксперимента	30
2.1.1 Данные	30
2.1.2 Модели и их конфигурация	31
2.1.3 Протокол оценки	32
2.2 Прямое сравнение моделей	32

2.2.1	Диагностика на синтетических рядах	32
2.2.2	Результаты на M3 Competition	35
2.2.3	Анализ по частотным категориям M3	39
2.2.4	Результаты на M4 Competition	42
2.2.5	Анализ по частотным категориям M4	45
2.2.6	Кросс-датасетный анализ	47
2.3	Итеративное прогнозирование	53
2.4	Предобучение трансформерных моделей	56
2.4.1	Детальные результаты предобучения по частотам . . .	57
2.4.2	Прогнозы предобученных моделей на конкретных рядах	64
2.4.3	Предобученные нейросети vs классические модели . .	67
2.5	Анализ отдельных рядов	72
2.5.1	Ежедневные ряды: нейросети vs классика	72
2.6	Выводы	76
Заключение		78
Список литературы		81

Введение

Прогнозирование временных рядов является одной из центральных задач в анализе данных, финансовой аналитике, управлении запасами и планировании ресурсов. Классические статистические модели (ARIMA, ETS, Prophet) на протяжении десятилетий оставались стандартом для краткосрочного прогноза. В последние годы были предложены нейросетевые архитектуры, явно включающие механизмы обучаемой декомпозиции рядов на компоненты (тренд, сезонность, остаток) и модули учёта долгосрочных зависимостей на основе внимания, свёрток и линейных проекций.

Настоящая работа посвящена исследованию условий, при которых обучаемая декомпозиция и нейросетевые механизмы учёта долгосрочных зависимостей дают практическое преимущество по сравнению с фиксированными статистическими подходами, и ситуаций, в которых более простые методы оказываются предпочтительнее. В качестве экспериментальной базы используются данные соревнований M3 и M4, а в качестве моделей - ARIMA, ETS, Prophet, N-BEATS, DLinear, Autoformer, TimesNet и Helformer.

Глава 1. Обзор подходов к прогнозированию временных рядов

1.1. Временные ряды и задача прогнозирования

1.1.1. Основные определения

Временным рядом называют упорядоченную последовательность наблюдений $\{y_t\}_{t=1}^T$, где каждому значению y_t поставлен в соответствие момент времени t , а наблюдения следуют через равные или нерегулярные промежутки [1]. В большинстве практических задач прогнозирования рассматриваются равноотстоящие ряды: ежемесячные, ежеквартальные, ежегодные наблюдения макроэкономических, финансовых или промышленных показателей. Каждый элемент ряда может быть вещественным числом (одномерный ряд) или вектором (многомерный, или многоканальный ряд); в данной работе основное внимание уделяется одномерному случаю, поскольку именно он является стандартным объектом соревнований M3 и M4 [2, 3].

Свойством, определяющим пригодность ряда к статистическому моделированию, является стационарность. Временной ряд называют *строго стационарным*, если совместное распределение любого конечного набора $\{y_{t_1}, y_{t_2}, \dots, y_{t_k}\}$ не изменяется при сдвиге всех индексов на величину τ . На практике чаще используется более слабое условие: ряд считается *слабо стационарным* (стационарным в широком смысле), если его математическое ожидание $\mu = \mathbb{E}[y_t]$ постоянно, дисперсия $\sigma^2 = \text{Var}(y_t)$ конечна и не зависит от t , а автоковариационная функция зависит только от лага:

$$\gamma(h) = \text{Cov}(y_t, y_{t+h}) = \mathbb{E}[(y_t - \mu)(y_{t+h} - \mu)]. \quad (1)$$

Нормируя $\gamma(h)$ на $\gamma(0) = \sigma^2$, получают *автокорреляционную функцию* (АКФ) $\rho(h) = \gamma(h)/\gamma(0)$, играющую центральную роль при подборе порядков моделей класса ARIMA [4].

Реальные экономические и промышленные ряды почти всегда нестационарны: они содержат тренд, сезонную составляющую и гетероскедастичность. Одним из стандартных средств приведения к стационарности служит

оператор разности:

$$\Delta y_t = y_t - y_{t-1}, \quad \Delta^d y_t = \Delta^{d-1}(\Delta y_t). \quad (2)$$

Для устранения сезонности с периодом s вводят сезонный разностный оператор $\Delta_s y_t = y_t - y_{t-s}$. Как показано в [4], сочетание обычного и сезонного дифференцирования позволяет привести широкий класс рядов к виду, пригодному для построения линейных стационарных моделей. Формальное обоснование разложения нестационарных процессов на постоянную и транзиторную компоненты дано в работе Бевериджа и Нельсона [5], а представление стационарного процесса как бесконечной скользящей средней — в теореме Вольда [6].

1.1.2. Постановка задачи прогнозирования

Задачу точечного прогнозирования временного ряда можно сформулировать следующим образом. Пусть дана история наблюдений $\mathbf{y}_{1:L} = (y_1, y_2, \dots, y_L)$, где L — длина входного окна. Требуется построить отображение

$$f_\theta: \mathbb{R}^L \rightarrow \mathbb{R}^H, \quad \hat{\mathbf{y}}_{L+1:L+H} = f_\theta(\mathbf{y}_{1:L}), \quad (3)$$

минимизирующее некоторую функцию потерь между прогнозом $\hat{\mathbf{y}}_{L+1:L+H}$ и реальными будущими значениями $\mathbf{y}_{L+1:L+H}$, где H — горизонт прогноза, а θ — параметры модели [7].

Для оценки качества используют схему фиксированного разделения: последние H точек ряда отделяются в тестовую выборку, а предшествующие L точек (или весь доступный до них отрезок) составляют обучающую часть. В соревнованиях М3 [2] и М4 [3] горизонт прогнозирования варьируется в зависимости от частоты наблюдений: $H = 6$ для годовых рядов, $H = 8$ для квартальных и $H = 18$ для месячных. Такая стандартизация позволяет сопоставлять различные методы в единых условиях.

В статистических моделях параметры θ оцениваются методом максимального правдоподобия или моментами, а в нейросетевых — методом стохастической градиентной оптимизации. Различие в парадигмах оценки параметров оказывает существенное влияние на поведение моделей при ограниченном объёме данных и является одной из центральных тем данной работы.

1.1.3. Метрики качества прогноза

Для сравнения прогнозных моделей применяют ряд метрик, каждая из которых имеет свои достоинства и ограничения.

Средняя абсолютная ошибка (MAE):

$$\text{MAE} = \frac{1}{H} \sum_{t=1}^H |y_t - \hat{y}_t|. \quad (4)$$

MAE выражена в единицах исходного ряда, что затрудняет сравнение рядов различного масштаба.

Среднеквадратическая ошибка (MSE) и её квадратный корень (RMSE):

$$\text{MSE} = \frac{1}{H} \sum_{t=1}^H (y_t - \hat{y}_t)^2, \quad \text{RMSE} = \sqrt{\text{MSE}}. \quad (5)$$

MSE штрафует большие отклонения сильнее, чем MAE, и широко используется как функция потерь при обучении нейронных сетей [8].

Средняя абсолютная процентная ошибка (MAPE):

$$\text{MAPE} = \frac{100\%}{H} \sum_{t=1}^H \frac{|y_t - \hat{y}_t|}{|y_t|}. \quad (6)$$

MAPE масштабно-инвариантна, однако не определена при $y_t = 0$ и асимметрична: одинаковые по абсолютной величине перепрогноз и недопрогноз дают разные процентные значения.

Симметричная MAPE (sMAPE):

$$\text{sMAPE} = \frac{200\%}{H} \sum_{t=1}^H \frac{|y_t - \hat{y}_t|}{|y_t| + |\hat{y}_t|}. \quad (7)$$

sMAPE была выбрана в качестве основной метрики соревнования M3 [2] благодаря симметрии относительно знака ошибки и ограниченности сверху величиной 200%. Тем не менее sMAPE критиковалась за смещённость к прогнозам, занижающим значения [9].

Средняя абсолютная масштабированная ошибка (MASE):

$$\text{MASE} = \frac{1}{H} \sum_{t=1}^H \frac{|y_t - \hat{y}_t|}{\frac{1}{T-m} \sum_{j=m+1}^T |y_j - y_{j-m}|}, \quad (8)$$

где T — длина обучающей части, а m — период сезонности (для несезонных рядов $m = 1$). MASE была предложена Хиндманом и Кёлером [9] как масштабно-инвариантная альтернатива MAPE и sMAPE. Её знаменатель представляет собой среднюю абсолютную ошибку наивного сезонного прогноза, вычисленную на обучающих данных. Значение $\text{MASE} < 1$ означает, что модель прогнозирует лучше наивного метода. В данной работе MASE и sMAPE используются совместно для обеспечения сопоставимости с результатами М3 и М4.

1.2. Классические статистические модели

1.2.1. Модели ARIMA и SARIMA

Семейство моделей ARIMA является, по-видимому, наиболее широко используемым классом линейных моделей временных рядов [4]. Построение модели осуществляется в рамках методологии Бокса–Дженкинса, включающей три этапа: идентификацию порядков, оценку параметров и диагностику остатков.

Процесс авторегрессии порядка p , обозначаемый $\text{AR}(p)$, определяется рекуррентным соотношением

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \quad (9)$$

где c — константа, $\phi_1, \dots, \phi_p$ — авторегрессионные коэффициенты, а ε_t — белый шум с нулевым средним и конечной дисперсией σ^2 . Для стационарности процесса необходимо и достаточно, чтобы все корни характеристического полинома $\Phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p$ лежали вне единичного круга [1].

Процесс скользящего среднего порядка q , $\text{MA}(q)$, задаётся формулой

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}, \quad (10)$$

где $\theta_1, \dots, \theta_q$ — параметры скользящего среднего. Условие обратимости аналогично: корни полинома $\Theta(z) = 1 + \theta_1 z + \dots + \theta_q z^q$ должны лежать вне единичного круга.

Объединяя оба процесса, получают модель $\text{ARMA}(p, q)$, а применяя к исходному ряду оператор разности порядка d , получают модель $\text{ARIMA}(p, d, q)$. В операторной записи:

$$\Phi(B)(1 - B)^d y_t = c + \Theta(B) \varepsilon_t, \quad (11)$$

где B — оператор обратного сдвига, $B y_t = y_{t-1}$.

Для рядов с выраженной сезонностью периода s применяют обобщение — модель $\text{SARIMA}(p, d, q)(P, D, Q)_s$:

$$\Phi_p(B) \tilde{\Phi}_P(B^s) (1 - B)^d (1 - B^s)^D y_t = c + \Theta_q(B) \tilde{\Theta}_Q(B^s) \varepsilon_t, \quad (12)$$

где $\tilde{\Phi}_P$ и $\tilde{\Theta}_Q$ — полиномы сезонных авторегрессионного и скользящего среднего компонентов соответственно [4].

Традиционно подбор порядков (p, d, q) осуществляется путём анализа автокорреляционной (АКФ) и частной автокорреляционной (ЧАКФ) функций, однако для массового прогнозирования сотен и тысяч рядов, как в соревнованиях M3 и M4, ручной подбор непрактичен. Автоматический алгоритм `auto_arima`, реализованный в пакете `forecast` для R и в библиотеке `pydarima` для Python, осуществляет последовательный перебор моделей с минимизацией информационного критерия AICc [10]. Этот подход используется в данной работе в качестве одного из классических базовых методов.

Результаты соревнований M3 [2] и M4 [3] убедительно продемонстрировали, что ARIMA-модели, особенно в автоматизированном варианте, остаются конкурентоспособными для широкого класса рядов. В M3 автоматическая ARIMA уступила методам экспоненциального сглаживания лишь на доли процента по sMAPE, а в M4 вошла в группу сильнейших статистических методов. Это объясняется тем, что ARIMA хорошо описывает локальную линейную динамику и сезонную структуру, тогда как при коротких рядах и умеренном горизонте преимущество более сложных моделей нивелируется дисперсией оценок.

1.2.2. Модели экспоненциального сглаживания (ETS)

Метод экспоненциального сглаживания был впервые описан Холтом в 1957 году [11] для рядов с линейным трендом и распространён Уинтерсом [12] на случай сезонности. В простейшей форме (*простое экспоненциальное сглаживание*, SES) прогноз строится по рекуррентному правилу:

$$\hat{y}_{t+1|t} = \ell_t, \quad \ell_t = \alpha y_t + (1 - \alpha) \ell_{t-1}, \quad 0 < \alpha < 1, \quad (13)$$

где ℓ_t — уровень ряда, а α — параметр сглаживания.

Метод Холта добавляет компоненту линейного тренда:

$$\begin{aligned} \ell_t &= \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1}), \\ b_t &= \beta (\ell_t - \ell_{t-1}) + (1 - \beta) b_{t-1}, \\ \hat{y}_{t+h|t} &= \ell_t + h b_t, \end{aligned} \quad (14)$$

где b_t — оценка наклона тренда, β — параметр сглаживания тренда.

Метод Холта–Уинтерса расширяет модель сезонной компонентой s_t с периодом m :

$$\begin{aligned} \ell_t &= \alpha (y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1}), \\ b_t &= \beta (\ell_t - \ell_{t-1}) + (1 - \beta) b_{t-1}, \\ s_t &= \gamma (y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma) s_{t-m}, \\ \hat{y}_{t+h|t} &= \ell_t + h b_t + s_{t+h-m}, \end{aligned} \quad (15)$$

где формулы (15) соответствуют аддитивной сезонности. Мультипликативный вариант заменяет вычитание делением и сложение умножением. Хиндман и др. [13] систематизировали все 30 возможных конфигураций экспоненциального сглаживания в рамках единой *модели пространства состояний*, введя обозначение ETS(ошибка, тренд, сезонность). Здесь каждая компонента принимает одно из значений: аддитивная (A), мультипликативная (M) или отсутствует (N), а тренд дополнительно может быть демпфированным (A_d , M_d). Это позволяет автоматически выбирать оптимальную модель из всех конфигураций по информационному критерию [10].

Принципиальное отличие ETS от ARIMA состоит в том, что ETS *явно*

разделяет ряд на компоненты уровня, тренда и сезонности ещё на этапе спецификации модели. Это делает ETS формой *фиксированной декомпозиции*: структура компонент (аддитивная или мультипликативная) задаётся до обучения, а не выучивается из данных. Позднее де Ливера и др. [14] расширили ETS до модели TBATS, способной работать с множественными сезонностями и преобразованием Бокса–Кокса, однако базовый принцип фиксированной декомпозиции сохранился.

Конкурентоспособность ETS убедительно подтверждена результатами соревнований. В M3 [2] модель Холта–Уинтерса с демпфированным трендом показала наилучшую среднюю sMAPE среди всех участников. В M4 [3] чистые статистические методы — ETS и ARIMA — оставались в числе лучших индивидуальных подходов, а победитель (ES-RNN) [15] объединил экспоненциальное сглаживание с рекуррентной сетью, что лишь подтвердило важность ETS-компоненты. Этот факт задаёт высокую планку для любых нейросетевых архитектур, претендующих на улучшение прогноза.

1.2.3. Модель Prophet

Модель Prophet, разработанная Тейлором и Летамом [16], представляет ряд как аддитивную комбинацию трёх компонент:

$$y_t = g(t) + s(t) + h(t) + \varepsilon_t, \quad (16)$$

где $g(t)$ — трендовая составляющая, $s(t)$ — сезонность, $h(t)$ — эффект внешних событий (праздников), а ε_t — ошибка модели.

Тренд моделируется как кусочно-линейная функция с автоматически определяемыми точками перелома:

$$g(t) = (k + \mathbf{a}(t)^\top \boldsymbol{\delta}) t + (m + \mathbf{a}(t)^\top \boldsymbol{\gamma}), \quad (17)$$

где k — базовый наклон, $\boldsymbol{\delta}$ — вектор поправок наклона в точках перелома, $\mathbf{a}(t)$ — вектор-индикатор принадлежности t к интервалам, а $\boldsymbol{\gamma}$ — поправки смещения для обеспечения непрерывности. Для рядов с насыщением (например, ёмкость рынка) предусмотрен логистический вариант тренда.

Сезонность представлена рядом Фурье:

$$s(t) = \sum_{n=1}^N \left(a_n \cos \frac{2\pi nt}{P} + b_n \sin \frac{2\pi nt}{P} \right), \quad (18)$$

где P — период (например, 365.25 для годовой сезонности), а N — число гармоник, контролирующих гладкость. Параметры a_n, b_n оцениваются совместно с трендом.

Prophet привлекателен простотой использования и устойчивостью к пропускам данных. Тем не менее в соревновательном контексте модель показывает умеренные результаты: на данных M4 Prophet заметно уступил лучшим методам [3]. С точки зрения декомпозиции Prophet занимает промежуточное положение: тренд и сезонность разделяются аддитивно (как в ETS), но параметры тренда (точки перелома) и сезонности (коэффициенты Фурье) оцениваются из данных. При этом сама структура декомпозиции — аддитивная сумма кусочно-линейного тренда и ряда Фурье — задаётся заранее и не адаптируется в процессе обучения.

1.3. Декомпозиция временных рядов

1.3.1. Фиксированная декомпозиция

Идея разложения временного ряда на компоненты — тренд, сезонность и остаток — является одной из старейших в анализе временных рядов [17]. Формально аддитивная декомпозиция записывается как

$$y_t = T_t + S_t + R_t, \quad (19)$$

где T_t — трендовая компонента, S_t — сезонная и R_t — остаточная. Мультипликативный вариант заменяет сложение умножением: $y_t = T_t \cdot S_t \cdot R_t$.

Наиболее распространённым методом фиксированной декомпозиции является процедура STL, предложенная Кливлендом и др. [18]. STL последовательно извлекает сезонную компоненту с помощью локальной регрессии (loess), оценивает тренд аналогичным образом и формирует остаток как разность. Процедура итеративно уточняет оценки, используя робастные веса для подавления выбросов. Параметры STL — ширина окна для сезонного

сглаживания, ширина окна для тренда и число итераций — задаются пользователем, но не обучаются из данных.

Метод Холта–Уинтерса (раздел 1.2.2) также может рассматриваться как форма неявной декомпозиции: рекуррентные уравнения для ℓ_t , b_t и s_t фактически разделяют ряд на уровень, тренд и сезонность. Однако тип взаимодействия компонент (аддитивный или мультипликативный) фиксируется при спецификации модели.

Ещё один класс фиксированных базисных функций представляют вейвлет-преобразования. В частности, максимально перекрывающееся дискретное вейвлет-преобразование (MODWT) [19] раскладывает ряд по набору масштабов, каждый из которых соответствует определённому диапазону частот. Вейвлет-коэффициенты различных уровней могут использоваться как входные признаки для прогнозной модели [20]. Однако базисные функции (вейвлеты Хаара, Добеши и др.) выбираются заранее и не адаптируются к конкретному ряду.

Общим свойством всех перечисленных методов является *фиксированная структура базисных функций*: скользящее среднее в STL, экспоненциальное взвешивание в ETS, конкретное семейство вейвлетов. Преимущество такого подхода — интерпретируемость и устойчивость при малом объёме данных. Недостаток — невозможность адаптировать базис к специфическим паттернам конкретного ряда.

1.3.2. Обучаемая декомпозиция

Переход от фиксированной к *обучаемой* декомпозиции составляет центральную тему настоящей работы. Под обучаемой декомпозицией понимается подход, в котором способ разделения ряда на компоненты определяется не заранее заданными правилами, а параметрами, оптимизируемыми в процессе обучения модели.

Простейшим примером служит модель DLinear [21], в которой декомпозиция осуществляется через скользящее среднее с ядром фиксированного размера k :

$$T_t = \frac{1}{k} \sum_{i=-(k-1)/2}^{(k-1)/2} y_{t+i}, \quad S_t = y_t - T_t. \quad (20)$$

Хотя само ядро скользящего среднего не содержит обучаемых параметров,

два отдельных линейных слоя, применяемых к T_t и S_t , фактически учатся проецировать каждую компоненту в прогноз. Тем самым модель определяет, какой вклад вносят тренд и сезонность, на основе данных.

Более развитый подход реализован в архитектуре N-BEATS [22], где каждый блок порождает *обучаемое базисное разложение*. В интерпретируемой конфигурации трендовый блок использует полиномиальный базис, а сезонный — гармонический, но коэффициенты этих базисов вычисляются полносвязной сетью на основе входных данных. Таким образом, модель адаптирует форму трендовой и сезонной компонент к конкретному ряду.

Архитектура Autoformer [23] вводит *прогрессивную декомпозицию*: на каждом уровне кодировщика и декодировщика применяется блок скользящего среднего, разделяющий промежуточное представление на трендовую и сезонную части. Декомпозиция повторяется на каждом слое, позволяя модели итеративно уточнять разделение.

FEDformer [24] переносит декомпозицию в частотную область: блоки внимания работают с подмножеством частот Фурье или вейвлет-коэффициентов, отбирая наиболее значимые моды. Выбор частотных компонент осуществляется обучаемо, что позволяет сети сосредоточиться на доминирующих периодичностях.

TimesNet [25] реализует неявную декомпозицию через преобразование одномерного ряда в набор двумерных представлений, соответствующих различным периодам. Доминирующие периоды определяются с помощью быстрого преобразования Фурье (БПФ), после чего для каждого периода ряд перестраивается в двумерный тензор и обрабатывается свёрточными блоками. Такой подход позволяет извлекать признаки на нескольких масштабах одновременно.

Таким образом, в современных нейросетевых архитектурах для временных рядов прослеживается общая тенденция: декомпозиция перестаёт быть предобработкой с фиксированным базисом и становится обучаемым компонентом модели. Однако открытым остаётся вопрос, *в каких условиях* обучаемая декомпозиция действительно даёт преимущество по сравнению с фиксированной, а в каких — приводит к переобучению или избыточной сложности, особенно при ограниченном объёме данных, характерном для индивидуального прогнозирования отдельных рядов.

1.4. Нейросетевые модели для временных рядов

1.4.1. Механизм внимания и архитектура трансформера

Архитектура Transformer, предложенная Васвани и др. [26], произвела революцию в обработке последовательностей. В основе архитектуры лежит механизм *масштабированного скалярного внимания*:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V, \quad (21)$$

где $Q \in \mathbb{R}^{n \times d_k}$ — матрица запросов, $K \in \mathbb{R}^{m \times d_k}$ — матрица ключей, $V \in \mathbb{R}^{m \times d_v}$ — матрица значений, а d_k — размерность ключей. Деление на $\sqrt{d_k}$ предотвращает попадание аргументов softmax в область насыщения.

Для повышения выразительности используют *многоголовое внимание*:

$$\begin{aligned} \text{MultiHead}(Q, K, V) &= \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O, \\ \text{head}_i &= \text{Attention}(QW_i^Q, KW_i^K, VW_i^V), \end{aligned} \quad (22)$$

где $W_i^Q, W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ и $W^O \in \mathbb{R}^{hd_v \times d_{\text{model}}}$ — обучаемые проекционные матрицы. Каждая «голова» вычисляет внимание в собственном подпространстве, что позволяет одновременно улавливать зависимости различной природы [26].

Полный блок трансформера включает многоголовое внимание, позиционно-чувствительную полносвязную сеть, остаточные соединения [27] и нормализацию слоя [28]. Исходный Transformer использует позиционное кодирование на основе синусоид для учёта порядка элементов.

Применение трансформеров к временным рядам мотивировано их способностью явно моделировать зависимости между произвольно удалёнными отсчётами. В отличие от рекуррентных сетей (LSTM [29], GRU), где информация передаётся последовательно через скрытые состояния и может «затухать» на длинных последовательностях, механизм внимания устанавливает прямые связи между любыми позициями входа. Следует отметить, что ещё до широкого распространения трансформеров в задачах прогнозирования важную роль сыграли рекуррентные модели вероятностного прогнозирования, в частности DeepAR [30], генерирующая не точечные прогнозы, а па-

параметры условного распределения будущих значений на каждом шаге авто-регрессии.

Однако стандартный механизм внимания имеет вычислительную сложность $O(n^2)$ по длине последовательности, что делает его дорогим для длинных рядов. Для решения этой проблемы были предложены архитектуры с разреженным вниманием. Informer [31] использует механизм ProbSparse attention, выбирающий наиболее информативные запросы по оценке KL-дивергенции и снижающий сложность до $O(n \log n)$. LogTrans [32] применяет разреженное внимание с логарифмическим шаблоном разреженности, позволяя каждому элементу обращаться лишь к экспоненциально удалённым предшественникам. Лю и др. [33] предложили Non-stationary Transformers, в которых механизм нормализации адаптируется к изменяющимся статистическим свойствам ряда, что позволяет учитывать нестационарность непосредственно внутри архитектуры. Эти работы заложили основу для семейства трансформерных архитектур, адаптированных к задачам прогнозирования временных рядов. Отдельно следует выделить архитектуру Temporal Fusion Transformer [34], которая сочетает механизм внимания с рекуррентными компонентами и механизмом отбора переменных, обеспечивая интерпретируемость прогнозов в многомерном случае.

Важно подчеркнуть, что успешность трансформеров в обработке естественного языка не гарантирует аналогичных результатов для временных рядов. В обзоре Вэнь и др. [35] отмечается, что временные ряды, в отличие от текстов, не обладают разреженной семантической структурой, и преимущество глобального внимания может нивелироваться более высоким уровнем шума. Несколько обзорных работ систематизируют развитие нейросетевых подходов к прогнозированию временных рядов [36, 37, 38, 35, 39], охватывая как рекуррентные, так и трансформерные архитектуры и позволяя проследить эволюцию от ранних полносвязных моделей к современным методам с обучаемой декомпозицией.

1.4.2. Autoformer

Архитектура Autoformer [23] была предложена для прогнозирования длинных временных рядов и отличается от стандартного трансформера в двух аспектах: использованием прогрессивной декомпозиции и заменой

стандартного механизма внимания на механизм автокорреляции.

Прогрессивная декомпозиция встраивается в каждый уровень кодировщика и декодировщика в виде блока $\text{SeriesDecomp}(\cdot)$, реализующего скользящее среднее с ядром размера k :

$$\mathbf{x}_{\text{trend}} = \text{AvgPool}(\text{Pad}(\mathbf{x}), k), \quad \mathbf{x}_{\text{season}} = \mathbf{x} - \mathbf{x}_{\text{trend}}. \quad (23)$$

На каждом слое промежуточное представление повторно разделяется на тренд и сезонность, что позволяет итеративно уточнять декомпозицию по мере прохождения данных через сеть.

Механизм *автокорреляции* заменяет скалярное произведение $QK^\top$ вычислением автокорреляций на основе быстрого преобразования Фурье (БПФ):

$$R_{Q,K}(\tau) = \mathcal{F}^{-1}(\mathcal{F}(Q) \cdot \overline{\mathcal{F}(K)}), \quad (24)$$

где $\mathcal{F}$ — дискретное преобразование Фурье, $\overline{(\cdot)}$ — комплексное сопряжение, а $R_{Q,K}(\tau)$ — автокорреляция по лагу τ . Модель выбирает k лагов с максимальной автокорреляцией и агрегирует соответствующие сдвинутые версии V , что позволяет выявлять периодические зависимости эффективнее стандартного внимания.

Авторы [23] показали, что Autoformer превосходит Informer и ряд других базовых линий на стандартных наборах (ETTh, ETTm, Weather), однако, как будет показано далее, при обучении на коротких индивидуальных рядах из M3 преимущество Autoformer не столь однозначно.

1.4.3. FEDformer

FEDformer [24] развивает идеи Autoformer, перенося механизм внимания в частотную область. Ключевой элемент архитектуры — блок *Frequency Enhanced Attention* (FEA), в котором вместо попарного сравнения временных позиций используется случайно выбранное подмножество из s частот Фурье. Вычисления производятся следующим образом.

Входной сигнал $\mathbf{x} \in \mathbb{R}^{L \times d}$ преобразуется в частотную область: $\mathbf{X} = \mathcal{F}(\mathbf{x}) \in \mathbb{C}^{L \times d}$. Из L частотных мод случайным образом выбирается подмножество размера $s \ll L$. Для выбранных мод выполняется поэлементное произведение запросов и ключей в частотной области, результат дополняется ну-

лями до полного спектра и преобразуется обратно:

$$\hat{\mathbf{y}} = \mathcal{F}^{-1}(\sigma(\mathbf{Q}_s \odot \mathbf{K}_s) \cdot \mathbf{V}_s), \quad (25)$$

где $\mathbf{Q}_s, \mathbf{K}_s, \mathbf{V}_s$ — спектральные представления запросов, ключей и значений на выбранных модах, σ — функция активации, $\odot$ — поэлементное произведение. Благодаря работе с подмножеством из s частот сложность FEA составляет $O(L)$ вместо $O(L^2)$ для стандартного внимания.

Наряду с вариантом Фурье авторы предлагают вейвлетную версию — *Wavelet Enhanced Attention* (WEA), в которой вместо частот Фурье используются вейвлет-коэффициенты. Оба варианта дополнены блоком прогрессивной декомпозиции, аналогичным Autoformer.

С точки зрения обучаемой декомпозиции FEDformer принципиально отличается от Autoformer тем, что декомпозиция частично выполняется в частотной области: модель не только разделяет тренд и сезонность, но и учится отбирать наиболее информативные спектральные компоненты. Это сближает FEDformer с вейвлетными методами [19], но с тем отличием, что выбор мод является обучаемым.

1.4.4. PatchTST

Архитектура PatchTST [40] предлагает иной подход к адаптации трансформера для временных рядов, отказываясь от явной декомпозиции в пользу двух конструктивных идей: *патчирования* и *независимости каналов*.

Патчирование заключается в разбиении входного ряда длины L на непересекающиеся или перекрывающиеся сегменты (патчи) фиксированной длины P :

$$\mathbf{p}_i = (y_{(i-1)S+1}, y_{(i-1)S+2}, \dots, y_{(i-1)S+P}), \quad i = 1, \dots, N, \quad (26)$$

где S — шаг, а $N = \lfloor (L - P) / S \rfloor + 1$ — число патчей. Каждый патч проецируется в d -мерное пространство линейным слоем и подаётся на вход стандартного блока трансформера.

Преимущества патчирования многообразны. Во-первых, число токенов сокращается с L до $N \ll L$, что квадратично уменьшает стоимость механизма внимания. Во-вторых, каждый патч агрегирует локальную информа-

цию, подобно свёрточному ядру, что снижает чувствительность к шуму. В-третьих, механизм внимания между патчами моделирует зависимости между *семантическими фрагментами* ряда, а не между отдельными отсчётами.

Принцип *независимости каналов* означает, что в многомерном случае каждый канал (переменная) обрабатывается отдельным экземпляром модели, без межканального внимания. Авторы [40] показали, что такая архитектура, несмотря на свою простоту, превосходит более сложные многоканальные модели на ряде стандартных наборов данных.

С точки зрения данной работы PatchTST представляет особый интерес как *контрольная архитектура без встроенной декомпозиции*: модель использует стандартный блок трансформера и не разделяет ряд на тренд и сезонность. Это позволяет оценить, какой вклад в качество прогноза вносит именно декомпозиция, а какой — сам механизм внимания.

1.4.5. DLinear

Модель DLinear [21] была предложена в контексте провокационного вопроса: действительно ли трансформерные архитектуры необходимы для прогнозирования временных рядов? Авторы показали, что простая комбинация декомпозиции скользящим средним и двух линейных проекций может конкурировать с Autoformer, FEDformer и Informer на стандартных наборах данных.

Архитектура DLinear состоит из трёх элементов:

1. Декомпозиция скользящим средним с ядром размера k , разделяющая вход на трендовую и сезонную части (формула (20)).
2. Линейный слой $W_T \in \mathbb{R}^{H \times L}$, проецирующий трендовую компоненту из L входных точек в H прогнозных.
3. Линейный слой $W_S \in \mathbb{R}^{H \times L}$ для сезонной компоненты.

Итоговый прогноз формируется как

$$\hat{\mathbf{y}} = W_T \mathbf{x}_{\text{trend}} + W_S \mathbf{x}_{\text{season}}. \quad (27)$$

Общее число параметров модели составляет $2LH$, что на несколько порядков меньше, чем у трансформерных архитектур.

Результаты DLinear поставили под сомнение безусловное превосходство сложных архитектур с механизмом внимания. Вместе с тем критики от-

мечают [35], что сравнение проводилось на специфических наборах (ETT, Weather, Electricity) с относительно короткими горизонтами, и выводы не обязательно переносятся на другие задачи.

Для настоящей работы DLinear выполняет двойную роль: с одной стороны, это пример простейшей обучаемой декомпозиции (линейные проекции после разделения скользящим средним); с другой стороны, это критическая базовая линия, по которой измеряется оправданность усложнения модели.

1.4.6. N-BEATS

N-BEATS [22] представляет собой архитектуру глубокой сети, построенную на принципе *обучаемого базисного разложения*. Модель состоит из нескольких стеков, каждый из которых содержит B блоков. Каждый блок принимает на вход вектор-окно $\mathbf{x} \in \mathbb{R}^L$ и порождает два выхода: *обратный прогноз* $\hat{\mathbf{x}} \in \mathbb{R}^L$ и *прямой прогноз* $\hat{\mathbf{y}} \in \mathbb{R}^H$. Остаток $\mathbf{x} - \hat{\mathbf{x}}$ передаётся следующему блоку — это механизм *двойного остаточного стекирования*, вдохновлённый остаточными соединениями [27].

Внутри каждого блока вектор $\mathbf{x}$ обрабатывается полносвязной сетью (4 слоя с активацией ReLU), порождающей вектор коэффициентов $\boldsymbol{\theta} \in \mathbb{R}^K$. Затем обратный прогноз и прямой прогноз формируются как линейные комбинации базисных векторов:

$$\hat{\mathbf{x}} = V_b \boldsymbol{\theta}_b, \quad \hat{\mathbf{y}} = V_f \boldsymbol{\theta}_f, \quad (28)$$

где $V_b \in \mathbb{R}^{L \times K}$ и $V_f \in \mathbb{R}^{H \times K}$ - матрицы базиса.

В *обобщённой* конфигурации матрицы V_b, V_f являются полностью обучаемыми параметрами. В *интерпретируемой* конфигурации базис фиксирован, но осмыслен:

- для трендового стека используется полиномиальный базис: $V_f[t, k] = t^k / T^k$, $k = 0, 1, \dots, K - 1$;
- для сезонного стека — гармонический базис: $V_f[t, k] = \cos(2\pi kt / H)$ и $V_f[t, k] = \sin(2\pi kt / H)$.

Коэффициенты $\boldsymbol{\theta}$ при этих базисах вычисляются нейронной сетью, что делает декомпозицию *обучаемой*: модель определяет амплитуду и соотношение компонент на основе данных, хотя семейство базисных функций задаётся аналитиком.

N-BEATS завоевал первое место в соревновании M4 среди чисто нейросетевых методов (уступив только гибриду ES-RNN [15]), что подтвердило практическую ценность обучаемого базисного разложения [22]. В дальнейшем идея была развита в архитектуре N-HiTS [41], добавившей иерархическую интерполяцию для работы с разными масштабами.

1.4.7. TimesNet

TimesNet [25] предлагает оригинальный подход к моделированию временных рядов через преобразование одномерной последовательности в набор двумерных представлений, соответствующих различным периодам.

На первом этапе доминирующие периоды ряда определяются с помощью быстрого преобразования Фурье (БПФ):

$$\mathbf{A} = \text{Avg}(\text{Amp}(\mathcal{F}(\mathbf{x}))), \quad \{p_1, p_2, \dots, p_k\} = \arg \text{Topk}(\mathbf{A}), \quad (29)$$

где $\text{Amp}(\cdot)$ — амплитудный спектр, $\text{Avg}(\cdot)$ — усреднение по каналам, а Topk — выбор k наиболее выраженных частот. Соответствующие периоды $p_1, \dots, p_k$ используются для перестройки одномерного ряда в двумерные тензоры.

Для каждого периода p_i исходный ряд длины L дополняется нулями до длины, кратной p_i , и перестраивается в матрицу размера $(L/p_i) \times p_i$. Строки этой матрицы соответствуют последовательным «циклам» длины p_i , а столбцы — позициям внутри цикла. Такое представление позволяет применить стандартные двумерные свёрточные операции (авторы используют блоки Inception [25]), которые одновременно моделируют *внутрипериодные* (вдоль столбцов) и *межпериодные* (вдоль строк) зависимости.

Результаты обработки для всех k периодов агрегируются через взвешенную сумму с весами, пропорциональными амплитуде соответствующей частоты:

$$\hat{\mathbf{x}} = \sum_{i=1}^k A_{p_i} \cdot \text{Reshape}_{1D}(\text{Inception}(\mathbf{X}_{p_i})). \quad (30)$$

TimesNet не выполняет явную декомпозицию на тренд и сезонность подобно Autoformer. Вместо этого модель осуществляет *неявную многомасштабную декомпозицию*: выделение нескольких доминирующих периодов и отдельная обработка каждого из них фактически разделяет ряд на компо-

ненты, соответствующие различным частотным диапазонам. Это родственно вейвлет-анализу [19], но с тем существенным отличием, что периоды определяются адаптивно из данных.

1.4.8. Helformer

Helformer [42] — гибридная архитектура, сочетающая фиксированную декомпозицию Холта–Уинтерса с нейросетевыми механизмами учёта сложных зависимостей. Особенностью подхода является то, что нейронная сеть прогнозирует не абсолютные значения ряда, а *корректирующие коэффициенты* (отношения фактических значений к прогнозу Холта–Уинтерса).

Модель работает в три этапа:

1. **Декомпозиция Холта–Уинтерса:** исходный ряд разлагается на уровень ℓ_t , тренд b_t и сезонность s_t по формулам (15), что даёт базовый прогноз $\hat{y}_t^{\text{HW}}$.
2. **Вычисление отношений:** для обучающей части формируется последовательность $r_t = y_t / \hat{y}_t^{\text{HW}}$, отражающая отклонения реальных данных от базового прогноза.
3. **Прогнозирование отношений нейросетью:** последовательность $\{r_t\}$ подаётся на вход гибридной сети, состоящей из блока многоголового внимания (22) и слоя LSTM [29]. Механизм внимания улавливает глобальные зависимости между отношениями, а LSTM моделирует их локальную динамику.

Итоговый прогноз формируется как произведение базового прогноза Холта–Уинтерса и предсказанного отношения:

$$\hat{y}_{t+h} = \hat{y}_{t+h}^{\text{HW}} \cdot \hat{r}_{t+h}. \quad (31)$$

С точки зрения классификации подходов к декомпозиции Helformer занимает уникальную позицию: декомпозиция выполняется *фиксированным* методом Холта–Уинтерса, а нейросеть отвечает за моделирование *остаточных отклонений* от базового прогноза. Это контрастирует с подходами Autoformer и N-BEATS, где сама декомпозиция является обучаемой. Такое сравнение позволяет ответить на вопрос: что важнее - обучаемость базиса декомпозиции или качество нейросетевой обработки компонент?

Следует отметить, что в оригинальной публикации [42] оценка прово-

дилась на данных о криптовалютах, причём обнаружена потенциальная утечка данных: базовый прогноз Холта–Уинтерса мог использовать информацию из тестового периода. В настоящей работе реализация Helformer выполнена с корректным разделением обучающей и тестовой выборок.

1.4.9. Итоги сравнительного анализа моделей

Рассмотренные в разделах 1.2–1.4 модели охватывают широкий спектр подходов к прогнозированию временных рядов — от классических статистических методов до современных нейросетевых архитектур. Для систематизации полученных сведений в таблице 1 приведено сопоставление всех рассмотренных моделей по ключевым характеристикам: типу декомпозиции, используемому механизму, сильным сторонам, ограничениям и рекомендуемым условиям применения.

Таблица 1. Сравнительная характеристика рассмотренных моделей прогнозирования

Модель	Тип де-комп.	Механизм	Сильные стороны	Ограничения	Условия применения
ARIMA	Фиксированная	Авторегрессия + скользящее среднее + разности	Обоснованная теория; мало параметров; интерпретируемость	Линейность; один сезонный период; ручной выбор порядков	Короткие и средние ряды со стационарной структурой
ETS	Фиксированная	Экспоненциальное сглаживание (уровень, тренд, сезонность)	Автоматический выбор модели; устойчивость; демпфирование тренда	Один сезонный период; ограниченная нелинейность	Короткие ряды; массовое прогнозирование
Prophet	Полу-фиксированная	Аддитивная: тренд + ряд Фурье + регрессоры	Множественная сезонность; автообнаружение точек излома	Завышенная гибкость; риск переобучения; чувствительность к выбору точек перелома	Ряды с несколькими сезонами и известными эффектами
DLinear	Обучаемая (простая)	Скользящее среднее, затем две линейные проекции	Минимальная сложность; быстрое обучение; конкурентная точность	Линейность; отсутствие взаимодействия компонент	Средние и длинные ряды; базовая линия для нейросетей
N-BEATS	Обучаемая (базисная)	Стек полносвязных блоков + базисное разложение (тренд, сезонность)	Двойной остаток; аналитические базисы; интерпретируемость	Большое число параметров; обучение на одном ряду — переобучение	Средние и длинные ряды при достаточном объеме данных
Autoformer	Обучаемая (прогрессивная)	Скользящее среднее на каждом слое + автокорреляция	Послойное выделение тренда; подсерийная агрегация	Сложная архитектура; нестабильность на коротких рядах	Длинные ряды с выраженной трендовой и сезонной структурой
FEDformer	Обучаемая (частотная)	Прогрессивная декомпозиция + случайный выбор мод Фурье / вейвлет	Линейная сложность; частотная селекция; устойчивость к шуму	Зависимость от выбора частотного базиса; сложная реализация	Длинные ряды с богатой частотной структурой
PatchTST	Нет явной	Патчи + ванильный трансформер (channel-independent)	Локальная семантика патчей; масштабируемость; простота	Отсутствие декомпозиции; зависимость от размера патча	Длинные ряды; многоканальные данные
TimesNet	Неявная (много-масштабная)	Адаптивные периоды, преобразование в 2D-тензоры, свёртки Inception	Многомасштабная адаптивность; универсальность задач	Вычислительная стоимость; косвенная интерпретируемость	Ряды с несколькими периодами; достаточные вычислительные ресурсы
Helformer	Фиксированная + нейросеть	Декомпозиция Холта-Уинтерса + внимание + LSTM над отношениями	Устойчивый базовый прогноз; нейросетевая коррекция остатков	Зависимость от качества HW-прогноза; мультипликативные допущения	Ряды с ясной трендово-сезонной структурой; ограниченные данные

Из таблицы 1 прослеживается несколько закономерностей, определяющих логику экспериментальной части работы.

Для коротких рядов ($T < 50$ наблюдений), характерных для годовой частоты в МЗ, ожидается доминирование классических и гибридных моделей. ETS и ARIMA оперируют малым числом параметров и опираются на статистически обоснованные процедуры оценки, что делает их устойчивыми

в условиях ограниченной выборки. Helformer, сочетающий фиксированную декомпозицию с нейросетевой коррекцией, также имеет преимущество: базовый прогноз Холта–Уинтерса обеспечивает разумный уровень точности даже при минимальном количестве данных, а нейросетевой компонент получает для обучения уже нормализованные отношения. Нейросетевые модели с полностью обучаемой декомпозицией (Autoformer, FEDformer, N-BEATS) на коротких рядах рискуют столкнуться с переобучением.

Для *рядов средней длины* ($50 \leq T \leq 100$), типичных для квартальной частоты, конкуренция между подходами наиболее открыта. С одной стороны, объём данных уже достаточен для оценки нескольких десятков параметров, что делает DLinear и N-BEATS конкурентоспособными. С другой стороны, классические модели по-прежнему выигрывают за счёт информационных критериев, автоматически ограничивающих сложность. Именно в этом диапазоне разница между качеством реализации и настройки гиперпараметров может быть определяющей, что подчёркивает важность строгой валидации экспериментального контура.

Для *длинных рядов* ($T > 100$, месячная и более высокие частоты) нейросетевые модели с обучаемой декомпозицией теоретически должны получать наибольшее преимущество. Достаточный объём данных позволяет обучить сложные представления тренда и сезонности, а механизмы внимания и автокорреляции — выявить нетривиальные долгосрочные зависимости, недоступные линейным моделям. Однако, как показывают результаты соревнований M3 [2] и M4 [3], а также работа Цзэн и др. [21], это преимущество далеко не гарантировано и чувствительно к качеству реализации, гиперпараметрам и вычислительному бюджету.

Таким образом, центральная гипотеза экспериментальной части формулируется не как утверждение о безусловном превосходстве того или иного класса моделей, а как исследование *границ применимости*: при каких характеристиках ряда (длина, частота, наличие сезонности, сложность тренда) обучаемая декомпозиция и нейросетевые механизмы учёта дальних зависимостей дают статистически значимый выигрыш, а при каких — избыточная сложность оказывается невостребованной. Конкретная экспериментальная проверка этой гипотезы описана в главе 2.

1.5. Соревнования по прогнозированию временных рядов

Серия соревнований M-Competition, организованная Макридакисом и коллегами, на протяжении более трёх десятилетий служит главным ориентиром для оценки методов прогнозирования. Два соревнования представляют наибольший интерес для данной работы.

M3 Competition [2] включало 3003 временных ряда четырёх частот (годовые, квартальные, месячные и прочие), собранных из различных предметных областей: макроэкономика, финансы, промышленность, демография. Горизонты прогноза зависели от частоты: $H = 6$ для годовых, $H = 8$ для квартальных и $H = 18$ для месячных рядов. Основной метрикой была sMAPE.

Главный результат M3 состоял в том, что простые методы — ETS с демпфированным трендом и комбинированные прогнозы — показали наилучшую среднюю точность. Ни одна сложная модель, включая нейронные сети того времени, не смогла систематически превзойти хорошо настроенные статистические методы. Этот результат на многие годы определил скептическое отношение сообщества к нейросетевым подходам в прогнозировании.

M4 Competition [3] масштабировало задачу до 100 000 рядов шести частот (от часовых до годовых). Победителем стал гибридный метод ES-RNN [15], объединивший экспоненциальное сглаживание на уровне отдельного ряда с рекуррентной нейронной сетью, обученной на всём наборе. Второе место заняла комбинация статистических методов FFORMA [43]. Чисто нейросетевые методы, за исключением ES-RNN, в целом уступали статистическим, хотя N-BEATS [22], опубликованный позднее, показал результаты, конкурентоспособные с ES-RNN.

Результаты M3 и M4 можно обобщить следующим образом:

1. Простые методы остаются чрезвычайно конкурентоспособными, особенно для коротких рядов и небольших горизонтов.
2. Гибридные подходы, сочетающие статистическую декомпозицию с нейросетевой обработкой, показали наибольший потенциал.
3. Комбинирование (ансамблирование) прогнозов нескольких методов, как правило, лучше любого индивидуального метода.
4. Сложность модели не является гарантией точности: важнее правильная постановка задачи и надлежащая оценка.

Серия M-Competition была продолжена соревнованием **M5** [44], в кото-

ром задача прогнозирования была перенесена в область розничных продаж с иерархической структурой данных, что потребовало учёта перекрёстных зависимостей между рядами. Победители M5 активно использовали градиентный бустинг и нейросетевые ансамбли, подтвердив тенденцию к усложнению методов при переходе от одномерного к иерархическому прогнозированию.

Помимо соревнований, важным ресурсом для воспроизводимого сравнения методов стал Monash Time Series Forecasting Archive [45] — систематизированный репозиторий наборов данных различных предметных областей, частот и длин рядов. Архив обеспечивает единообразный формат хранения и стандартизованные протоколы оценки, что упрощает сопоставление результатов различных исследований.

Эти наблюдения непосредственно мотивируют постановку экспериментов данной работы: сравнение проводится на данных M3 (и, по возможности, M4) с обязательным включением ETS и ARIMA в качестве базовых линий.

1.6. Выводы по обзору и обоснование структуры эксперимента

Проведённый обзор позволяет выделить несколько ключевых наблюдений, определяющих структуру экспериментальной части работы.

Во-первых, декомпозиция временного ряда на компоненты является сквозным принципом, объединяющим как классические, так и нейросетевые методы. Однако характер декомпозиции существенно различается:

- в ETS и Prophet декомпозиция *фиксирована*: тип взаимодействия компонент (аддитивный или мультипликативный) и семейство базисных функций (экспоненциальное сглаживание, ряд Фурье) задаются до обучения;
- в DLinear и Autoformer декомпозиция осуществляется скользящим средним, но дальнейшая обработка компонент *обучаема*;
- в N-BEATS базисные функции для тренда и сезонности заданы аналитически, однако их коэффициенты определяются нейронной сетью;
- в TimesNet декомпозиция неявная: ряд преобразуется в набор двумерных представлений для адаптивно выбранных периодов;
- в FEDformer декомпозиция переносится в частотную область с обучаемым выбором мод;

- в Heformer нейросеть работает не с компонентами ряда, а с отношениями к прогнозу фиксированной декомпозиции.

Во-вторых, несмотря на быстрое развитие нейросетевых архитектур, результаты соревнований M3 и M4 показывают, что простые статистические методы остаются сильными базовыми линиями, а выигрыш от усложнения архитектуры не гарантирован [2, 3]. Работа Цзэн и др. [21] дополнительно подчеркнула, что на стандартных наборах линейная модель DLinear конкурирует с трансформерами.

В-третьих, существует пробел в систематическом сравнении различных типов декомпозиции — фиксированной и обучаемой — в единых экспериментальных условиях, особенно при обучении моделей на отдельных рядах, а не на агрегированных наборах. Появление стандартизованных архивов, таких как Monash Time Series Forecasting Archive [45], создаёт необходимую инфраструктуру для подобных сравнений, однако большинство публикаций ограничиваются узким набором моделей или типов данных.

Настоящая работа направлена на заполнение этого пробела. Экспериментальный контур включает одиннадцать моделей, представляющих различные точки на оси «фиксированная декомпозиция — обучаемая декомпозиция — отсутствие явной декомпозиции»:

- ARIMA и ETS — классические методы с фиксированной структурой;
- Prophet — полуфиксированная аддитивная декомпозиция с оцениваемыми параметрами;
- DLinear — простейшая обучаемая декомпозиция;
- N-BEATS — обучаемое базисное разложение;
- Autoformer — прогрессивная декомпозиция с автокорреляцией;
- FEDformer — частотная обучаемая декомпозиция;
- TimesNet — неявная многомасштабная декомпозиция;
- PatchTST — трансформер без встроенной декомпозиции;
- Heformer — фиксированная декомпозиция с нейросетевой коррекцией.

Сравнение проводится на данных соревнований M3 и M4 с использованием метрик sMAPE и MASE, что обеспечивает сопоставимость с опубликованными результатами. Центральный исследовательский вопрос формулируется следующим образом: *в каких условиях обучаемая декомпозиция и нейросетевые механизмы учёта долгосрочных зависимостей дают стати-*

стически значимое преимущество по сравнению с классическими подходами, а в каких — нет?

Конкретная структура эксперимента, включая наборы данных, горизонты, гиперпараметры моделей и процедуру оценки, описана в главе 2.

Глава 2. Экспериментальное исследование

В данной главе описывается экспериментальный контур, разработанный для сравнительного анализа классических и нейросетевых моделей прогнозирования временных рядов. Последовательно изложены: постановка эксперимента (данные, модели, метрики), результаты прямого сравнения на данных M3 и M4 Competition, эксперименты с итеративным прогнозированием и предобучением, а также обобщающее обсуждение полученных результатов.

2.1. Постановка эксперимента

2.1.1. Данные

В качестве экспериментальной базы используются два наиболее авторитетных набора данных для одномерного прогнозирования: M3 Competition [2] и M4 Competition [3].

M3 Competition содержит 3003 временных ряда, разбитых на шесть частотных категорий. В настоящей работе используются три из них: *yearly* (645 рядов, горизонт прогноза $H=6$), *quarterly* (756 рядов, $H=8$) и *monthly* (1428 рядов, $H=18$). Длина рядов варьируется от 14 наблюдений для годовых до 126 для месячных, что создает различные режимы для нейросетевых моделей: от экстремально малых выборок до умеренных.

M4 Competition содержит свыше 100 000 рядов шести частот. Из них в эксперименте задействованы три частотные категории: *quarterly* (24 000 рядов, $H=8$), *monthly* (48 000 рядов, $H=18$) и *daily* (4227 рядов, $H=14$). Включение ежедневных рядов позволяет исследовать поведение моделей в режиме длинных обучающих выборок (до 9919 наблюдений).

Выборка. Для M3 Competition используются все 2829 рядов трёх частотных категорий (645 *yearly*, 756 *quarterly*, 1428 *monthly*), что обеспечивает полный охват набора данных и устойчивые статистические оценки. Для M4 из каждой категории случайным образом ($\text{seed}=42$) отбирается по 1000 рядов для квартальных и месячных категорий и 1000 ежедневных рядов (3000 рядов суммарно). Параллелизация на 16 вычислительных ядрах (*joblib*) позволяет выполнить полный прогон M3 за 5–8 часов, M4 — за 12–18 часов.

Разбиение. Для каждого ряда последние H значений выделяются как

тестовая выборка; все предшествующие наблюдения используются для обучения. Этот протокол соответствует стандарту соревнований M3/M4 [2, 3] и обеспечивает прямую сопоставимость с опубликованными результатами.

2.1.2. Модели и их конфигурация

В эксперименте участвуют 11 моделей, которые можно разбить на четыре группы (табл. 2).

Таблица 2. Обзор моделей: архитектура, декомпозиция и ключевые гиперпараметры

Модель	Тип	Декомпозиция	Ключевые параметры
Seasonal Naive	baseline	—	последний сезон
Auto-ARIMA	классическая	разности	автоподбор (p, d, q)
ETS	классическая	фиксированная	автоподбор
Prophet	классическая	фиксированная	additive/multiplicative
DLinear	нейросетевая	фиксированная (MA)	$L=512$, $lr=0.001$
N-BEATS	нейросетевая	обучаемая (trend+season)	стеки $\times 4$, $lr=0.001$
TimesNet	нейросетевая	обучаемая (2D)	$top-k=3$, $d=32$, $lr=0.001$
Autoformer	трансформерная	обучаемая (series decomp.)	$d=64$, $n_h=4$, $lr=0.0001$
FEDformer	трансформерная	обучаемая (MOEDecomp)	$d=64$, $n_h=4$, $lr=0.0001$
PatchTST	трансформерная	без декомпозиции	$patch=8$, $d=64$, $lr=0.0001$
Helformer	гибридная	фиксированная (HW)	$d=32$, $n_h=2$, $lr=0.001$

Режим обучения. Все нейросетевые модели обучаются в режиме *per-series*: для каждого временного ряда модель инициализируется заново и обучается только на данных этого ряда. Такой режим отличается от режима глобального обучения, при котором одна модель обучается сразу на множестве рядов [46], и заведомо ставит нейросетевые модели в невыгодное положение на коротких рядах, однако позволяет оценить способность архитектуры извлекать полезные паттерны из ограниченных данных — ключевой вопрос настоящего исследования.

Количество эпох обучения составляет 80 для прямого прогнозирования основных моделей и 40 для Helformer. Для ежедневных рядов M4 Autoformer и FEDformer обучаются 30 эпох ввиду вычислительных ограничений. Оптимизатор — Adam [47] ($lr=0.001$ для DLinear, N-BEATS, TimesNet, Helformer;

$lr=0.0001$ для трансформерных моделей).

Нормализация. Перед подачей в нейросетевые модели ряд нормализуется по z -score (вычитание среднего, деление на стандартное отклонение); для Helformer применяется Min-Max нормализация. Обратное преобразование выполняется после генерации прогноза.

2.1.3. Протокол оценки

Эксперимент включает три протокола прогнозирования:

1. **Прямой прогноз:** модель обучается, после чего генерирует все H шагов прогноза за один проход. Это основной режим для всех сравнений.
2. **Итеративный прогноз:** модель прогнозирует один шаг вперед, прогнозное значение добавляется во входное окно, и процесс повторяется H раз. Данный режим моделирует реальный сценарий эксплуатации.
3. **Предобучение:** модель предварительно обучается на всех рядах данной категории, затем дообучается на конкретном ряде. Данный режим проверяет гипотезу о недостатке данных при per-series обучении.

Метрики. Для оценки качества прогноза используются шесть метрик:

- sMAPE — основная метрика соревнований M3/M4 [9];
- MAPE;
- RMSE;
- MSE;
- MAE;
- MASE [9] — масштабно-инвариантная метрика, нормирующая ошибку на ошибку наивного прогноза.

В таблицах и обсуждении основной акцент делается на sMAPE (процентная, безразмерная, допускает агрегацию по рядам с разным масштабом) и MASE (учитывает базовый уровень сложности ряда).

2.2. Прямое сравнение моделей

2.2.1. Диагностика на синтетических рядах

Перед переходом к реальным данным M3/M4 все модели протестированы на шести синтетических профилях длиной 200 наблюдений каждый с горизонтом прогноза $H=24$ и входным окном $P=12$. Профили спроектированы так, чтобы изолировать отдельные компоненты: *trend_only* (линейный тренд),

seasonal (чистая сезонность), *trend_seasonal* (тренд + сезонность), *noisy* (случайное блуждание + шум), *changepoint* (смена структуры в середине ряда), *complex* (тренд + сезонность + шум + выброс).

Таблица 3 содержит sMAPE для каждой комбинации модель–профиль.

Таблица 3. Диагностика на синтетических профилях: sMAPE по 6 профилям (горизонт $H=24$, окно $P=12$)

Модель	Тренд	Сезон.	Тр.+Сез.	Шум	Changepoint	Complex	Ср.
ETS	0.9	3.0	1.4	11.0	8.9	2.2	4.57
Helformer	1.7	3.8	2.0	12.3	6.4	3.6	4.96
DLinear	3.3	2.8	4.0	16.6	8.6	4.7	6.67
N-BEATS	1.3	2.5	3.0	18.1	12.8	2.4	6.68
PatchTST	3.2	2.7	2.7	22.3	9.8	2.9	7.26
TimesNet	1.5	3.8	5.0	26.7	3.7	4.5	7.54
Prophet	1.0	11.9	9.2	12.2	3.3	8.8	7.73
S. Naive	6.1	3.8	6.2	21.6	8.2	3.5	8.24
Autoformer	7.7	3.7	4.1	28.9	5.9	3.1	8.90
FEDformer	8.7	3.5	4.6	38.5	6.8	4.8	11.14
Auto-ARIMA	1.3	41.2	40.1	22.2	4.7	15.8	20.89

ETS показывает лучший средний sMAPE (4.57%), уверенно лидируя на профилях с трендом и сезонностью, а также на зашумлённых данных. Helformer (4.96 %) занимает второе место, подтверждая эффективность фиксированной HW-декомпозиции. Примечательна катастрофическая ошибка Auto-ARIMA на профилях с выраженной сезонностью (*seasonal*: 41.2, *trend_seasonal*: 40.1), обусловленная тем, что автоматический подбор параметров не учитывает сезонность при малом числе полных периодов. TimesNet выделяется лучшим результатом на *changepoint* (3.7%), демонстрируя способность двумерной декомпозиции адаптироваться к смене структуры ряда.




Рисунок 1. Синтетический ряд с чистой сезонностью ($N=200$, горизонт $H=24$)




Рисунок 2. Синтетический ряд с трендом и сезонностью ($N=200$, горизонт $H=24$)




Рисунок 3. Сложный синтетический ряд с трендом, сезонностью, шумом и выбросом ($N=200$, горизонт $H=24$)

2.2.2. Результаты на M3 Competition

Таблица 4 содержит средние значения sMAPE по категориям и в целом для всех одиннадцати моделей на полном M3 Competition (2829 рядов). Жирным выделены лучшие результаты в каждой категории.

Таблица 4. Прямое прогнозирование на M3: sMAPE по категориям (2829 рядов)

Модель	Yearly (645)	Quarterly (756)	Monthly (1428)	Overall
Seasonal Naive	17.88	11.07	17.24	15.74
Auto-ARIMA	17.85	10.90	18.14	16.14
ETS	19.12	10.80	17.42	16.04
Prophet	21.88	14.36	19.52	18.68
TimesNet	21.11	12.50	18.82	17.65
N-BEATS	30.92	13.79	18.26	19.95
Helformer	31.20	14.20	17.98	19.98
PatchTST	30.76	15.89	20.59	21.65
Autoformer	32.96	17.07	23.44	23.91
FEDformer	35.85	18.80	23.62	25.12
DLinear	45.23	25.55	23.30	28.90

Таблица 5 дополняет картину метрикой MASE, нечувствительной к масштабу ряда. Модели отсортированы по среднему MASE по трём категориям.

Таблица 5. Средние значения MASE на M3 (2829 рядов)

Модель	Среднее MASE
ETS	1.503
Auto-ARIMA	1.631
Seasonal Naive	1.683
TimesNet	1.704
Prophet	1.838
N-BEATS	2.269
PatchTST	2.390
Autoformer	2.607
FEDformer	2.846
DLinear	3.639
Helformer	—*

*Helformer: числовая нестабильность MASE на годовых рядах.

Эту картину дополняет аналогичная тепловая карта по MASE (рис. 4), а непосредственное сравнение рейтингов по двум метрикам показано на рис. 5.




Рисунок 4. Тепловая карта MASE по 6 частотам M3+M4

Если sMAPE и MASE согласованы, рейтинги моделей по этим метрикам должны совпадать (рис. 5).




Рисунок 5. Сравнение рейтингов моделей по sMAPE и MASE

Рисунок 5 показывает высокую согласованность рейтингов по sMAPE и MASE: Auto-ARIMA и ETS лидируют по обоим метрикам, TimesNet остается лучшей нейросетевой моделью. Наибольшее расхождение наблюдается для N-BEATS и Helformer, что объясняется различной чувствительностью метрик к масштабу ряда и выбросам.

Из полученных данных следует ряд наблюдений.

Классические модели лидируют на полном M3. Seasonal Naive (15.74), ETS (16.04) и Auto-ARIMA (16.14) занимают три первых места по общему sMAPE, что согласуется с результатами соревнований M3 [2]. ETS показывает лучший MASE (1.503), подтверждая свою эффективность как масштабно-инвариантный ориентир. Среди нейросетевых моделей TimesNet (17.65) ближе всего к классическим, проигрывая ETS менее чем на 2 п.п. по sMAPE.

Зависимость от частоты. На годовых рядах (14–47 точек) нейросетевые модели демонстрируют наибольшее отставание: лучший из них TimesNet (21.11) проигрывает Auto-ARIMA (17.85) более чем на 3 п.п. На квартальных рядах TimesNet (12.50) отстаёт от ETS (10.80) на 1.7 п.п., а N-BEATS (13.79) и Helformer (14.20) входят в зону умеренной конкурентоспособности. На месячных рядах Helformer (17.98) и N-BEATS (18.26) приближаются к уровню классических моделей (Seasonal Naive 17.24, ETS 17.42), демонстрируя эффективность декомпозиции при достаточном объёме данных (более 100 наблюдений).

DLinear. Несмотря на свою архитектурную простоту, DLinear показывает слабые результаты на M3 (28.90 overall), что объясняется малым объемом обучающих данных: модель не может эффективно разделить тренд и сезонность при per-series обучении на коротких рядах.




Рисунок 6. sMAPE по частотным категориям M3 (2829 рядов)

На рис. 6 визуально представлено распределение sMAPE по категориям. На полном наборе нейросетевые модели побеждают лучшую классическую в 40 % годовых, 41 % квартальных и 47 % месячных рядов.

Рисунки 7–9 иллюстрируют типичные прогнозы на конкретных рядах каждой категории M3.




Рисунок 7. Годовой ряд T352 M3 (горизонт $H=6$)




Рисунок 8. Квартальный ряд T478 M3 (горизонт $H=8$)




Рисунок 9. Месячный ряд T779 M3 (горизонт $H=18$)

2.2.3. Анализ по частотным категориям M3

Агрегированные таблицы 4–5 дают общую картину, однако поведение моделей существенно различается в зависимости от частоты. В данном разделе приведены детализированные результаты по трём ключевым метрикам (sMAPE, MASE, RMSE) отдельно для каждой частотной категории M3.

Таблица 6. Метрики на годовых рядах М3: sMAPE, MASE, RMSE (645 рядов, горизонт $H=6$)

Модель	sMAPE (%)	MASE	RMSE
Auto-ARIMA	17.85	3.095	1391.88
Seasonal Naive	17.88	3.172	1178.59
ETS	19.12	3.133	1435.49
TimesNet	21.11	3.247	1392.33
Prophet	21.88	3.528	1407.91
PatchTST	30.76	5.139	1847.46
N-BEATS	30.92	5.089	1898.97
Helformer*	31.20	—	—
Autoformer	32.96	5.632	1958.95
FEDformer	35.85	6.243	2093.97
DLinear	45.23	7.946	2535.54

*Helformer: числовая нестабильность MASE/RMSE на годовых рядах.

Годовые ряды (Yearly). Годовые ряды М3 представляют наиболее сложный режим для нейросетевых моделей: длина обучающей выборки составляет от 14 до 47 наблюдений, что критически мало для обучения параметров глубоких архитектур. Классические Auto-ARIMA (17.85) и Seasonal Naive (17.88) уверенно доминируют, а лучшая нейросетевая модель — TimesNet (21.11) — отстаёт более чем на 3 п.п. DLinear (45.23) демонстрирует катастрофическую ошибку, подтверждая неспособность простого линейного разложения работать при дефиците данных.

Таблица 7. Метрики на квартальных рядах M3: sMAPE, MASE, RMSE (756 рядов, горизонт $H=8$)

Модель	sMAPE (%)	MASE	RMSE
ETS	10.80	1.261	649.93
Auto-ARIMA	10.90	1.356	671.15
Seasonal Naive	11.07	1.425	682.21
TimesNet	12.50	1.481	747.19
N-BEATS	13.79	1.726	829.19
Helformer	14.20	2.048	1116.28
Prophet	14.36	1.690	822.23
PatchTST	15.89	1.971	914.08
Autoformer	17.07	2.181	978.65
FEDformer	18.80	2.498	1082.78
DLinear	25.55	3.624	1430.87

Квартальные ряды (Quarterly). Квартальные ряды (длина 24–72 наблюдения) представляют переходную зону, в которой нейросетевые модели начинают приближаться к классическим. ETS лидирует (10.80 sMAPE, 1.261 MASE), Auto-ARIMA (10.90) практически не уступает. TimesNet (12.50) показывает лучший результат среди нейросетевых моделей, отставая от ETS менее чем на 2 п.п.

Таблица 8. Метрики на месячных рядах M3: sMAPE, MASE, RMSE (1428 рядов, горизонт $H=18$)

Модель	sMAPE (%)	MASE	RMSE
Seasonal Naive	17.24	1.146	951.03
ETS	17.42	0.895	825.56
Helformer	17.98	1.108	1249.21
Auto-ARIMA	18.14	1.116	981.02
N-BEATS	18.26	1.283	1008.54
TimesNet	18.82	1.125	998.73
Prophet	19.52	1.152	956.38
PatchTST	20.59	1.370	1118.09
DLinear	23.30	1.702	1263.92
Autoformer	23.44	1.465	1202.88
FEDformer	23.62	1.495	1213.63

Месячные ряды (Monthly). На месячных рядах (длина 68–126 наблюдений) нейросетевые модели становятся конкурентоспособными: Helformer (17.98) и N-BEATS (18.26) приближаются к уровню Seasonal Naive (17.24) и ETS (17.42). ETS показывает лучший MASE (0.895) и RMSE (825.56), подтверждая эффективность экспоненциального сглаживания на месячных данных. TimesNet (18.82) также конкурентоспособен, а трансформерные модели (PatchTST 20.59, Autoformer 23.44, FEDformer 23.62) отстают заметнее.

2.2.4. Результаты на M4 Competition

Таблица 9 содержит результаты на квартальных и месячных рядах M4.

Таблица 9. Прямое прогнозирование на квартальных и месячных рядах M4: sMAPE (1000 рядов на категорию)

Модель	Quarterly	Monthly	Overall
ETS	9.74	15.14	12.44
Auto-ARIMA	10.23	14.74	12.49
Seasonal Naive	12.15	15.87	14.01
TimesNet	12.80	16.91	14.85
Helformer	16.44	17.06	16.75
Prophet	15.44	19.64	17.54
N-BEATS	16.23	18.98	17.60
PatchTST	16.01	20.74	18.38
Autoformer	18.70	22.30	20.50
FEDformer	20.02	22.88	21.45
DLinear	21.33	22.21	21.77

На расширенной выборке M4 (1000 рядов на категорию) классические модели сохраняют лидерство: ETS (12.44 overall) и Auto-ARIMA (12.49) занимают первые два места. TimesNet (14.85) — лучшая нейросетевая модель, существенно приблизившаяся к классическим (разрыв менее 2.5 п.п.). Helformer (16.75) и N-BEATS (17.60) показывают устойчивые результаты в среднем диапазоне. Autoformer (20.50) и FEDformer (21.45) по-прежнему замыкают рейтинг; причины рассмотрены в кросс-датасетном анализе (п. 2.2.6).

Принципиально иная картина наблюдается на ежедневных рядах M4 (табл. 10).

Таблица 10. Прямое прогнозирование на ежедневных рядах М4: sMAPE и MASE (1000 рядов, горизонт $H=14$)

Модель	sMAPE	MASE
Auto-ARIMA	3.22	1.16
ETS	3.46	1.17
TimesNet	3.62	1.31
Seasonal Naive	4.05	1.53
PatchTST	4.44	1.65
N-BEATS	4.46	1.69
Helformer	4.49	1.78
DLinear	4.54	1.68
Autoformer	4.84	1.76
FEDformer	5.15	1.90
Prophet	11.24	4.09




Рисунок 10. sMAPE на ежедневных рядах М4 (1000 рядов, горизонт $H=14$)

На полной выборке ежедневных рядов (1000 рядов) Auto-ARIMA (3.22) лидирует, за ним ETS (3.46) и TimesNet (3.62), который является лучшей нейросетевой моделью и отстаёт от лидера всего на 0.4 п.п. PatchTST (4.44), N-BEATS (4.46) и Helformer (4.49) демонстрируют сопоставимые результаты. Увеличение выборки с 30 до 1000 рядов привело к росту средних sMAPE за счёт включения более сложных рядов, но подтвердило ключевое наблюдение: на длинных рядах нейросетевые модели конкурентоспособны с классическими, а TimesNet приближается к уровню ETS.

Рисунки 11–13 иллюстрируют типичные прогнозы на конкретных рядах каждой категории М4.




Рисунок 11. Квартальный ряд Q2061 М4 (горизонт $H=8$)




Рисунок 12. Месячный ряд M4124 М4 (горизонт $H=18$)




Рисунок 13. Ежедневный ряд D362 M4 (горизонт $H=14$)

2.2.5. Анализ по частотным категориям M4

Аналогично M3, детализированные результаты на M4 приведены отдельно для каждой частотной категории.

Таблица 11. Метрики на квартальных рядах M4: sMAPE, MASE, RMSE (1000 рядов, горизонт $H=8$)

Модель	sMAPE (%)	MASE	RMSE
ETS	9.74	1.19	627.01
Auto-ARIMA	10.23	1.24	656.69
Seasonal Naive	12.15	1.58	775.40
TimesNet	12.80	1.44	805.33
Prophet	15.44	1.77	880.78
PatchTST	16.01	1.95	933.56
N-BEATS	16.23	2.00	956.09
Helformer	16.44	2.09	1273.24
Autoformer	18.70	2.34	1079.81
FEDformer	20.02	2.52	1132.42
DLinear	21.33	2.99	1246.88

Квартальные ряды M4 (Quarterly). На квартальных рядах M4 (1000 рядов) классические модели сохраняют преимущество: ETS (9.74) лидирует по sMAPE, MASE и RMSE, Auto-ARIMA (10.23) занимает второе место. TimesNet (12.80) показывает лучший результат среди нейросетевых моделей, отставая от ETS на 3 п.п. Autoformer (18.70) и FEDformer (20.02) демон-

стрируют значительное отставание, что подтверждает системный характер проблемы трансформерных архитектур с обучаемой декомпозицией при regression обучении.

Таблица 12. Метрики на месячных рядах M4: sMAPE, MASE, RMSE (1000 рядов, горизонт $H=18$)

Модель	sMAPE (%)	MASE	RMSE
Auto-ARIMA	14.74	1.21	790.41
ETS	15.14	1.05	757.23
Seasonal Naïve	15.87	1.31	852.35
TimesNet	16.91	1.22	866.27
Helformer	17.06	1.35	1032.20
N-BEATS	18.98	1.49	972.60
Prophet	19.64	1.43	885.67
PatchTST	20.74	1.53	1049.30
DLinear	22.21	1.63	1116.70
Autoformer	22.30	1.68	1138.38
FEDformer	22.88	1.79	1190.58

Месячные ряды M4 (Monthly). На месячных рядах M4 (1000 рядов) Auto-ARIMA лидирует по sMAPE (14.74), а ETS — по MASE (1.05) и RMSE (757.23). TimesNet (16.91) показывает лучший результат среди нейросетевых моделей, отставая от лидера менее чем на 2.2 п.п. Helformer (17.06) подтверждает эффективность фиксированной HW-декомпозиции. Увеличение выборки с 30 до 1000 рядов существенно изменило абсолютные значения и некоторые ранжировки: TimesNet улучшился с 28.03 до 16.91, N-BEATS — с 26.31 до 18.98, что свидетельствует о нерепрезентативности малых подвыборок.

Таблица 13. Метрики на ежедневных рядах M4: sMAPE, MASE, RMSE (1000 рядов, горизонт $H=14$)

Модель	sMAPE (%)	MASE	RMSE
Auto-ARIMA	3.22	1.16	258.60
ETS	3.46	1.17	247.11
TimesNet	3.62	1.31	269.27
Seasonal Naive	4.05	1.53	315.58
PatchTST	4.44	1.65	325.94
N-BEATS	4.46	1.69	319.18
Helformer*	4.49	1.78	269.23
DLinear	4.54	1.68	340.00
Autoformer	4.84	1.76	344.08
FEDformer	5.15	1.90	357.23
Prophet	11.24	4.09	743.43

*Helformer RMSE: среднее без 1% выбросов (3 ряда с числовым переполнением).

Ежедневные ряды M4 (Daily). Ежедневные ряды M4 (длина 107–9919 наблюдений) представляют режим, наиболее благоприятный для нейросетевых моделей. Auto-ARIMA (3.22) лидирует, но TimesNet (3.62) является лучшей нейросетевой моделью и отстаёт от лидера всего на 0.4 п.п. sMAPE. PatchTST (4.44), N-BEATS (4.46) и Helformer (4.49) показывают сопоставимые результаты, демонстрируя, что при длинных обучающих выборках нейросетевые модели приближаются к уровню классических подходов. Аномалия Prophet (11.24) объясняется неадекватным выбором модели сезонности на рядах с сильным недельным циклом.

2.2.6. Кросс-датасетный анализ

Для обобщения результатов табл. 14 сводит средние sMAPE по всем шести экспериментальным категориям.

Таблица 14. Кросс-датасетное сравнение sMAPE по 6 частотам M3+M4

Модель	M3-Y	M3-Q	M3-M	M4-Q	M4-M	M4-D	Среднее
Auto-ARIMA	17.85	10.90	18.14	10.23	14.74	3.22	12.51
ETS	19.12	10.80	17.42	9.74	15.14	3.46	12.61
S. Naive	17.88	11.07	17.24	12.15	15.87	4.05	13.04
TimesNet	21.11	12.50	18.82	12.80	16.91	3.62	14.29
Helformer	31.20	14.20	17.98	16.44	17.06	4.49	16.90
Prophet	21.88	14.36	19.52	15.44	19.64	11.24	17.01
N-BEATS	30.92	13.79	18.26	16.23	18.98	4.46	17.11
PatchTST	30.76	15.89	20.59	16.01	20.74	4.44	18.07
Autoformer	32.96	17.07	23.44	18.70	22.30	4.84	19.89
FEDformer	35.85	18.80	23.62	20.02	22.88	5.15	21.05
DLinear	45.23	25.55	23.30	21.33	22.21	4.54	23.69

Средний ранг по шести категориям (табл. 15) дает устойчивую ранжировку моделей с учетом вариативности между наборами данных.

Таблица 15. Средний ранг моделей по 6 частотам M3+M4 (по sMAPE)

Модель	Средний ранг
Auto-ARIMA	1.83
ETS	1.83
Seasonal Naive	2.67
TimesNet	4.17
N-BEATS	6.00
Helformer	6.17
PatchTST	6.83
Prophet	7.00
Autoformer	9.33
DLinear	9.83
FEDformer	10.33

Помимо средних значений, важна стабильность моделей между категориями (рис. 14): классические модели (голубые) демонстрируют наименьший разброс, тогда как DLinear и FEDformer имеют наибольшую вариативность качества между категориями, что ограничивает их практическую применимость без дополнительной настройки под конкретную частоту.




Рисунок 14. Стабильность моделей: разброс sMAPE по 6 частотам M3+M4




Рисунок 15. Тепловая карта sMAPE по 6 частотам M3+M4

На уровне абсолютных значений лидерство классических моделей очевидно; перейдём к рангам, чтобы устранить влияние масштаба и яснее увидеть относительное положение моделей по категориям.




Рисунок 16. Тепловая карта рангов моделей по 6 частотам M3+M4 (по sMAPE)

Чтобы увидеть, как ранги меняются с частотой и длиной ряда, удобно представить ту же информацию в виде линейной траектории по шести категориям.




Рисунок 17. Эволюция рангов ключевых моделей по частотным категориям

Анализ табл. 14 и 15 (рис. 17) позволяет выделить следующие закономерности.

Auto-ARIMA и *ETS* — лидеры кросс-датасетного сравнения. *Auto-ARIMA* и *ETS* делят первое место по среднему рангу (1.83): *Auto-ARIMA* ли-

дирует на M3-Y (17.85), M4-M (14.74) и M4-D (3.22), ETS — на M3-Q (10.80) и M4-Q (9.74). Seasonal Naive (ранг 2.67) демонстрирует стабильно высокое качество за счёт устойчивости к переобучению. TimesNet (ранг 4.17) — лучшая нейросетевая модель, входящая в четвёрку лидеров на пяти из шести категорий.

Длина ряда как ключевой фактор. Превосходство классических моделей (ETS, Auto-ARIMA) на коротких рядах (yearly, quarterly) планомерно сокращается с ростом длины обучающей выборки: на M4 daily TimesNet (3.62) — лучшая нейросетевая модель, отстающая от Auto-ARIMA (3.22) всего на 0.4 п.п. PatchTST (4.44), N-BEATS (4.46) и Helformer (4.49) показывают сопоставимые результаты. На M3 monthly Helformer (17.98) и N-BEATS (18.26) уже сопоставимы с ETS (17.42). Этот результат согласуется с тезисом Зенга и соавторов [21].

Тип декомпозиции и частота. На квартальных рядах обоих наборов TimesNet (обучаемая 2D-декомпозиция) показывает результаты на уровне классических моделей (12.50 vs. 10.80 на M3-Q; 12.80 vs. 9.74 на M4-Q). Helformer с фиксированной HW-декомпозицией (14.20 на M3-Q, 16.44 на M4-Q) подтверждает эффективность декомпозиции при наличии выраженной сезонной структуры и хотя бы 40–60 наблюдений. Группировка по типу декомпозиции (рис. 18) подтверждает наблюдение: в per-series режиме модели без декомпозиции (Seasonal Naive, Auto-ARIMA, PatchTST) и с фиксированной декомпозицией (ETS, DLinear, N-BEATS, Helformer) показывают сопоставимое среднее качество, тогда как модели с обучаемой декомпозицией (Autoformer, FEDformer, TimesNet) отстают из-за высокой вариативности: TimesNet сильно повышает среднее группы, а Autoformer и FEDformer его понижают.




Рисунок 18. Средние sMAPE и MASE по типу декомпозиции

Трансформерные архитектуры. Autoformer и FEDformer стабильно занимают нижние позиции (ранги 9.33–10.33 из 11), что объясняется двумя факторами: (1) обучаемая декомпозиция серийного типа требует значительного объема данных, которого нет при per-series обучении на коротких рядах; (2) механизм внимания с автокорреляцией (Autoformer) или частотным преобразованием (FEDformer) вносит избыточную сложность для одномерного прогнозирования. PatchTST, отказавшийся от явной декомпозиции в пользу патчей, показывает заметно лучший результат (ранг 6.83) среди трансформеров.




Рисунок 19. Зависимость sMAPE от длины обучающей выборки на ежедневных рядах M4 (1000 рядов)

Рисунок 19 визуализирует зависимость sMAPE от длины обучающей выборки: для коротких рядов (менее 500 наблюдений) Auto-ARIMA и ETS

стабильно лидируют, но с ростом длины разрыв с TimesNet и PatchTST сокращается. На рядах свыше 2000 наблюдений все пять моделей демонстрируют сопоставимое качество. Дополнительный взгляд на ту же зависимость показан на рис. 20.




Рисунок 20. M4 Daily: преимущество лучшей нейросетевой модели над лучшей классической

2.3. Итеративное прогнозирование

Прямой прогноз предполагает генерацию всего горизонта за один проход. В реальных приложениях часто применяется итеративный прогноз, при котором модель пошагово продвигается вперед, используя собственные предсказания в качестве входных данных. Итеративный режим подвержен накоплению ошибок: неточность каждого шага вносит систематическое смещение в последующие шаги [48].

Эксперимент по сравнению direct и rollout проведен на обоих наборах данных (M3: 92 ряда, M4: 90 рядов) для девяти моделей. Результаты на M3 представлены в табл. 16.

Таблица 16. Прямое vs итеративное прогнозирование на M3: sMAPE и деградация Δ (92 ряда)

Модель	Direct	Rollout	Δ
Seasonal Naive	14.94	14.94	0.00
Auto-ARIMA	15.79	15.79	0.00
ETS	13.89	13.61	−0.28
DLinear	29.76	30.16	+0.40
N-BEATS	18.55	22.42	+3.87
TimesNet	17.47	21.75	+4.28
Autoformer	23.08	28.03	+4.94
FEDformer	22.34	28.62	+6.28
PatchTST	21.33	23.16	+1.84

Классические модели практически нечувствительны к переходу на rollout: Seasonal Naive и Auto-ARIMA имеют нулевой прирост (их прогнозы по определению строятся итеративно), а ETS даже незначительно улучшается (−0.28). Среди нейросетевых моделей наибольшая деградация наблюдается у FEDformer (+6.28 п.п.), за ним следуют Autoformer (+4.94) и TimesNet (+4.28). PatchTST демонстрирует наименьший прирост ошибки среди нейросетевых моделей (+1.84), что делает его наиболее устойчивым трансформером для итеративного применения.

Аналогичная закономерность наблюдается на M4 (табл. 17).

Таблица 17. Прямое vs итеративное прогнозирование на M4: sMAPE и деградация Δ (90 рядов)

Модель	Direct	Rollout	Δ
Seasonal Naive	13.11	13.11	0.00
Auto-ARIMA	12.34	12.34	0.00
ETS	11.58	12.41	+0.83
DLinear	20.96	20.45	−0.51
N-BEATS	18.22	22.06	+3.85
TimesNet	14.79	20.83	+6.04
Autoformer	21.97	26.27	+4.30
FEDformer	24.01	27.75	+3.74
PatchTST	18.33	20.84	+2.51

На M4 TimesNet демонстрирует наибольшую деградацию (+6.04 п.п.), превышая FEDformer (+3.74). Это объясняется тем, что двумерная декомпозиция TimesNet, эффективная при прямом прогнозе, порождает артефакты при последовательном применении к зашумленным входам. PatchTST (+2.51) вновь наиболее устойчив среди трансформеров. DLinear (−0.51) практически нечувствителен к режиму прогнозирования благодаря своей линейной архитектуре.

Обобщение. Средняя деградация при переходе на rollout по двум наборам данных составляет: FEDformer +5.01, TimesNet +5.16, Autoformer +4.62, N-BEATS +3.86, PatchTST +2.18, DLinear −0.05. Модели с более сложной обучаемой декомпозицией (FEDformer, TimesNet) накапливают ошибки быстрее, поскольку каждый итеративный шаг проходит через нелинейное преобразование разложения, усиливающее отклонения. PatchTST, работающий непосредственно с патчами входного ряда без явной декомпозиции, оказывается наиболее робастным.




Рисунок 21. Прямой vs итеративный прогноз на квартальном ряде T478 M3 (горизонт $H=8$)




Рисунок 22. Прямой vs итеративный прогноз на месячном ряде T779 M3 (горизонт $H=18$)

2.4. Предобучение трансформерных моделей

Одной из ключевых гипотез настоящей работы является предположение, что слабые результаты нейросетевых моделей в per-series режиме обусловлены не архитектурными ограничениями, а недостатком обучающих данных. Для проверки этой гипотезы проведён систематический эксперимент с предобучением, охватывающий все шесть нейросетевых моделей и Helformer на шести частотных категориях: M3 yearly, M3 quarterly, M3 monthly, M4 quarterly, M4 monthly и M4 daily.

Протокол. На первом этапе каждая модель предварительно обучается на обучающих выборках *всех* рядов соответствующей категории в режиме скользящего окна: все 645 годовых, 756 квартальных и 1428 месячных рядов M3, а также 5000 подвыбранных квартальных и 5000 месячных рядов M4 (40 эпох предобучения). На втором этапе предобученная модель дообучается на каждом из 30 тестовых рядов (20 эпох). Результат сравнивается с обучением «с нуля» (80 эпох) на тех же рядах. Такой протокол позволяет оценить эффект переноса знаний (transfer learning) из корпуса рядов на отдельный ряд [46].

Таблица 18 содержит относительное улучшение sMAPE при предобучении по всем комбинациям модель–частота. Положительные значения означают снижение sMAPE (улучшение), отрицательные — ухудшение.

Таблица 18. Эффект предобучения: относительное улучшение sMAPE по 6 частотам

Модель	M3-Y	M3-Q	M3-M	M4-Q	M4-M	M4-D	Среднее
DLinear	+37.6	+50.8	+16.6	+47.8	+37.2	−1.2	+31.5
Autoformer	+22.1	+12.8	+10.5	+40.0	+36.4	+30.9	+25.5
FEDformer	+24.1	−5.6	+11.2	+43.9	+35.8	−8.9	+16.8
Helformer	−8.0	+25.0	+17.5	+51.5	+16.3	+7.0	+18.2
PatchTST	+20.4	−3.2	+6.7	+14.1	+29.1	+12.3	+13.2
N-BEATS	−0.8	−8.3	−16.2	+23.2	+12.5	+2.0	+2.1
TimesNet	−52.6	−25.5	+13.0	−16.9	+14.6	+13.5	−9.0

2.4.1. Детальные результаты предобучения по частотам

Сводная таблица 18 отражает лишь относительные изменения. Для содержательного анализа необходимо рассмотреть абсолютные значения sMAPE по каждой частотной категории, что позволяет сопоставить эффект предобучения с уровнем классических baseline-моделей.

Таблица 19. Предобучение на годовых рядах M3: sMAPE с предобучением и без (30 рядов, $H=6$)

Модель	С нуля	Предобучение	Δ (%)
FEDformer	30.09	22.83	+24.1
Autoformer	30.05	23.12	+22.1
PatchTST	29.04	23.41	+20.4
DLinear	38.00	23.72	+37.6
N-BEATS	23.56	23.75	−0.8
TimesNet	16.44	25.08	−52.6
Helformer	27.59	29.80	−8.0
<i>Классические модели (per-series, для сравнения)</i>			
Auto-ARIMA		12.64	—
ETS		12.84	—

M3 Yearly ($H=6$, 30 рядов). На годовых рядах предобучение приводит к выравниванию результатов нейросетевых моделей в узком коридоре 22.8–25.1 %. Трансформерные модели (FEDformer, Autoformer, PatchTST) существенно улучшаются, однако TimesNet, показывавший лучший результат при обучении с нуля (16.44), деградирует до 25.08 — предобучение на корпусе коротких рядов разрушает его специализированную 2D-декомпозицию.

Таблица 20. Предобучение на квартальных рядах М3: sMAPE с предобучением и без (30 рядов, $H=8$)

Модель	С нуля	Предобучение	Δ (%)
TimesNet	9.90	12.43	−25.5
DLinear	25.70	12.65	+50.8
Autoformer	15.84	13.81	+12.8
N-BEATS	13.25	14.35	−8.3
PatchTST	14.60	15.07	−3.2
FEDformer	15.00	15.84	−5.6
Helformer	28.55	21.42	+25.0
<i>Классические модели (per-series, для сравнения)</i>			
Auto-ARIMA		10.54	—
ETS		9.73	—

М3 Quarterly ($H=8$, 30 рядов). На квартальных рядах наблюдается выраженная дивергенция: DLinear получает максимальное улучшение (+50.8 %), тогда как TimesNet и N-BEATS, эффективные при per-series обучении, ухудшаются. Лучший абсолютный результат с предобучением — DLinear (12.65), что сопоставимо с ETS (10.80 на полном М3 quarterly).

Таблица 21. Предобучение на месячных рядах М3: sMAPE с предобучением и без (30 рядов, $H=18$)

Модель	С нуля	Предобучение	Δ (%)
TimesNet	15.72	13.68	+13.0
DLinear	16.77	13.98	+16.6
Autoformer	16.88	15.10	+10.5
PatchTST	16.26	15.17	+6.7
FEDformer	18.37	16.32	+11.2
N-BEATS	14.89	17.30	−16.2
Helformer	27.88	23.01	+17.5
<i>Классические модели (per-series, для сравнения)</i>			
Auto-ARIMA		12.55	—
ETS		12.33	—

М3 Monthly ($H=18$, 30 рядов). Месячные ряды М3 являются ключевой категорией для эксперимента с предобучением. TimesNet с предобучением (13.68) впервые в данном исследовании превосходит ETS (17.42 на полном М3 monthly) — улучшение составляет 3.7 п.п. DLinear (13.98) также обхо-

дит ETS. N-BEATS, напротив, ухудшается (–16.2 %), поскольку его residual-архитектура уже эффективно специализируется на конкретном ряде.




Рисунок 23. sMAPE с предобучением и без на месячных рядах M3

Таблица 22. Предобучение на квартальных рядах M4: sMAPE с предобучением и без (30 рядов, $H=8$)

Модель	С нуля	Предобучение	Δ (%)
DLinear	29.58	15.44	+47.8
FEDformer	34.96	19.60	+43.9
PatchTST	22.86	19.64	+14.1
Autoformer	33.48	20.09	+40.0
Helformer	42.22	20.49	+51.5
N-BEATS	27.98	21.49	+23.2
TimesNet	19.26	22.52	–16.9
<i>Классические модели (per-series, для сравнения)</i>			
Auto-ARIMA		16.60	—
ETS		15.23	—

M4 Quarterly ($H=8$, 30 рядов). На M4 quarterly эффект предобучения максимален: Helformer улучшается на +51.5 %, DLinear на +47.8 %, FEDformer на +43.9 %. Предобучение на 5000 рядах формирует устойчивые сезонные паттерны, что особенно полезно для моделей с фиксированной декомпозицией. TimesNet вновь демонстрирует ухудшение (–16.9 %), подтверждая закономерность: его адаптивная 2D-декомпозиция конфликтует с глобальным предобучением.

Таблица 23. Предобучение на месячных рядах M4: sMAPE с предобучением и без (30 рядов, $H=18$)

Модель	С нуля	Предобучение	Δ (%)
FEDformer	24.36	15.64	+35.8
Autoformer	25.61	16.29	+36.4
TimesNet	20.10	17.17	+14.6
DLinear	27.42	17.23	+37.2
PatchTST	24.75	17.54	+29.1
N-BEATS	20.94	18.32	+12.5
Helformer	55.32	46.32	+16.3
<i>Классические модели (per-series, для сравнения)</i>			
Auto-ARIMA		15.96	—
ETS		15.52	—

M4 Monthly ($H=18$, 30 рядов). На месячных рядах M4 все семь моделей улучшаются с предобучением, причём Autoformer (+36.4 %) и DLinear (+37.2 %) показывают наибольший выигрыш. Даже TimesNet, чувствительный к предобучению на коротких рядах, здесь улучшается на +14.6 %, что подтверждает гипотезу о пороговой длине: при достаточном объёме данных для дообучения глобальная инициализация помогает и адаптивным архитектурам.

Таблица 24. Предобучение на ежедневных рядах M4: sMAPE с предобучением и без (30 рядов, $H=14$)

Модель	С нуля	Предобучение	Δ (%)
PatchTST	2.69	2.36	+12.3
DLinear	2.41	2.44	−1.2
TimesNet	2.84	2.46	+13.5
Autoformer	4.07	2.81	+30.9
Helformer	3.08	2.87	+7.0
N-BEATS	3.27	3.20	+2.0
FEDformer	3.82	4.16	−8.9
<i>Классические модели (per-series, для сравнения)</i>			
Auto-ARIMA		2.59	—
ETS		2.47	—




Рисунок 24. sMAPE с предобучением и без на ежедневных рядах M4

M4 Daily ($H=14$, 30 рядов). Ежедневные ряды M4 представляют уникальный режим для предобучения: длина обучающих выборок (до 9919 наблюдений) обеспечивает достаточный объём данных и для per-series обучения. PatchTST с предобучением (2.36) показывает лучший абсолютный результат, а Autoformer демонстрирует рекордное улучшение (+30.9 %). TimesNet, деградировавший на коротких рядах, здесь устойчиво улучшается (+13.5 %). Однако DLinear (−1.2 %) и FEDformer (−8.9 %) не получают выигрыша: DLinear уже достигает оптимума при per-series обучении на длинных рядах, а частотная декомпозиция FEDformer конфликтует с глобальными паттернами.

Анализ шести частотных категорий позволяет выделить следующие закономерности.

TimesNet с предобучением (13.68) превосходит ETS (17.42) на M3 monthly. Это наиболее значимый единичный результат: нейросетевая модель с обучаемой декомпозицией обходит лучшую классическую модель на крупной категории (1428 рядов), подтверждая гипотезу о том, что дефицит данных, а не архитектурные ограничения, был главным препятствием.

DLinear — наибольший совокупный выигрыш от предобучения. По шести категориям DLinear улучшается в среднем на +31.5 %, что объясняется минимальной ёмкостью его линейной архитектуры: при per-series обучении на коротких рядах МА-фильтр не может корректно разделить тренд и сезонность, тогда как предобучение на корпусе рядов формирует адекватные начальные веса. На длинных ежедневных рядах эффект предобучения для DLinear исчезает (−1.2 %), поскольку per-series обучение уже достаточно.

TimesNet деградирует на коротких рядах, но улучшается на длинных. Двумерное представление TimesNet эффективно специализируется при per-series обучении; предобучение на гетерогенном корпусе «размывает» эту адаптацию и навязывает усреднённые паттерны, разрушая per-series специализацию. Однако при достаточной длине дообучающей выборки (M3 monthly: +13.0 %, M4 monthly: +14.6 %, M4 daily: +13.5 %) этот конфликт ослабевает.

M4 демонстрирует более выраженный эффект предобучения. На M4 квартальных рядах Helformer улучшается на +51.5 %, DLinear на +47.8 %, FEDformer на +43.9 %. На M4 daily Autoformer показывает рекордное улучшение +30.9 %: предобучение на 4227 длинных рядах формирует устойчивые паттерны, компенсируя слабость обучаемой декомпозиции при per-series обучении. Предобучение на 5000–24 000 рядах (в сравнении с 645–1428 рядами M3) формирует более устойчивые глобальные представления.




Рисунок 25. Эффект предобучения: относительное улучшение sMAPE по 6 частотам M3+M4

Центральным результатом эксперимента с предобучением является превосходство нейросетевых моделей над ETS на месячных рядах. TimesNet с предобучением показывает sMAPE 13.68 % — на 3.7 п.п. лучше, чем ETS (17.42 %) на полном M3 monthly. Это первый случай в данной работе, когда нейросетевая модель убедительно обходит лучшую классическую на крупном наборе данных.

DLinear — наибольший выигрыш от предобучения на коротких рядах. DLinear демонстрирует среднее улучшение +31.5 % по шести категориям, трансформируясь из худшей модели (sMAPE 28.90 на полном M3) в конкурентоспособную. Этот результат объясняется тем, что линейная архитектура

DLinear при per-series обучении на коротких рядах не может корректно разделить тренд и сезонность; предобучение на корпусе рядов позволяет модели сформировать адекватные веса МА-фильтра ещё до дообучения на конкретном ряде.

Autoformer и FEDformer — существенное улучшение, особенно на M4. Autoformer (+24.4 % в среднем) и FEDformer (+21.9 %) получают наибольший выигрыш на квартальных и месячных рядах M4 (+36–44 %), где обучающие выборки длиннее и предобучение на 5000 рядах формирует устойчивые представления о сезонных паттернах. На M3 квартальных рядах FEDformer парадоксально ухудшается (–5.6 %), что объясняется конфликтом между MOEDecomr-декомпозицией, настроенной на глобальный корпус, и индивидуальными особенностями коротких рядов.

TimesNet — предобучение на коротких рядах разрушает выученные паттерны. TimesNet показывает среднее ухудшение –13.5 %, причём наиболее выраженное на годовых (–52.6 %) и квартальных (–25.5 %) рядах M3. Двумерная декомпозиция TimesNet [25] эффективно адаптируется к конкретному ряду при per-series обучении; предобучение на корпусе «размывает» эту адаптацию. Однако на месячных рядах M3 (+13.0 %) и M4 (+14.6 %), где длина обучающей выборки достаточна для дообучения, предобучение всё же помогает.

N-BEATS — минимальный эффект. N-BEATS с архитектурой residual-стеков [22] демонстрирует среднее улучшение лишь +2.1 %, причём на M3 предобучение ухудшает результат. N-BEATS изначально спроектирован как сильный per-series обучающийся, и глобальное предобучение не даёт ему существенного преимущества.

Практическое следствие. Предобучение на корпусе рядов сдвигает границу конкурентоспособности нейросетевых моделей с примерно 100 наблюдений (per-series режим) до примерно 40 наблюдений, существенно расширяя область применения глубоких архитектур для прогнозирования временных рядов. При полноценном глобальном обучении трансформерные модели потенциально могут существенно сократить разрыв с классическими подходами — и даже превзойти их, как продемонстрировано в ряде недавних работ [40, 49].




Рисунок 26. PatchTST с предобучением и без на месячном ряде T779 M3 (горизонт $H=18$)




Рисунок 27. Autoformer с предобучением и без на месячном ряде T779 M3 (горизонт $H=18$)

Эффект предобучения для всех семи нейросетевых моделей суммирован на рис. 25 и тепловой карте (рис. 36).

2.4.2. Прогнозы предобученных моделей на конкретных рядах

Для наглядной демонстрации эффекта предобучения рис. 28–31 показывают прогнозы с предобучением и без на ежедневном ряде D2111 ($N=232$), на котором все 7 нейросетевых моделей улучшаются с предобучением. Представлены четыре характерных примера — Autoformer, Helformer, DLinear

и TimesNet, — покрывающих разные архитектурные семейства и демонстрирующих различную чувствительность к переносу знаний.



Рисунок 28. Autoformer на ряде D2111: прогноз с нуля и с предобучением

Автокорреляционный механизм Autoformer выигрывает от глобальной инициализации — без неё модель не успевает обучить устойчивые сезонные паттерны на коротком ряде. Аналогичную, но ещё более выраженную картину показывает гибридный Helformer.



Рисунок 29. Helformer на ряде D2111: прогноз с нуля и с предобучением

Эффект ещё ярче для Helformer: фиксированная HW-декомпозиция плюс предобученная LSTM-коррекция радикально снижают ошибку. Для контраста полезно посмотреть, как ведут себя архитектуры без attention-механизма — DLinear и TimesNet.



Рисунок 30. DLinear на ряде D2111: с нуля vs с предобучением

DLinear демонстрирует более скромный эффект — линейная архитектура и без предобучения достаточно точна на коротких рядах. У TimesNet с его 2D-декомпозицией картина иная.



Рисунок 31. TimesNet на ряде D2111: с нуля vs с предобучением

Рисунки 32 и 33 показывают кульминационное сравнение: все нейросетевые модели с предобучением (сплошные линии) против классических моделей (пунктирные линии) на двух ежедневных рядах. На обоих примерах предобученные нейросети уверенно побеждают лучшую классическую модель.



Рисунок 32. Ряд D2111: предобученные нейросети vs классические модели

Аналогичная картина наблюдается на ряде D2216, где предобученные нейросети также доминируют.



Рисунок 33. Ряд D2216: предобученные нейросети vs классические модели

2.4.3. Предобученные нейросети vs классические модели

Сводная таблица 25 сопоставляет абсолютные значения sMAPE предобученных нейросетевых моделей с классическими baseline-моделями по всем шести частотным категориям.

Таблица 25. sMAPE: предобученные нейросетевые и классические модели по 6 частотам M3+M4

Модель	M3-Y	M3-Q	M3-M	M4-Q	M4-M	M4-D	Ср.
<i>Классические модели (per-series)</i>							
Auto-ARIMA	17.85	10.90	18.14	10.23	14.74	3.22	12.51
S. Naive	17.88	11.07	17.24	12.15	15.87	4.05	13.04
ETS	19.12	10.80	17.42	9.74	15.14	3.46	12.61
<i>Нейросетевые модели (с предобучением)</i>							
TimesNet PT	25.08	12.43	13.68	22.52	17.17	2.46	15.56
DLinear PT	23.72	12.65	13.98	15.44	17.23	2.44	14.24
PatchTST PT	23.12	15.07	15.17	19.64	17.54	2.36	15.48
Autoformer PT	23.41	13.81	15.10	20.09	16.29	2.81	15.25
FEDformer PT	22.83	15.84	16.32	19.60	15.64	4.16	15.73
N-BEATS PT	23.75	14.35	17.30	21.49	18.32	3.20	16.40
Helformer PT	29.80	21.42	23.01	20.49	46.32	2.87	23.99

Ключевые наблюдения из табл. 25:

- *M3 monthly*: TimesNet PT (13.68) и DLinear PT (13.98) уверенно побеждают все три классические модели (ETS 17.42, S. Naive 17.24, Auto-ARIMA 18.14). Это подтверждает, что при достаточном объеме корпуса для предобучения нейросетевые модели способны превзойти лучшие классические подходы.
- *M4 daily*: PatchTST PT (2.36), DLinear PT (2.44) и TimesNet PT (2.46) превосходят Auto-ARIMA (3.22) и ETS (3.46) на 0.8–1.1 п.п. В целом 6 из 7 предобученных нейросетей побеждают все классические модели на ежедневных рядах.
- *M4 monthly*: FEDformer PT (15.64) и Autoformer PT (16.29) выходят на уровень Seasonal Naive (15.87), хотя Auto-ARIMA (14.74) и ETS (15.14) сохраняют лидерство.
- *Короткие ряды (M3-Y, M3-Q, M4-Q)*: классические модели по-прежнему лидируют, что объясняется недостаточной длиной обучающей выборки для дообучения предобученных моделей.

Рисунок 34 визуализирует две ключевые категории, где предобучение выводит нейросетевые модели вперед: M3 monthly и M4 daily.




Рисунок 34. Предобученные нейросети vs классические модели на M3 monthly и M4 daily

На M3 monthly разрыв между лучшей предобученной моделью (TimesNet PT, 13.68) и лучшей классической (S. Naive, 17.24) достигает 3.6 п.п., что является наибольшим разрывом в пользу нейросетей за весь эксперимент. Чтобы оценить эффект предобучения в целом, рис. 35 сопоставляет средний ранг каждой нейросетевой модели в per-series режиме и с предобучением.




Рисунок 35. Средний ранг нейросетевых моделей в per-series режиме и с предобучением

Все семь нейросетевых моделей улучшают свой средний ранг при переходе к предобучению, причём DLinear, FEDformer и Autoformer показывают наибольший прирост — от +3 до +5 позиций. Детальная картина по частотам представлена на тепловой карте (рис. 36).




Рисунок 36. Тепловая карта эффекта предобучения: улучшение sMAPE по 6 частотам M3+M4

Положительные значения преобладают на M4 quarterly, M4 monthly и M3 monthly, а отрицательные на M3 yearly у TimesNet и Helformer — именно там, где обучающие выборки слишком коротки для эффективного fine-tuning. Альтернативный взгляд на разрыв между классическими и нейросетевыми подходами — абсолютная разница лучших sMAPE по каждой категории (рис. 37).




Рисунок 37. Лучшая классическая vs лучшая нейросетевая модель (per-series) по 6 частотам M3+M4

Разрыв планомерно сокращается с ростом длины ряда: на M3 yearly классические модели опережают нейросетевые на 5–6 п.п., тогда как на M4

daily разрыв исчезает и меняет знак в пользу нейросетей. Чтобы понять, насколько массовым является это преимущество на ежедневных рядах, рис. 38 показывает, у скольких рядов M4 daily Auto-ARIMA опережает K нейросетевых моделей.




Рисунок 38. Число нейросетевых моделей, побеждающих Auto-ARIMA на ежедневных рядах M4 (1000 рядов)

Лишь на $\sim 30\%$ рядов Auto-ARIMA лидирует с отрывом, тогда как на остальных хотя бы одна нейросетевая модель её догоняет или превосходит. Завершает обзор распределение sMAPE по моделям на M4 daily (рис. 39), которое демонстрирует не только средние значения, но и хвосты распределений.




Рисунок 39. sMAPE по моделям на ежедневных рядах M4

Auto-ARIMA, ETS и TimesNet имеют наиболее компактные распреде-

ления с короткими хвостами, тогда как DLinear, Autoformer и FEDformer показывают более широкое распределение, что объясняет их более высокий средний sMAPE несмотря на приемлемые медианы.

2.5. Анализ отдельных рядов

Для наглядной демонстрации возможностей нейросетевых моделей представлены прогнозы на отдельных рядах, где нейросети значительно превосходят классические подходы.




Рисунок 40. Доля рядов, где нейросеть побеждает лучшую классическую модель, по 6 частотам M3+M4 (per-series)

Рисунок 40 показывает, что доля рядов, на которых нейросетевые модели побеждают лучшую классическую, растёт с увеличением длины ряда: на M3 yearly (14–20 наблюдений) win rate составляет 10–15 %, а на M4 daily (107–9919 наблюдений) достигает 30–50 % для TimesNet и Helformer, подтверждая порог длины ряда как критический фактор конкурентоспособности нейросетевых моделей. Этот контекст мотивирует более детальный взгляд на отдельные ряды, где нейросети демонстрируют наибольший выигрыш.

2.5.1. Ежедневные ряды: нейросети vs классика

Среди 1000 ежедневных рядов M4 на 517 рядах (51.7 %) лучшая нейросетевая модель превосходит лучшую классическую по sMAPE, а на 295 рядах

(29.5 %) побеждают 3 и более нейросетевых моделей. Рисунки 41–46 иллюстрируют характерные примеры.




Рисунок 41. Ряд D1117 ($N=4197$): все нейросетевые модели побеждают классические

Здесь все 7 нейросетевых моделей побеждают классические — Autoformer и HeliFormer показывают sMAPE втрое ниже Seasonal Naive. На следующем ряде D2052 проверим, удерживается ли преимущество при существенно меньшей длине выборки.




Рисунок 42. Ряд D2052 ($N=174$): N-BEATS улавливает восходящий тренд

На коротком ряде ($N=174$) N-BEATS втрое точнее Seasonal Naive за счёт корректного захвата восходящего тренда. Ряд D2361 возвращает нас к режиму длинной серии, но с другой архитектурной победительницей.




Рисунок 43. Ряд D2361 ($N=4193$): DLinear и PatchTST точнее классических моделей

На длинной серии DLinear (1.4 %) и PatchTST (2.1 %) значительно опережают классические модели. Ряд D4166 показывает работу TimesNet на нестационарном паттерне.




Рисунок 44. Ряд D4166 ($N=327$): TimesNet моделирует нестационарный паттерн

TimesNet (4.3 %) втрое точнее Seasonal Naive — пример, где 2D-декомпозиция корректно моделирует нестационарный паттерн. Завершают подборку два ряда умеренной длины.



Рисунок 45. Ряд D4121 ($N=268$)

PatchTST (1.0 %) и N-BEATS (1.3 %) точнее S. Naive (3.0 %) при умеренной длине обучающей выборки. Последний пример — ряд D1816, на котором длина выборки уже близка к критическому порогу.



Рисунок 46. Ряд D1816 ($N=93$)

Представленные примеры демонстрируют, что нейросетевые модели побеждают на рядах с нестационарными паттернами (смена тренда, нелинейная сезонность), где статистические подходы неизбежно воспроизводят устаревшие паттерны. Ключевые наблюдения:

- На длинных рядах ($N > 500$) нейросети побеждают за счёт обучаемости на нестационарных структурах (D1117, D2361).
- На рядах умеренной длины ($N = 100-500$) выигрыш менее выражен, но N-BEATS и PatchTST систематически превосходят Seasonal Naive

(D2052, D4166).

- Autoformer и Helformer особенно эффективны на рядах с выраженной сезонностью (D1117), где декомпозиция серийного типа и фиксированная HW-декомпозиция корректно изолируют сезонную компоненту.

2.6. Выводы

Полученные результаты позволяют ответить на исследовательские вопросы, сформулированные во введении.

- На полном M3 Competition (2829 рядов) классические модели лидируют в целом: Seasonal Naive (15.74), ETS (16.04), Auto-ARIMA (16.14). TimesNet (17.65) — лучшая нейросетевая модель, отставая от Seasonal Naive менее чем на 2 п.п. На полной выборке M4 (1000 рядов на категорию) картина аналогична: Auto-ARIMA (12.51) и ETS (12.61) лидируют, TimesNet (14.29) ближе всего к классическим. Обучаемая декомпозиция (TimesNet, N-BEATS) становится конкурентоспособной при длине ряда свыше 80–100 наблюдений (M3 monthly, M4 daily).
- На коротких рядах лидируют ETS и Auto-ARIMA. Среди нейросетевых архитектур TimesNet с 2D-свертками и N-BEATS с residual-стеками показывают лучшие результаты, значительно превосходя трансформерные модели (Autoformer, FEDformer, PatchTST). Helformer конкурентоспособен на месячных рядах (17.98 на M3 monthly, 17.06 на M4 monthly), но числовая нестабильность на годовых рядах ограничивает его применимость.
- В per-series режиме — нет: PatchTST (ранг 6.83), Autoformer (ранг 9.33), FEDformer (ранг 10.33) проигрывают более простым N-BEATS (ранг 6.00) и TimesNet (ранг 4.17). Масштабный эксперимент с предобучением на шести частотах подтверждает, что нейросетевые архитектуры эффективны при наличии достаточного объёма данных: DLinear улучшается на +31.5 %, Autoformer — на +25.5 %. На M4 daily PatchTST с предобучением (2.36) показывает лучший абсолютный результат среди всех моделей, превосходя Auto-ARIMA (3.22) и ETS (3.46).
- На годовых рядах любая обучаемая декомпозиция проигрывает фиксированной; на квартальных обучаемая 2D-декомпозиция TimesNet вы-

ходит на уровень ETS; на ежедневных рядах все нейросетевые модели конкурентоспособны с классическими подходами.

- Эксперименты показывают критическую границу порядка 50–100 наблюдений. Ниже этого порога нейросетевые модели систематически уступают статистическим. Выше — разрыв сокращается и на отдельных категориях (M3 monthly, M4 daily) исчезает. Предобучение на корпусе рядов позволяет эффективно сдвинуть эту границу вниз.

Систематический эксперимент с предобучением на шести частотных категориях (M3 yearly/quarterly/monthly, M4 quarterly/monthly/daily) и семи моделях выявил дифференцированный эффект переноса знаний. DLinear показывает наибольший средний выигрыш (+31.5 %), трансформируясь из худшей нейросетевой модели в конкурентоспособную. Autoformer (+25.5 %) получает значительное улучшение, особенно на M4 daily (+30.9 %) и M4 quarterly (+40.0 %). TimesNet, напротив, в среднем ухудшается (−9.0 %) на коротких рядах, но улучшается на длинных (M3 monthly: +13.0 %, M4 daily: +13.5 %), что свидетельствует о пороговой зависимости эффекта предобучения от длины ряда.

Наиболее значимым результатом предобучения является превосходство нейросетевых моделей над классическими на двух крупных категориях:

- *M3 monthly (1428 рядов)*: TimesNet PT (13.68) побеждает ETS (17.42) и Auto-ARIMA (18.14) на 3.7–4.5 п.п. DLinear PT (13.98) и Autoformer PT (15.10) также превосходят все три классические модели.
- *M4 daily (1000 рядов)*: 6 из 7 предобученных нейросетей побеждают все три классические модели. PatchTST PT (2.36) и DLinear PT (2.44) лидируют, превосходя Auto-ARIMA (3.22) на 0.8–0.9 п.п. TimesNet PT (2.46) и Autoformer PT (2.81) также выигрывают. Только FEDformer PT (4.16) не достигает уровня Auto-ARIMA.

Эти результаты подтверждают центральную гипотезу работы: дефицит данных, а не архитектурные ограничения, является главным препятствием для глубоких моделей прогнозирования. При наличии достаточного корпуса для предобучения нейросетевые модели не только сокращают разрыв с классическими, но и уверенно превосходят их на длинных рядах.

Заключение

Настоящая работа была посвящена исследованию условий, при которых обучаемая декомпозиция временных рядов на компоненты и нейросетевые механизмы учета долгосрочных зависимостей дают практическое преимущество по сравнению с фиксированными статистическими подходами, а также ситуаций, в которых более простые методы оказываются предпочтительнее. Для ответа на этот вопрос был разработан масштабный экспериментальный контур, включающий 11 моделей (4 классические, 7 нейросетевых) и 5829 временных рядов из наборов M3 Competition (2829 рядов: 645 yearly, 756 quarterly, 1428 monthly) и M4 Competition (3000 рядов: 1000 quarterly, 1000 monthly, 1000 daily). Эксперимент охватывает прямое прогнозирование, итеративный режим и предобучение на корпусе рядов.

Основные результаты работы можно сформулировать следующим образом.

1. Классические модели лидируют в per-series режиме, но нейросетевые конкурентоспособны на длинных рядах. На полном M3 Competition (2829 рядов) Seasonal Naïve (15.74 %), ETS (16.04 %) и Auto-ARIMA (16.14 %) лидируют по среднему взвешенному sMAPE. TimesNet (17.65 %) — лучшая нейросетевая модель, отставая от Seasonal Naïve менее чем на 2 п.п. На M4 Competition (1000 рядов на категорию) картина аналогична: Auto-ARIMA (12.51 %) и ETS (12.61 %) лидируют, TimesNet (14.29 %) ближе всего к классическим. Однако на ежедневных рядах M4 (длина до 9919 наблюдений) TimesNet (3.62 %) уступает Auto-ARIMA (3.22 %) лишь на 0.4 п.п., а PatchTST (4.44 %), N-BEATS (4.46 %) и Helformer (4.49 %) демонстрируют сопоставимые результаты.

2. Длина ряда является критическим фактором для нейросетевых моделей. Экспериментально установлена граница порядка 50–100 наблюдений, ниже которой нейросетевые модели систематически уступают статистическим, а выше — становятся конкурентоспособными. На месячных рядах M3 (~126 наблюдений) Helformer (17.98 %) и N-BEATS (18.26 %) сопоставимы с ETS (17.42 %). На ежедневных рядах M4 (до 9919 наблюдений) все нейросетевые модели конкурентоспособны с классическими.

3. Предобучение кардинально повышает качество нейросетевых

моделей. Масштабный эксперимент с предобучением на шести частотных категориях (M3 yearly/quarterly/monthly, M4 quarterly/monthly/daily) и семи моделях выявил дифференцированный эффект переноса знаний. DLinear показывает наибольший средний выигрыш (+31.5 %), Autoformer — +25.5 %, Helformer — +18.2 %. На M4 daily PatchTST с предобучением (2.36 %) превосходит Auto-ARIMA (3.22 %) и ETS (3.46 %), демонстрируя, что при наличии корпуса однородных рядов нейросетевые модели способны превзойти классические. TimesNet, напротив, деградирует при предобучении на коротких рядах (–52.6 % на M3 yearly), но улучшается на длинных (M4 daily: +13.5 %), что свидетельствует о пороговой зависимости эффекта предобучения от длины ряда.

4. Обучаемая декомпозиция эффективна при достаточном объёме данных. Модели с обучаемой декомпозицией (TimesNet, N-BEATS) демонстрируют переход от неэффективной к конкурентоспособной при увеличении длины ряда. TimesNet с двумерной декомпозицией (средний ранг 4.17) входит в четвёрку лидеров на пяти из шести категорий, уступая лишь классическим моделям. Трансформерные модели с обучаемой декомпозицией серийного типа (Autoformer, FEDformer) оказались наименее эффективными в per-series режиме (средний ранг 9.33 и 10.33), однако при предобучении значительно улучшаются.

5. Итеративное прогнозирование выявляет хрупкость обучаемой декомпозиции. При переходе от прямого к итеративному прогнозированию модели с обучаемой декомпозицией демонстрируют наибольшую деградацию: FEDformer +5.01 п.п., TimesNet +5.16 п.п. PatchTST (+2.18 п.п.), работающий с патчами без явной декомпозиции, оказался наиболее устойчивым трансформером. Классические модели (ETS, Auto-ARIMA) практически нечувствительны к режиму прогнозирования.

На основании полученных результатов можно сформулировать следующие **практические рекомендации**:

- для одномерных рядов с выраженной сезонностью при малом объёме данных (<100 наблюдений) ETS и Auto-ARIMA являются лучшим выбором;
- при длине ряда свыше 100 наблюдений целесообразно рассмотреть TimesNet или N-BEATS как альтернативу классическим моделям, осо-

бенно при наличии нелинейных паттернов;

- при наличии корпуса однородных рядов предобучение нейросетевых моделей (особенно DLinear, Autoformer, Heforner) даёт значительное улучшение (+18–32 %), что делает их конкурентоспособными и превосходящими классические подходы;
- для задач, требующих итеративного прогнозирования, следует отдавать предпочтение моделям без сложной обучаемой декомпозиции (PatchTST, DLinear) или классическим подходам;
- тип декомпозиции должен соответствовать режиму обучения: фиксированная декомпозиция (ETS, DLinear) наиболее устойчива, обучаемая (TimesNet, Autoformer) — наиболее адаптивна при достаточном объёме данных.

Таким образом, проведённое исследование показывает, что ответ на вопрос о превосходстве обучаемой декомпозиции не является бинарным: эффективность нейросетевых механизмов критически зависит от длины ряда, режима обучения и доступного объёма данных. Предобучение на корпусе рядов позволяет эффективно преодолеть порог минимальной длины и вывести нейросетевые модели на уровень, превосходящий классические подходы.

Список литературы

1. Hamilton J.D. Time Series Analysis / J.D. Hamilton. – Princeton, NJ: Princeton University Press, 1994. – 799 p.
2. Makridakis S. The M3-Competition: Results, Conclusions and Implications / S. Makridakis, M. Hibon // International Journal of Forecasting. – 2000. – Vol. 16, no. 4. – P. 451–476. – DOI: 10.1016/S0169-2070(00)00057-1.
3. Makridakis S. The M4 Competition: 100,000 Time Series and 61 Forecasting Methods / S. Makridakis, E. Spiliotis, V. Assimakopoulos // International Journal of Forecasting. – 2020. – Vol. 36, no. 1. – P. 54–74. – DOI: 10.1016/j.ijforecast.2019.04.014.
4. Box G.E.P. Time Series Analysis: Forecasting and Control / G.E.P. Box, G.M. Jenkins. – San Francisco: Holden-Day, 1970. – 553 p.
5. Beveridge S. A New Approach to Decomposition of Economic Time Series into Permanent and Transitory Components with Particular Attention to Measurement of the “Business Cycle” / S. Beveridge, C.R. Nelson // Journal of Monetary Economics. – 1981. – Vol. 7, no. 2. – P. 151–174. – DOI: 10.1016/0304-3932(81)90040-4.
6. Wold H. A Study in the Analysis of Stationary Time Series / H. Wold. – Uppsala: Almqvist & Wiksells, 1938. – 214 p.
7. Hyndman R.J. Forecasting: Principles and Practice / R.J. Hyndman, G. Athanasopoulos. – 3rd ed. – Melbourne, Australia: OTexts, 2021. – 442 p.
8. Goodfellow I. Deep Learning / I. Goodfellow, Y. Bengio, A. Courville. – Cambridge, MA: MIT Press, 2016. – 775 p.
9. Hyndman R.J. Another Look at Measures of Forecast Accuracy / R.J. Hyndman, A.B. Koehler // International Journal of Forecasting. – 2006. – Vol. 22, no. 4. – P. 679–688. – DOI: 10.1016/j.ijforecast.2006.03.001.
10. Hyndman R.J. Forecasting with Exponential Smoothing: The State Space Approach / R.J. Hyndman, A.B. Koehler, J.K. Ord, R.D. Snyder. – Berlin, Heidelberg: Springer, 2008. – 362 p. – DOI: 10.1007/978-3-540-71918-2.

11. Holt C.C. Forecasting Seasonals and Trends by Exponentially Weighted Moving Averages / C.C. Holt // International Journal of Forecasting. – 2004. – Vol. 20, no. 1. – P. 5–10. – DOI: 10.1016/j.ijforecast.2003.09.015.
12. Winters P.R. Forecasting Sales by Exponentially Weighted Moving Averages / P.R. Winters // Management Science. – 1960. – Vol. 6, no. 3. – P. 324–342. – DOI: 10.1287/mnsc.6.3.324.
13. Hyndman R.J. A State Space Framework for Automatic Forecasting Using Exponential Smoothing Methods / R.J. Hyndman, A.B. Koehler, R.D. Snyder, S. Grose // International Journal of Forecasting. – 2002. – Vol. 18, no. 3. – P. 439–454. – DOI: 10.1016/S0169-2070(01)00110-8.
14. De Livera A.M. Forecasting Time Series with Complex Seasonal Patterns Using Exponential Smoothing / A.M. De Livera, R.J. Hyndman, R.D. Snyder // Journal of the American Statistical Association. – 2011. – Vol. 106, no. 496. – P. 1513–1527. – DOI: 10.1198/jasa.2011.tm09771.
15. Smyl S. A Hybrid Method of Exponential Smoothing and Recurrent Neural Networks for Time Series Forecasting / S. Smyl // International Journal of Forecasting. – 2020. – Vol. 36, no. 1. – P. 75–85. – DOI: 10.1016/j.ijforecast.2019.03.017.
16. Taylor S.J. Forecasting at Scale / S.J. Taylor, B. Letham // The American Statistician. – 2018. – Vol. 72, no. 1. – P. 37–45. – DOI: 10.1080/00031305.2017.1380080.
17. Айвазян С.А. Прикладная статистика и основы эконометрики / С.А. Айвазян, В.С. Мхитарян. – Москва: ЮНИТИ-ДАНА, 1998.
18. Cleveland R.B. STL: A Seasonal-Trend Decomposition Procedure Based on Loess / R.B. Cleveland, W.S. Cleveland, J.E. McRae, I. Terpenning // Journal of Official Statistics. – 1990. – Vol. 6, no. 1. – P. 3–33.
19. Percival D.B. Wavelet Methods for Time Series Analysis / D.B. Percival, A.T. Walden. – Cambridge: Cambridge University Press, 2000. – 594 p. – DOI: 10.1017/CBO9780511841040.

20. Percival D.B. On Estimation of the Wavelet Variance / D.B. Percival // *Biometrika*. – 1995. – Vol. 82, no. 3. – P. 619–631. – DOI: 10.1093/biomet/82.3.619.
21. Zeng A. Are Transformers Effective for Time Series Forecasting? / A. Zeng, M. Chen, L. Zhang, Q. Xu // *Proceedings of the AAAI Conference on Artificial Intelligence*. – 2023. – Vol. 37, no. 9. – P. 11121–11128. – DOI: 10.1609/aaai.v37i9.26317.
22. Oreshkin B.N. N-BEATS: Neural Basis Expansion Analysis for Interpretable Time Series Forecasting [Электронный ресурс] / B.N. Oreshkin, D. Carpow, N. Chapados, Y. Bengio. – 2020. – Режим доступа: <https://openreview.net/forum?id=r1ecqn4YwB> (дата обращения: 25.02.2026), свободный.
23. Wu H. Autoformer: Decomposition Transformers with Auto-Correlation for Long-Term Series Forecasting [Электронный ресурс] / H. Wu, J. Xu, J. Wang, M. Long. – 2021. – Режим доступа: <https://proceedings.neurips.cc/paper/2021/hash/bcc0d400288793e8bdcd7c19a8ac0f2> Abstract.html (дата обращения: 25.02.2026), свободный.
24. Zhou T. FEDformer: Frequency Enhanced Decomposed Transformer for Long-term Series Forecasting / T. Zhou, Z. Ma, Q. Wen, X. Wang, L. Sun, R. Jin // *Proceedings of the 39th International Conference on Machine Learning*. – 2022. – Vol. 162. – P. 27268–27286. – Режим доступа: <https://proceedings.mlr.press/v162/zhou22g.html> (дата обращения: 25.02.2026), свободный.
25. Wu H. TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis [Электронный ресурс] / H. Wu, T. Hu, Y. Liu, H. Zhou, J. Wang, M. Long. – 2023. – Режим доступа: https://openreview.net/forum?id=ju_Uqw384Oq (дата обращения: 25.02.2026), свободный.
26. Vaswani A. Attention Is All You Need [Электронный ресурс] / A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A.N. Gomez, Ł. Kaiser, I. Polosukhin. – 2017. – Режим доступа:

- <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845a>
Abstract.html (дата обращения: 25.02.2026), свободный.
27. He K. Deep Residual Learning for Image Recognition / K. He, X. Zhang, S. Ren, J. Sun // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. – 2016. – P. 770–778. – DOI: 10.1109/CVPR.2016.90.
 28. Ba J.L. Layer Normalization [Электронный ресурс] / J.L. Ba, J.R. Kiros, G.E. Hinton. – 2016. – arXiv:1607.06450 [stat.ML]. – Режим доступа: <https://arxiv.org/abs/1607.06450> (дата обращения: 25.02.2026), свободный.
 29. Hochreiter S. Long Short-Term Memory / S. Hochreiter, J. Schmidhuber // Neural Computation. – 1997. – Vol. 9, no. 8. – P. 1735–1780. – DOI: 10.1162/neco.1997.9.8.1735.
 30. Salinas D. DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks / D. Salinas, V. Flunkert, J. Gasthaus, T. Januschowski // International Journal of Forecasting. – 2020. – Vol. 36, no. 3. – P. 1181–1191. – DOI: 10.1016/j.ijforecast.2019.07.001.
 31. Zhou H. Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting / H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong, W. Zhang // Proceedings of the AAAI Conference on Artificial Intelligence. – 2021. – Vol. 35, no. 12. – P. 11106–11115. – DOI: 10.1609/aaai.v35i12.17325.
 32. Li S. Enhancing the Locality and Breaking the Memory Bottleneck of Transformer on Time Series Forecasting [Электронный ресурс] / S. Li, X. Jin, Y. Xuan, X. Zhou, W. Chen, Y.-X. Wang, X. Yan. – 2019. – Режим доступа: <https://proceedings.neurips.cc/paper/2019/hash/6775a0635c302542da2c32aa19d86b>
Abstract.html (дата обращения: 25.02.2026), свободный.
 33. Liu Y. Non-stationary Transformers: Exploring the Stationarity in Time Series Forecasting [Электронный ресурс] / Y. Liu, H. Wu, J. Wang, M. Long. – 2022. – Режим доступа: <https://openreview.net/forum?id=ucNDIDRNjjv> (дата обращения: 25.02.2026), свободный.

34. Lim B. Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting / B. Lim, S.Ö. Arık, N. Loeff, T. Pfister // International Journal of Forecasting. – 2021. – Vol. 37, no. 4. – P. 1748–1764. – DOI: 10.1016/j.ijforecast.2021.03.012.
35. Wen Q. Transformers in Time Series: A Survey / Q. Wen, T. Zhou, C. Zhang, W. Chen, Z. Ma, J. Yan, L. Sun // Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence. – 2023. – P. 6778–6786. – DOI: 10.24963/ijcai.2023/759.
36. Lim B. Time-Series Forecasting with Deep Learning: A Survey / B. Lim, S. Zohren // Philosophical Transactions of the Royal Society A. – 2021. – Vol. 379, no. 2194. – Art. 20200209. – DOI: 10.1098/rsta.2020.0209.
37. Torres J.F. Deep Learning for Time Series Forecasting: A Survey / J.F. Torres, D. Hadjout, A. Sebaa, F. Martínez-Álvarez, A. Troncoso // Big Data. – 2021. – Vol. 9, no. 1. – P. 3–21. – DOI: 10.1089/big.2020.0159.
38. Benidis K. Deep Learning for Time Series Forecasting: Tutorial and Literature Survey / K. Benidis, S.S. Rangapuram, V. Flunkert, Y. Wang, D. Maddix, C. Turkmen, J. Gasthaus, M. Bohlke-Schneider, D. Salinas, L. Stella, F.-X. Aubet, L. Callot, T. Januschowski // ACM Computing Surveys. – 2022. – Vol. 55, no. 6. – P. 1–36. – DOI: 10.1145/3533382.
39. Hewamalage H. Recurrent Neural Networks for Time Series Forecasting: Current Status and Future Directions / H. Hewamalage, C. Bergmeir, K. Bandara // International Journal of Forecasting. – 2021. – Vol. 37, no. 1. – P. 388–427. – DOI: 10.1016/j.ijforecast.2020.06.008.
40. Nie Y. A Time Series is Worth 64 Words: Long-term Forecasting with Transformers [Электронный ресурс] / Y. Nie, N.H. Nguyen, P. Sinthong, J. Kalagnanam. – 2023. – Режим доступа: <https://openreview.net/forum?id=Jbdc0vTOcol> (дата обращения: 25.02.2026), свободный.
41. Challu C. NHITS: Neural Hierarchical Interpolation for Time Series Forecasting / C. Challu, K.G. Olivares, B.N. Oreshkin, F. Garza Ramirez, M. Mergenthaler Canseco, A. Dubrawski // Proceedings of the AAAI

- Conference on Artificial Intelligence. – 2023. – Vol. 37, no. 6. – P. 6989–6997. – DOI: 10.1609/aaai.v37i6.25854.
42. Kehinde T.O. Helformer: An Attention-Based Deep Learning Model for Cryptocurrency Price Forecasting / T.O. Kehinde, O.J. Adedokun, O.A. Olanrewaju // Journal of Big Data. – 2025. – Vol. 12. – Art. 81. – DOI: 10.1186/s40537-025-01135-4.
43. Montero-Manso P. FFORMA: Feature-Based Forecast Model Averaging / P. Montero-Manso, G. Athanasopoulos, R.J. Hyndman, T.S. Talagala // International Journal of Forecasting. – 2020. – Vol. 36, no. 1. – P. 86–92. – DOI: 10.1016/j.ijforecast.2019.02.011.
44. Makridakis S. M5 Accuracy Competition: Results, Findings, and Conclusions / S. Makridakis, E. Spiliotis, V. Assimakopoulos // International Journal of Forecasting. – 2022. – Vol. 38, no. 4. – P. 1346–1364. – DOI: 10.1016/j.ijforecast.2021.11.013.
45. Godahewa R. Monash Time Series Forecasting Archive [Электронный ресурс] / R. Godahewa, C. Bergmeir, G.I. Webb, R.J. Hyndman, P. Montero-Manso. – 2021. – Режим доступа: <https://openreview.net/forum?id=wEc1mgAjU-> (дата обращения: 25.02.2026), свободный.
46. Bandara K. Forecasting Across Time Series Databases Using Recurrent Neural Networks on Groups of Similar Series: A Clustering Approach / K. Bandara, C. Bergmeir, S. Smyl // Expert Systems with Applications. – 2020. – Vol. 140. – Art. 112896. – DOI: 10.1016/j.eswa.2019.112896.
47. Kingma D.P. Adam: A Method for Stochastic Optimization [Электронный ресурс] / D.P. Kingma, J. Ba. – 2015. – Режим доступа: <https://arxiv.org/abs/1412.6980> (дата обращения: 25.02.2026), свободный.
48. Cerqueira V. Evaluating Time Series Forecasting Models: An Empirical Study on Performance Estimation Methods / V. Cerqueira, L. Torgo, I. Mozetič // Machine Learning. – 2020. – Vol. 109, no. 11. – P. 1997–2028. – DOI: 10.1007/s10994-020-05910-7.

49. Liu Y. iTransformer: Inverted Transformers Are Effective for Time Series Forecasting [Электронный ресурс] / Y. Liu, T. Hu, H. Zhang, H. Wu, S. Wang, L. Ma, M. Long. – 2024. – Режим доступа: <https://openreview.net/forum?id=JePfAI8fah> (дата обращения: 25.02.2026), свободный.