

Оглавление

Введение	4
Глава 1. Обзор подходов к прогнозированию временных рядов	5
1.1 Временные ряды и задача прогнозирования	5
1.1.1 Основные определения	5
1.1.2 Постановка задачи прогнозирования	6
1.1.3 Метрики качества прогноза	7
1.2 Классические статистические модели	8
1.2.1 Модели ARIMA и SARIMA	8
1.2.2 Модели экспоненциального сглаживания (ETS)	10
1.2.3 Модель Prophet	11
1.3 Декомпозиция временных рядов	12
1.3.1 Фиксированная декомпозиция	12
1.3.2 Обучаемая декомпозиция	13
1.4 Нейросетевые модели для временных рядов	15
1.4.1 Механизм внимания и архитектура трансформера	15
1.4.2 Autoformer	17
1.4.3 FEDformer	18
1.4.4 PatchTST	18
1.4.5 DLinear	19
1.4.6 N-BEATS	20
1.4.7 TimesNet	21
1.4.8 Helformer	22
1.4.9 Итоги сравнительного анализа моделей	23
1.5 Соревнования по прогнозированию временных рядов	26
1.6 Выводы по обзору и обоснование структуры эксперимента	27
Глава 2. Экспериментальное исследование	30
2.1 Постановка эксперимента	30
2.1.1 Данные	30
2.1.2 Модели и их конфигурация	31
2.1.3 Протокол оценки	32
2.2 Прямое сравнение моделей	32
2.2.1 Диагностика на синтетических рядах	32

Заключение	62
-----------------------------	-----------

Введение

Прогнозирование временных рядов является одной из центральных задач в анализе данных, финансовой аналитике, управлении запасами и планировании ресурсов. Классические статистические модели (ARIMA, ETS, Prophet) на протяжении десятилетий оставались стандартом для краткосрочного прогноза. В последние годы были предложены нейросетевые архитектуры, явно включающие механизмы обучаемой декомпозиции рядов на компоненты (тренд, сезонность, остаток) и модули учёта долгосрочных зависимостей на основе внимания, свёрток и линейных проекций.

Настоящая работа посвящена исследованию условий, при которых обучаемая декомпозиция и нейросетевые механизмы учёта долгосрочных зависимостей дают практическое преимущество по сравнению с фиксированными статистическими подходами, и ситуаций, в которых более простые методы оказываются предпочтительнее. В качестве экспериментальной базы используются данные соревнований M3 и M4, а в качестве моделей - ARIMA, ETS, Prophet, N-BEATS, DLinear, Autoformer, TimesNet и Helformer.

Глава 1. Обзор подходов к прогнозированию временных рядов

1.1. Временные ряды и задача прогнозирования

1.1.1. Основные определения

Временным рядом называют упорядоченную последовательность наблюдений $\{y_t\}_{t=1}^T$, где каждому значению y_t поставлен в соответствие момент времени t , а наблюдения следуют через равные или нерегулярные промежутки [hamilton1994time]. В большинстве практических задач прогнозирования рассматриваются равноотстоящие ряды: ежемесячные, ежеквартальные, ежегодные наблюдения макроэкономических, финансовых или промышленных показателей. Каждый элемент ряда может быть вещественным числом (одномерный ряд) или вектором (многомерный, или многоканальный ряд); в данной работе основное внимание уделяется одномерному случаю, поскольку именно он является стандартным объектом соревнований M3 и M4 [makridakis2000m3; makridakis2020m4].

Свойством, определяющим пригодность ряда к статистическому моделированию, является стационарность. Временной ряд называют *строго стационарным*, если совместное распределение любого конечного набора $\{y_{t_1}, y_{t_2}, \dots, y_{t_k}\}$ не изменяется при сдвиге всех индексов на величину τ . На практике чаще используется более слабое условие: ряд считается *слабо стационарным* (стационарным в широком смысле), если его математическое ожидание $\mu = \mathbb{E}[y_t]$ постоянно, дисперсия $\sigma^2 = \text{Var}(y_t)$ конечна и не зависит от t , а автоковариационная функция зависит только от лага:

$$\gamma(h) = \text{Cov}(y_t, y_{t+h}) = \mathbb{E}[(y_t - \mu)(y_{t+h} - \mu)]. \quad (1)$$

Нормируя $\gamma(h)$ на $\gamma(0) = \sigma^2$, получают *автокорреляционную функцию* (АКФ) $\rho(h) = \gamma(h)/\gamma(0)$, играющую центральную роль при подборе порядков моделей класса ARIMA [box1970time].

Реальные экономические и промышленные ряды почти всегда нестационарны: они содержат тренд, сезонную составляющую и гетероскедастичность. Одним из стандартных средств приведения к стационарности служит

оператор разности:

$$\Delta y_t = y_t - y_{t-1}, \quad \Delta^d y_t = \Delta^{d-1}(\Delta y_t). \quad (2)$$

Для устранения сезонности с периодом s вводят сезонный разностный оператор $\Delta_s y_t = y_t - y_{t-s}$. Как показано в [box1970time], сочетание обычного и сезонного дифференцирования позволяет привести широкий класс рядов к виду, пригодному для построения линейных стационарных моделей. Формальное обоснование разложения нестационарных процессов на постоянную и транзиторную компоненты дано в работе Бевериджа и Нельсона [beveridge1981decomposition], а представление стационарного процесса как бесконечной скользящей средней — в теореме Вольда [wold1938study].

1.1.2. Постановка задачи прогнозирования

Задачу точечного прогнозирования временного ряда можно сформулировать следующим образом. Пусть дана история наблюдений $\mathbf{y}_{1:L} = (y_1, y_2, \dots, y_L)$, где L — длина входного окна. Требуется построить отображение

$$f_\theta: \mathbb{R}^L \rightarrow \mathbb{R}^H, \quad \hat{\mathbf{y}}_{L+1:L+H} = f_\theta(\mathbf{y}_{1:L}), \quad (3)$$

минимизирующее некоторую функцию потерь между прогнозом $\hat{\mathbf{y}}_{L+1:L+H}$ и реальными будущими значениями $\mathbf{y}_{L+1:L+H}$, где H — горизонт прогноза, а θ — параметры модели [hyndman2021forecasting].

Для оценки качества используют схему фиксированного разделения: последние H точек ряда отделяются в тестовую выборку, а предшествующие L точек (или весь доступный до них отрезок) составляют обучающую часть. В соревнованиях M3 [makridakis2000m3] и M4 [makridakis2020m4] горизонт прогнозирования варьируется в зависимости от частоты наблюдений: $H = 6$ для годовых рядов, $H = 8$ для квартальных и $H = 18$ для месячных. Такая стандартизация позволяет сопоставлять различные методы в единых условиях.

В статистических моделях параметры θ оцениваются методом максимального правдоподобия или моментами, а в нейросетевых — методом стохастической градиентной оптимизации. Различие в парадигмах оценки параметров оказывает существенное влияние на поведение моделей при ограни-

ченном объёме данных и является одной из центральных тем данной работы.

1.1.3. Метрики качества прогноза

Для сравнения прогнозных моделей применяют ряд метрик, каждая из которых имеет свои достоинства и ограничения.

Средняя абсолютная ошибка (MAE):

$$\text{MAE} = \frac{1}{H} \sum_{t=1}^H |y_t - \hat{y}_t|. \quad (4)$$

MAE выражена в единицах исходного ряда, что затрудняет сравнение рядов различного масштаба.

Среднеквадратическая ошибка (MSE) и её квадратный корень (RMSE):

$$\text{MSE} = \frac{1}{H} \sum_{t=1}^H (y_t - \hat{y}_t)^2, \quad \text{RMSE} = \sqrt{\text{MSE}}. \quad (5)$$

MSE штрафует большие отклонения сильнее, чем MAE, и широко используется как функция потерь при обучении нейронных сетей [goodfellow2016deep].

Средняя абсолютная процентная ошибка (MAPE):

$$\text{MAPE} = \frac{100\%}{H} \sum_{t=1}^H \frac{|y_t - \hat{y}_t|}{|y_t|}. \quad (6)$$

MAPE масштабно-инвариантна, однако не определена при $y_t = 0$ и асимметрична: одинаковые по абсолютной величине перепрогноз и недопрогноз дают разные процентные значения.

Симметричная MAPE (sMAPE):

$$\text{sMAPE} = \frac{200\%}{H} \sum_{t=1}^H \frac{|y_t - \hat{y}_t|}{|y_t| + |\hat{y}_t|}. \quad (7)$$

sMAPE была выбрана в качестве основной метрики соревнования M3 [makridakis2000m3] благодаря симметрии относительно знака ошибки и ограниченности сверху величиной 200%. Тем не менее sMAPE критиковалась за смещённость к прогнозам, занижающим значе-

ния [hyndman2006accuracy].

Средняя абсолютная масштабированная ошибка (MASE):

$$\text{MASE} = \frac{1}{H} \sum_{t=1}^H \frac{|y_t - \hat{y}_t|}{\frac{1}{T-m} \sum_{j=m+1}^T |y_j - y_{j-m}|}, \quad (8)$$

где T — длина обучающей части, а m — период сезонности (для несезонных рядов $m = 1$). MASE была предложена Хиндманом и Кёлером [hyndman2006accuracy] как масштабно-инвариантная альтернатива MAPE и sMAPE. Её знаменатель представляет собой среднюю абсолютную ошибку наивного сезонного прогноза, вычисленную на обучающих данных. Значение $\text{MASE} < 1$ означает, что модель прогнозирует лучше наивного метода. В данной работе MASE и sMAPE используются совместно для обеспечения сопоставимости с результатами M3 и M4.

1.2. Классические статистические модели

1.2.1. Модели ARIMA и SARIMA

Семейство моделей ARIMA является, по-видимому, наиболее широко используемым классом линейных моделей временных рядов [box1970time]. Построение модели осуществляется в рамках методологии Бокса–Дженкинса, включающей три этапа: идентификацию порядков, оценку параметров и диагностику остатков.

Процесс авторегрессии порядка p , обозначаемый $\text{AR}(p)$, определяется рекуррентным соотношением

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \quad (9)$$

где c — константа, $\phi_1, \dots, \phi_p$ — авторегрессионные коэффициенты, а ε_t — белый шум с нулевым средним и конечной дисперсией σ^2 . Для стационарности процесса необходимо и достаточно, чтобы все корни характеристического полинома $\Phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p$ лежали вне единичного круга [hamilton1994time].

Процесс скользящего среднего порядка q , $MA(q)$, задаётся формулой

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}, \quad (10)$$

где $\theta_1, \dots, \theta_q$ — параметры скользящего среднего. Условие обратимости аналогично: корни полинома $\Theta(z) = 1 + \theta_1 z + \dots + \theta_q z^q$ должны лежать вне единичного круга.

Объединяя оба процесса, получают модель $ARMA(p, q)$, а применяя к исходному ряду оператор разности порядка d , получают модель $ARIMA(p, d, q)$. В операторной записи:

$$\Phi(B)(1 - B)^d y_t = c + \Theta(B) \varepsilon_t, \quad (11)$$

где B — оператор обратного сдвига, $B y_t = y_{t-1}$.

Для рядов с выраженной сезонностью периода s применяют обобщение — модель $SARIMA(p, d, q)(P, D, Q)_s$:

$$\Phi_p(B) \tilde{\Phi}_P(B^s) (1 - B)^d (1 - B^s)^D y_t = c + \Theta_q(B) \tilde{\Theta}_Q(B^s) \varepsilon_t, \quad (12)$$

где $\tilde{\Phi}_P$ и $\tilde{\Theta}_Q$ — полиномы сезонных авторегрессионного и скользящего среднего компонентов соответственно [box1970time].

Традиционно подбор порядков (p, d, q) осуществляется путём анализа автокорреляционной (АКФ) и частной автокорреляционной (ЧАКФ) функций, однако для массового прогнозирования сотен и тысяч рядов, как в соревнованиях M3 и M4, ручной подбор непрактичен. Автоматический алгоритм `auto_arima`, реализованный в пакете `forecast` для R и в библиотеке `pmdarima` для Python, осуществляет последовательный перебор моделей с минимизацией информационного критерия AICc [hyndman2008expsmoothing]. Этот подход используется в данной работе в качестве одного из классических базовых методов.

Результаты соревнований M3 [makridakis2000m3] и M4 [makridakis2020m4] убедительно продемонстрировали, что ARIMA-модели, особенно в автоматизированном варианте, остаются конкурентоспособными для широкого класса рядов. В M3 автоматическая ARIMA уступила методам экспоненциального сглаживания лишь на доли процента по sMAPE, а в M4 вошла

в группу сильнейших статистических методов. Это объясняется тем, что ARIMA хорошо описывает локальную линейную динамику и сезонную структуру, тогда как при коротких рядах и умеренном горизонте преимущество более сложных моделей нивелируется дисперсией оценок.

1.2.2. Модели экспоненциального сглаживания (ETS)

Метод экспоненциального сглаживания был впервые описан Холтом в 1957 году [**holt2004forecasting**] для рядов с линейным трендом и распространён Уинтерсом [**winters1960forecasting**] на случай сезонности. В простейшей форме (*простое экспоненциальное сглаживание*, SES) прогноз строится по рекуррентному правилу:

$$\hat{y}_{t+1|t} = \ell_t, \quad \ell_t = \alpha y_t + (1 - \alpha) \ell_{t-1}, \quad 0 < \alpha < 1, \quad (13)$$

где ℓ_t — уровень ряда, а α — параметр сглаживания.

Метод Холта добавляет компоненту линейного тренда:

$$\begin{aligned} \ell_t &= \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1}), \\ b_t &= \beta (\ell_t - \ell_{t-1}) + (1 - \beta) b_{t-1}, \\ \hat{y}_{t+h|t} &= \ell_t + h b_t, \end{aligned} \quad (14)$$

где b_t — оценка наклона тренда, β — параметр сглаживания тренда.

Метод Холта–Уинтерса расширяет модель сезонной компонентой s_t с периодом m :

$$\begin{aligned} \ell_t &= \alpha (y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1}), \\ b_t &= \beta (\ell_t - \ell_{t-1}) + (1 - \beta) b_{t-1}, \\ s_t &= \gamma (y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma) s_{t-m}, \\ \hat{y}_{t+h|t} &= \ell_t + h b_t + s_{t+h-m}, \end{aligned} \quad (15)$$

где формулы (15) соответствуют аддитивной сезонности. Мультипликативный вариант заменяет вычитание делением и сложение умножением. Хиндман и др. [**hyndman2002ets**] систематизировали все 30 возможных конфигураций экспоненциального сглаживания в рамках единой модели пространства состояний, введя обозначение ETS(ошибка, тренд, сезонность).

Здесь каждая компонента принимает одно из значений: аддитивная (A), мультипликативная (M) или отсутствует (N), а тренд дополнительно может быть демпфированным (A_d , M_d). Это позволяет автоматически выбирать оптимальную модель из всех конфигураций по информационному критерию [hyndman2008expsmoothing].

Принципиальное отличие ETS от ARIMA состоит в том, что ETS *явно разделяет* ряд на компоненты уровня, тренда и сезонности ещё на этапе спецификации модели. Это делает ETS формой *фиксированной декомпозиции*: структура компонент (аддитивная или мультипликативная) задаётся до обучения, а не выучивается из данных. Позднее де Ливера и др. [delivera2011tbats] расширили ETS до модели TBATS, способной работать с множественными сезонностями и преобразованием Бокса–Кокса, однако базовый принцип фиксированной декомпозиции сохранился.

Конкурентоспособность ETS убедительно подтверждена результатами соревнований. В M3 [makridakis2000m3] модель Холта–Уинтерса с демпфированным трендом показала наилучшую среднюю sMAPE среди всех участников. В M4 [makridakis2020m4] чистые статистические методы — ETS и ARIMA — оставались в числе лучших индивидуальных подходов, а победитель (ES-RNN) [smyl2020hybrid] объединил экспоненциальное сглаживание с рекуррентной сетью, что лишь подтвердило важность ETS-компоненты. Этот факт задаёт высокую планку для любых нейросетевых архитектур, претендующих на улучшение прогноза.

1.2.3. Модель Prophet

Модель Prophet, разработанная Тейлором и Летамом [taylor2018prophet], представляет ряд как аддитивную комбинацию трёх компонент:

$$y_t = g(t) + s(t) + h(t) + \varepsilon_t, \quad (16)$$

где $g(t)$ — трендовая составляющая, $s(t)$ — сезонность, $h(t)$ — эффект внешних событий (праздников), а ε_t — ошибка модели.

Тренд моделируется как кусочно-линейная функция с автоматически определяемыми точками перелома:

$$g(t) = (k + \mathbf{a}(t)^\top \boldsymbol{\delta}) t + (m + \mathbf{a}(t)^\top \boldsymbol{\gamma}), \quad (17)$$

где k — базовый наклон, δ — вектор поправок наклона в точках перелома, $\mathbf{a}(t)$ — вектор-индикатор принадлежности t к интервалам, а γ — поправки смещения для обеспечения непрерывности. Для рядов с насыщением (например, ёмкость рынка) предусмотрен логистический вариант тренда.

Сезонность представлена рядом Фурье:

$$s(t) = \sum_{n=1}^N \left(a_n \cos \frac{2\pi nt}{P} + b_n \sin \frac{2\pi nt}{P} \right), \quad (18)$$

где P — период (например, 365.25 для годовой сезонности), а N — число гармоник, контролирующих гладкость. Параметры a_n, b_n оцениваются совместно с трендом.

Prophet привлекателен простотой использования и устойчивостью к пропускам данных. Тем не менее в соревновательном контексте модель показывает умеренные результаты: на данных M4 Prophet заметно уступил лучшим методам [makridakis2020m4]. С точки зрения декомпозиции Prophet занимает промежуточное положение: тренд и сезонность разделяются аддитивно (как в ETS), но параметры тренда (точки перелома) и сезонности (коэффициенты Фурье) оцениваются из данных. При этом сама структура декомпозиции — аддитивная сумма кусочно-линейного тренда и ряда Фурье — задаётся заранее и не адаптируется в процессе обучения.

1.3. Декомпозиция временных рядов

1.3.1. Фиксированная декомпозиция

Идея разложения временного ряда на компоненты — тренд, сезонность и остаток — является одной из старейших в анализе временных рядов [aivazyan1998statistics]. Формально аддитивная декомпозиция записывается как

$$y_t = T_t + S_t + R_t, \quad (19)$$

где T_t — трендовая компонента, S_t — сезонная и R_t — остаточная. Мультипликативный вариант заменяет сложение умножением: $y_t = T_t \cdot S_t \cdot R_t$.

Наиболее распространённым методом фиксированной декомпозиции является процедура STL, предложенная Кливлендом и др. [cleveland1990stl]. STL последовательно извлекает сезонную компоненту с помощью локальной

регрессии (loess), оценивает тренд аналогичным образом и формирует остаток как разность. Процедура итеративно уточняет оценки, используя робастные веса для подавления выбросов. Параметры STL — ширина окна для сезонного сглаживания, ширина окна для тренда и число итераций — задаются пользователем, но не обучаются из данных.

Метод Холта–Уинтерса (раздел 1.2.2) также может рассматриваться как форма неявной декомпозиции: рекуррентные уравнения для ℓ_t , b_t и s_t фактически разделяют ряд на уровень, тренд и сезонность. Однако тип взаимодействия компонент (аддитивный или мультипликативный) фиксируется при спецификации модели.

Ещё один класс фиксированных базисных функций представляют вейвлет-преобразования. В частности, максимально перекрывающееся дискретное вейвлет-преобразование (MODWT) [**percival2000wavelet**] раскладывает ряд по набору масштабов, каждый из которых соответствует определённому диапазону частот. Вейвлет-коэффициенты различных уровней могут использоваться как входные признаки для прогнозной модели [**percival1995wavelet**]. Однако базисные функции (вейвлеты Хаара, Добеши и др.) выбираются заранее и не адаптируются к конкретному ряду.

Общим свойством всех перечисленных методов является *фиксированная структура базисных функций*: скользящее среднее в STL, экспоненциальное взвешивание в ETS, конкретное семейство вейвлетов. Преимущество такого подхода — интерпретируемость и устойчивость при малом объёме данных. Недостаток — невозможность адаптировать базис к специфическим паттернам конкретного ряда.

1.3.2. Обучаемая декомпозиция

Переход от фиксированной к *обучаемой* декомпозиции составляет центральную тему настоящей работы. Под обучаемой декомпозицией понимается подход, в котором способ деления ряда на компоненты определяется не заранее заданными правилами, а параметрами, оптимизируемыми в процессе обучения модели.

Простейшим примером служит модель DLinear [**zeng2023transformers**], в которой декомпозиция осуществляется через скользящее среднее с ядром

фиксированного размера k :

$$T_t = \frac{1}{k} \sum_{i=-(k-1)/2}^{(k-1)/2} y_{t+i}, \quad S_t = y_t - T_t. \quad (20)$$

Хотя само ядро скользящего среднего не содержит обучаемых параметров, два отдельных линейных слоя, применяемых к T_t и S_t , фактически учатся проецировать каждую компоненту в прогноз. Тем самым модель определяет, какой вклад вносят тренд и сезонность, на основе данных.

Более развитый подход реализован в архитектуре N-BEATS [oreshkin2020nbeats] где каждый блок порождает *обучаемое базисное разложение*. В интерпретируемой конфигурации трендовый блок использует полиномиальный базис, а сезонный — гармонический, но коэффициенты этих базисов вычисляются полносвязной сетью на основе входных данных. Таким образом, модель адаптирует форму трендовой и сезонной компонент к конкретному ряду.

Архитектура Autoformer [wu2021autoformer] вводит *прогрессивную декомпозицию*: на каждом уровне кодировщика и декодировщика применяется блок скользящего среднего, разделяющий промежуточное представление на трендовую и сезонную части. Декомпозиция повторяется на каждом слое, позволяя модели итеративно уточнять разделение.

FEDformer [zhou2022fedformer] переносит декомпозицию в частотную область: блоки внимания работают с подмножеством частот Фурье или вейвлет-коэффициентов, отбирая наиболее значимые моды. Выбор частотных компонент осуществляется обучаемо, что позволяет сети сосредоточиться на доминирующих периодичностях.

TimesNet [wu2023timesnet] реализует неявную декомпозицию через преобразование одномерного ряда в набор двумерных представлений, соответствующих различным периодам. Доминирующие периоды определяются с помощью быстрого преобразования Фурье (БПФ), после чего для каждого периода ряд перестраивается в двумерный тензор и обрабатывается свёрточными блоками. Такой подход позволяет извлекать признаки на нескольких масштабах одновременно.

Таким образом, в современных нейросетевых архитектурах для временных рядов прослеживается общая тенденция: декомпозиция перестаёт быть предобработкой с фиксированным базисом и становится обучаемым

компонентом модели. Однако открытым остаётся вопрос, *в каких условиях* обучаемая декомпозиция действительно даёт преимущество по сравнению с фиксированной, а в каких — приводит к переобучению или избыточной сложности, особенно при ограниченном объёме данных, характерном для индивидуального прогнозирования отдельных рядов.

1.4. Нейросетевые модели для временных рядов

1.4.1. Механизм внимания и архитектура трансформера

Архитектура Transformer, предложенная Васвани и др. [vaswani2017attention], произвела революцию в обработке последовательностей. В основе архитектуры лежит механизм *масштабированного скалярного внимания*:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V, \quad (21)$$

где $Q \in \mathbb{R}^{n \times d_k}$ — матрица запросов, $K \in \mathbb{R}^{m \times d_k}$ — матрица ключей, $V \in \mathbb{R}^{m \times d_v}$ — матрица значений, а d_k — размерность ключей. Деление на $\sqrt{d_k}$ предотвращает попадание аргументов softmax в область насыщения.

Для повышения выразительности используют *многоголовое внимание*:

$$\begin{aligned} \text{MultiHead}(Q, K, V) &= \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O, \\ \text{head}_i &= \text{Attention}(QW_i^Q, KW_i^K, VW_i^V), \end{aligned} \quad (22)$$

где $W_i^Q, W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ и $W^O \in \mathbb{R}^{hd_v \times d_{\text{model}}}$ — обучаемые проекционные матрицы. Каждая «голова» вычисляет внимание в собственном подпространстве, что позволяет одновременно улавливать зависимости различной природы [vaswani2017attention].

Полный блок трансформера включает многоголовое внимание, позиционно-чувствительную полносвязную сеть, остаточные соединения [he2016resnet] и нормализацию слоя [ba2016layernorm]. Исходный Transformer использует позиционное кодирование на основе синусоид для учёта порядка элементов.

Применение трансформеров к временным рядам мотивировано их способностью явно моделировать зависимости между произвольно удалёнными отсчётами. В отличие от рекуррентных сетей (LSTM [hochreiter1997lstm],

GRU), где информация передаётся последовательно через скрытые состояния и может «затухать» на длинных последовательностях, механизм внимания устанавливает прямые связи между любыми позициями входа. Следует отметить, что ещё до широкого распространения трансформеров в задачах прогнозирования важную роль сыграли рекуррентные модели вероятностного прогнозирования, в частности DeepAR [salinas2020deepar], генерирующая не точечные прогнозы, а параметры условного распределения будущих значений на каждом шаге авторегрессии.

Однако стандартный механизм внимания имеет вычислительную сложность $O(n^2)$ по длине последовательности, что делает его дорогим для длинных рядов. Для решения этой проблемы были предложены архитектуры с разреженным вниманием. Informer [zhou2021informer] использует механизм ProbSparse attention, выбирающий наиболее информативные запросы по оценке KL-дивергенции и снижающий сложность до $O(n \log n)$. LogTrans [li2019enhancing] применяет разреженное внимание с логарифмическим шаблоном разреженности, позволяя каждому элементу обращаться лишь к экспоненциально удалённым предшественникам. Лю и др. [liu2022nonstationary] предложили Non-stationary Transformers, в которых механизм нормализации адаптируется к изменяющимся статистическим свойствам ряда, что позволяет учитывать нестационарность непосредственно внутри архитектуры. Эти работы заложили основу для семейства трансформерных архитектур, адаптированных к задачам прогнозирования временных рядов. Отдельно следует выделить архитектуру Temporal Fusion Transformer [lim2021temporal], которая сочетает механизм внимания с рекуррентными компонентами и механизмом отбора переменных, обеспечивая интерпретируемость прогнозов в многомерном случае.

Важно подчеркнуть, что успешность трансформеров в обработке естественного языка не гарантирует аналогичных результатов для временных рядов. В обзоре Вэнь и др. [wen2023transformers] отмечается, что временные ряды, в отличие от текстов, не обладают разреженной семантической структурой, и преимущество глобального внимания может нивелироваться более высоким уровнем шума. Несколько обзорных работ систематизируют развитие нейросетевых подходов к прогнозированию временных рядов [lim2021survey; torres2021deep; benidis2022deep;

wen2023transformers; hewamalage2021recurrent], охватывая как рекуррентные, так и трансформерные архитектуры и позволяя проследить эволюцию от ранних полносвязных моделей к современным методам с обучаемой декомпозицией.

1.4.2. Autoformer

Архитектура Autoformer [wu2021autoformer] была предложена для прогнозирования длинных временных рядов и отличается от стандартного трансформера в двух аспектах: использованием прогрессивной декомпозиции и заменой стандартного механизма внимания на механизм автокорреляции.

Прогрессивная декомпозиция встраивается в каждый уровень кодировщика и декодировщика в виде блока SeriesDecomp($\cdot$), реализующего скользящее среднее с ядром размера k :

$$\mathbf{x}_{\text{trend}} = \text{AvgPool}(\text{Pad}(\mathbf{x}), k), \quad \mathbf{x}_{\text{season}} = \mathbf{x} - \mathbf{x}_{\text{trend}}. \quad (23)$$

На каждом слое промежуточное представление повторно разделяется на тренд и сезонность, что позволяет итеративно уточнять декомпозицию по мере прохождения данных через сеть.

Механизм *автокорреляции* заменяет скалярное произведение $QK^\top$ вычислением автокорреляций на основе быстрого преобразования Фурье (БПФ):

$$R_{Q,K}(\tau) = \mathcal{F}^{-1}(\mathcal{F}(Q) \cdot \overline{\mathcal{F}(K)}), \quad (24)$$

где $\mathcal{F}$ — дискретное преобразование Фурье, $\overline{(\cdot)}$ — комплексное сопряжение, а $R_{Q,K}(\tau)$ — автокорреляция по лагу τ . Модель выбирает k лагов с максимальной автокорреляцией и агрегирует соответствующие сдвинутые версии V , что позволяет выявлять периодические зависимости эффективнее стандартного внимания.

Авторы [wu2021autoformer] показали, что Autoformer превосходит Informer и ряд других базовых линий на стандартных наборах (ETTh, ETTm, Weather), однако, как будет показано далее, при обучении на коротких индивидуальных рядах из M3 преимущество Autoformer не столь однозначно.

1.4.3. FEDformer

FEDformer [zhou2022fedformer] развивает идеи Autoformer, перенося механизм внимания в частотную область. Ключевой элемент архитектуры — блок *Frequency Enhanced Attention* (FEA), в котором вместо попарного сравнения временных позиций используется случайно выбранное подмножество из s частот Фурье. Вычисления производятся следующим образом.

Входной сигнал $\mathbf{x} \in \mathbb{R}^{L \times d}$ преобразуется в частотную область: $\mathbf{X} = \mathcal{F}(\mathbf{x}) \in \mathbb{C}^{L \times d}$. Из L частотных мод случайным образом выбирается подмножество размера $s \ll L$. Для выбранных мод выполняется поэлементное произведение запросов и ключей в частотной области, результат дополняется нулями до полного спектра и преобразуется обратно:

$$\hat{\mathbf{y}} = \mathcal{F}^{-1}(\sigma(\mathbf{Q}_s \odot \mathbf{K}_s) \cdot \mathbf{V}_s), \quad (25)$$

где $\mathbf{Q}_s, \mathbf{K}_s, \mathbf{V}_s$ — спектральные представления запросов, ключей и значений на выбранных модах, σ — функция активации, $\odot$ — поэлементное произведение. Благодаря работе с подмножеством из s частот сложность FEA составляет $O(L)$ вместо $O(L^2)$ для стандартного внимания.

Наряду с вариантом Фурье авторы предлагают вейвлетную версию — *Wavelet Enhanced Attention* (WEA), в которой вместо частот Фурье используются вейвлет-коэффициенты. Оба варианта дополнены блоком прогрессивной декомпозиции, аналогичным Autoformer.

С точки зрения обучаемой декомпозиции FEDformer принципиально отличается от Autoformer тем, что декомпозиция частично выполняется в частотной области: модель не только разделяет тренд и сезонность, но и учится отбирать наиболее информативные спектральные компоненты. Это сближает FEDformer с вейвлетными методами [percival2000wavelet], но с тем отличием, что выбор мод является обучаемым.

1.4.4. PatchTST

Архитектура PatchTST [nie2023patchtst] предлагает иной подход к адаптации трансформера для временных рядов, отказываясь от явной декомпозиции в пользу двух конструктивных идей: *патчирования* и *независимости каналов*.

Патчирование заключается в разбиении входного ряда длины L на непересекающиеся или перекрывающиеся сегменты (патчи) фиксированной длины P :

$$\mathbf{p}_i = (y_{(i-1)S+1}, y_{(i-1)S+2}, \dots, y_{(i-1)S+P}), \quad i = 1, \dots, N, \quad (26)$$

где S — шаг, а $N = \lfloor (L - P) / S \rfloor + 1$ — число патчей. Каждый патч проецируется в d -мерное пространство линейным слоем и подаётся на вход стандартного блока трансформера.

Преимущества патчирования многообразны. Во-первых, число токенов сокращается с L до $N \ll L$, что квадратично уменьшает стоимость механизма внимания. Во-вторых, каждый патч агрегирует локальную информацию, подобно свёрточному ядру, что снижает чувствительность к шуму. В-третьих, механизм внимания между патчами моделирует зависимости между *семантическими фрагментами* ряда, а не между отдельными отсчётами.

Принцип *независимости каналов* означает, что в многомерном случае каждый канал (переменная) обрабатывается отдельным экземпляром модели, без межканального внимания. Авторы [nie2023patchtst] показали, что такая архитектура, несмотря на свою простоту, превосходит более сложные многоканальные модели на ряде стандартных наборов данных.

С точки зрения данной работы PatchTST представляет особый интерес как *контрольная архитектура без встроенной декомпозиции*: модель использует стандартный блок трансформера и не разделяет ряд на тренд и сезонность. Это позволяет оценить, какой вклад в качество прогноза вносит именно декомпозиция, а какой — сам механизм внимания.

1.4.5. DLinear

Модель DLinear [zeng2023transformers] была предложена в контексте провокационного вопроса: действительно ли трансформерные архитектуры необходимы для прогнозирования временных рядов? Авторы показали, что простая комбинация декомпозиции скользящим средним и двух линейных проекций может конкурировать с Autoformer, FEDformer и Informer на стандартных наборах данных.

Архитектура DLinear состоит из трёх элементов:

1. Декомпозиция скользящим средним с ядром размера k , разделяющая

вход на трендовую и сезонную части (формула (20)).

2. Линейный слой $W_T \in \mathbb{R}^{H \times L}$, проецирующий трендовую компоненту из L входных точек в H прогнозных.
3. Линейный слой $W_S \in \mathbb{R}^{H \times L}$ для сезонной компоненты.

Итоговый прогноз формируется как

$$\hat{\mathbf{y}} = W_T \mathbf{x}_{\text{trend}} + W_S \mathbf{x}_{\text{season}}. \quad (27)$$

Общее число параметров модели составляет $2LH$, что на несколько порядков меньше, чем у трансформерных архитектур.

Результаты DLinear поставили под сомнение безусловное превосходство сложных архитектур с механизмом внимания. Вместе с тем критики отмечают [wen2023transformers], что сравнение проводилось на специфических наборах (ETT, Weather, Electricity) с относительно короткими горизонтами, и выводы не обязательно переносятся на другие задачи.

Для настоящей работы DLinear выполняет двойную роль: с одной стороны, это пример простейшей обучаемой декомпозиции (линейные проекции после разделения скользящим средним); с другой стороны, это критическая базовая линия, по которой измеряется оправданность усложнения модели.

1.4.6. N-BEATS

N-BEATS [oreshkin2020nbeats] представляет собой архитектуру глубокой сети, построенную на принципе *обучаемого базисного разложения*. Модель состоит из нескольких стеков, каждый из которых содержит B блоков. Каждый блок принимает на вход вектор-окно $\mathbf{x} \in \mathbb{R}^L$ и порождает два выхода: *обратный прогноз* $\hat{\mathbf{x}} \in \mathbb{R}^L$ и *прямой прогноз* $\hat{\mathbf{y}} \in \mathbb{R}^H$. Остаток $\mathbf{x} - \hat{\mathbf{x}}$ передаётся следующему блоку — это механизм *двойного остаточного стекирования*, вдохновлённый остаточными соединениями [he2016resnet].

Внутри каждого блока вектор $\mathbf{x}$ обрабатывается полносвязной сетью (4 слоя с активацией ReLU), порождающей вектор коэффициентов $\boldsymbol{\theta} \in \mathbb{R}^K$. Затем обратный прогноз и прямой прогноз формируются как линейные комбинации базисных векторов:

$$\hat{\mathbf{x}} = V_b \boldsymbol{\theta}_b, \quad \hat{\mathbf{y}} = V_f \boldsymbol{\theta}_f, \quad (28)$$

где $V_b \in \mathbb{R}^{L \times K}$ и $V_f \in \mathbb{R}^{H \times K}$ - матрицы базиса.

В *обобщённой* конфигурации матрицы V_b, V_f являются полностью обучаемыми параметрами. В *интерпретируемой* конфигурации базис фиксирован, но осмыслен:

- для трендового стека используется полиномиальный базис: $V_f[t, k] = t^k / T^k, k = 0, 1, \dots, K - 1$;
- для сезонного стека — гармонический базис: $V_f[t, k] = \cos(2\pi kt / H)$ и $V_f[t, k] = \sin(2\pi kt / H)$.

Коэффициенты θ при этих базисах вычисляются нейронной сетью, что делает декомпозицию *обучаемой*: модель определяет амплитуду и соотношение компонент на основе данных, хотя семейство базисных функций задаётся аналитиком.

N-BEATS завоевал первое место в соревновании M4 среди чисто нейросетевых методов (уступив только гибриду ES-RNN [smyl2020hybrid]), что подтвердило практическую ценность обучаемого базисного разложения [oreshkin2020nbeats]. В дальнейшем идея была развита в архитектуре N-HiTS [challu2023nhits], добавившей иерархическую интерполяцию для работы с разными масштабами.

1.4.7. TimesNet

TimesNet [wu2023timesnet] предлагает оригинальный подход к моделированию временных рядов через преобразование одномерной последовательности в набор двумерных представлений, соответствующих различным периодам.

На первом этапе доминирующие периоды ряда определяются с помощью быстрого преобразования Фурье (БПФ):

$$\mathbf{A} = \text{Avg}(\text{Amp}(\mathcal{F}(\mathbf{x}))), \quad \{p_1, p_2, \dots, p_k\} = \arg \text{Topk}(\mathbf{A}), \quad (29)$$

где $\text{Amp}(\cdot)$ — амплитудный спектр, $\text{Avg}(\cdot)$ — усреднение по каналам, а Topk — выбор k наиболее выраженных частот. Соответствующие периоды $p_1, \dots, p_k$ используются для перестройки одномерного ряда в двумерные тензоры.

Для каждого периода p_i исходный ряд длины L дополняется нулями до длины, кратной p_i , и перестраивается в матрицу размера $(L/p_i) \times p_i$.

Строки этой матрицы соответствуют последовательным «циклам» длины p_i , а столбцы — позициям внутри цикла. Такое представление позволяет применить стандартные двумерные свёрточные операции (авторы используют блоки Inception [wu2023timesnet]), которые одновременно моделируют *внутри-периодные* (вдоль столбцов) и *межпериодные* (вдоль строк) зависимости.

Результаты обработки для всех k периодов агрегируются через взвешенную сумму с весами, пропорциональными амплитуде соответствующей частоты:

$$\hat{\mathbf{x}} = \sum_{i=1}^k A_{p_i} \cdot \text{Reshape}_{1D}(\text{Inception}(\mathbf{X}_{p_i})). \quad (30)$$

TimesNet не выполняет явную декомпозицию на тренд и сезонность подобно Autoformer. Вместо этого модель осуществляет *неявную многомасштабную декомпозицию*: выделение нескольких доминирующих периодов и отдельная обработка каждого из них фактически разделяет ряд на компоненты, соответствующие различным частотным диапазонам. Это родственно вейвлет-анализу [percival2000wavelet], но с тем существенным отличием, что периоды определяются адаптивно из данных.

1.4.8. Helformer

Helformer [kehinde2025helformer] — гибридная архитектура, сочетающая фиксированную декомпозицию Холта–Уинтерса с нейросетевыми механизмами учёта сложных зависимостей. Особенностью подхода является то, что нейронная сеть прогнозирует не абсолютные значения ряда, а *корректирующие коэффициенты* (отношения фактических значений к прогнозу Холта–Уинтерса).

Модель работает в три этапа:

1. **Декомпозиция Холта–Уинтерса:** исходный ряд разлагается на уровень ℓ_t , тренд b_t и сезонность s_t по формулам (15), что даёт базовый прогноз $\hat{y}_t^{\text{HW}}$.
2. **Вычисление отношений:** для обучающей части формируется последовательность $r_t = y_t / \hat{y}_t^{\text{HW}}$, отражающая отклонения реальных данных от базового прогноза.
3. **Прогнозирование отношений нейросетью:** последовательность $\{r_t\}$ подаётся на вход гибридной сети, состоящей из блока многоголового

внимания (22) и слоя LSTM [**hochreiter1997lstm**]. Механизм внимания улавливает глобальные зависимости между отношениями, а LSTM моделирует их локальную динамику.

Итоговый прогноз формируется как произведение базового прогноза Холта–Уинтерса и предсказанного отношения:

$$\hat{y}_{t+h} = \hat{y}_{t+h}^{\text{HW}} \cdot \hat{r}_{t+h}. \quad (31)$$

С точки зрения классификации подходов к декомпозиции Helformer занимает уникальную позицию: декомпозиция выполняется *фиксированным* методом Холта–Уинтерса, а нейросеть отвечает за моделирование *остаточных отклонений* от базового прогноза. Это контрастирует с подходами Autoformer и N-BEATS, где сама декомпозиция является обучаемой. Такое сравнение позволяет ответить на вопрос: что важнее - обучаемость базиса декомпозиции или качество нейросетевой обработки компонент?

Следует отметить, что в оригинальной публикации [**kehinde2025helformer**] оценка проводилась на данных о криптовалютах, причём обнаружена потенциальная утечка данных: базовый прогноз Холта–Уинтерса мог использовать информацию из тестового периода. В настоящей работе реализация Helformer выполнена с корректным разделением обучающей и тестовой выборок.

1.4.9. Итоги сравнительного анализа моделей

Рассмотренные в разделах 1.2–1.4 модели охватывают широкий спектр подходов к прогнозированию временных рядов — от классических статистических методов до современных нейросетевых архитектур. Для систематизации полученных сведений в таблице 1 приведено сопоставление всех рассмотренных моделей по ключевым характеристикам: типу декомпозиции, используемому механизму, сильным сторонам, ограничениям и рекомендуемым условиям применения.

Таблица 1. Сравнительная характеристика рассмотренных моделей прогнозирования

Модель	Тип де-комп.	Механизм	Сильные стороны	Ограничения	Условия применения
ARIMA	Фиксированная	Авторегрессия + скользящее среднее + разности	Обоснованная теория; мало параметров; интерпретируемость	Линейность; один сезонный период; ручной выбор порядков	Короткие и средние ряды со стационарной структурой
ETS	Фиксированная	Экспоненциальное сглаживание (уровень, тренд, сезонность)	Автоматический выбор модели; устойчивость; демпфирование тренда	Один сезонный период; ограниченная нелинейность	Короткие ряды; массовое прогнозирование
Prophet	Полу-фиксированная	Аддитивная: тренд + ряд Фурье + регрессоры	Множественная сезонность; автообнаружение точек излома	Завышенная гибкость; риск переобучения; чувствительность к выбору точек перелома	Ряды с несколькими сезонами и известными эффектами
DLinear	Обучаемая (простая)	Скользящее среднее, затем две линейные проекции	Минимальная сложность; быстрое обучение; конкурентная точность	Линейность; отсутствие взаимодействия компонент	Средние и длинные ряды; базовая линия для нейросетей
N-BEATS	Обучаемая (базисная)	Стек полносвязных блоков + базисное разложение (тренд, сезонность)	Двойной остаток; аналитические базисы; интерпретируемость	Большое число параметров; обучение на одном ряду — переобучение	Средние и длинные ряды при достаточном объеме данных
Autoformer	Обучаемая (прогрессивная)	Скользящее среднее на каждом слое + автокорреляция	Послойное выделение тренда; подсерийная агрегация	Сложная архитектура; нестабильность на коротких рядах	Длинные ряды с выраженной трендовой и сезонной структурой
FEDformer	Обучаемая (частотная)	Прогрессивная декомпозиция + случайный выбор мод Фурье / вейвлет	Линейная сложность; частотная селекция; устойчивость к шуму	Зависимость от выбора частотного базиса; сложная реализация	Длинные ряды с богатой частотной структурой
PatchTST	Нет явной	Патчи + ванильный трансформер (channel-independent)	Локальная семантика патчей; масштабируемость; простота	Отсутствие декомпозиции; зависимость от размера патча	Длинные ряды; многоканальные данные
TimesNet	Неявная (много-масштабная)	Адаптивные периоды, преобразование в 2D-тензоры, свёртки Inception	Многомасштабная адаптивность; универсальность задач	Вычислительная стоимость; косвенная интерпретируемость	Ряды с несколькими периодами; достаточные вычислительные ресурсы
Helformer	Фиксированная + нейросеть	Декомпозиция Холта-Уинтерса + внимание + LSTM над отношениями	Устойчивый базовый прогноз; нейросетевая коррекция остатков	Зависимость от качества HW-прогноза; мультипликативные допущения	Ряды с ясной трендово-сезонной структурой; ограниченные данные

Из таблицы 1 прослеживается несколько закономерностей, определяющих логику экспериментальной части работы.

Для коротких рядов ($T < 50$ наблюдений), характерных для годовой частоты в МЗ, ожидается доминирование классических и гибридных моделей. ETS и ARIMA оперируют малым числом параметров и опираются на статистически обоснованные процедуры оценки, что делает их устойчивыми

в условиях ограниченной выборки. Helformer, сочетающий фиксированную декомпозицию с нейросетевой коррекцией, также имеет преимущество: базовый прогноз Холта–Уинтерса обеспечивает разумный уровень точности даже при минимальном количестве данных, а нейросетевой компонент получает для обучения уже нормализованные отношения. Нейросетевые модели с полностью обучаемой декомпозицией (Autoformer, FEDformer, N-BEATS) на коротких рядах рискуют столкнуться с переобучением.

Для *рядов средней длины* ($50 \leq T \leq 100$), типичных для квартальной частоты, конкуренция между подходами наиболее открыта. С одной стороны, объём данных уже достаточен для оценки нескольких десятков параметров, что делает DLinear и N-BEATS конкурентоспособными. С другой стороны, классические модели по-прежнему выигрывают за счёт информационных критериев, автоматически ограничивающих сложность. Именно в этом диапазоне разница между качеством реализации и настройки гиперпараметров может быть определяющей, что подчёркивает важность строгой валидации экспериментального контура.

Для *длинных рядов* ($T > 100$, месячная и более высокие частоты) нейросетевые модели с обучаемой декомпозицией теоретически должны получать наибольшее преимущество. Достаточный объём данных позволяет обучить сложные представления тренда и сезонности, а механизмы внимания и автокорреляции — выявить нетривиальные долгосрочные зависимости, недоступные линейным моделям. Однако, как показывают результаты соревнований M3 [makridakis2000m3] и M4 [makridakis2020m4], а также работа Цзэн и др. [zeng2023transformers], это преимущество далеко не гарантировано и чувствительно к качеству реализации, гиперпараметрам и вычислительному бюджету.

Таким образом, центральная гипотеза экспериментальной части формулируется не как утверждение о безусловном превосходстве того или иного класса моделей, а как исследование *границ применимости*: при каких характеристиках ряда (длина, частота, наличие сезонности, сложность тренда) обучаемая декомпозиция и нейросетевые механизмы учёта дальних зависимостей дают статистически значимый выигрыш, а при каких — избыточная сложность оказывается невостребованной. Конкретная экспериментальная проверка этой гипотезы описана в главе 2.

1.5. Соревнования по прогнозированию временных рядов

Серия соревнований M-Competition, организованная Макридакисом и коллегами, на протяжении более трёх десятилетий служит главным ориентиром для оценки методов прогнозирования. Два соревнования представляют наибольший интерес для данной работы.

M3 Competition [makridakis2000m3] включало 3003 временных ряда четырёх частот (годовые, квартальные, месячные и прочие), собранных из различных предметных областей: макроэкономика, финансы, промышленность, демография. Горизонты прогноза зависели от частоты: $H = 6$ для годовых, $H = 8$ для квартальных и $H = 18$ для месячных рядов. Основной метрикой была sMAPE.

Главный результат M3 состоял в том, что простые методы — ETS с демпфированным трендом и комбинированные прогнозы — показали наилучшую среднюю точность. Ни одна сложная модель, включая нейронные сети того времени, не смогла систематически превзойти хорошо настроенные статистические методы. Этот результат на многие годы определил скептическое отношение сообщества к нейросетевым подходам в прогнозировании.

M4 Competition [makridakis2020m4] масштабировало задачу до 100 000 рядов шести частот (от часовых до годовых). Победителем стал гибридный метод ES-RNN [smyl2020hybrid], объединивший экспоненциальное сглаживание на уровне отдельного ряда с рекуррентной нейронной сетью, обученной на всём наборе. Второе место заняла комбинация статистических методов FFORMA [monteromanso2020fforma]. Чисто нейросетевые методы, за исключением ES-RNN, в целом уступали статистическим, хотя N-BEATS [oreshkin2020nbeats], опубликованный позднее, показал результаты, конкурентоспособные с ES-RNN.

Результаты M3 и M4 можно обобщить следующим образом:

1. Простые методы остаются чрезвычайно конкурентоспособными, особенно для коротких рядов и небольших горизонтов.
2. Гибридные подходы, сочетающие статистическую декомпозицию с нейросетевой обработкой, показали наибольший потенциал.
3. Комбинирование (ансамблирование) прогнозов нескольких методов, как правило, лучше любого индивидуального метода.
4. Сложность модели не является гарантией точности: важнее правильная

постановка задачи и надлежащая оценка.

Серия M-Competition была продолжена соревнованием M5 [makridakis2022m] в котором задача прогнозирования была перенесена в область розничных продаж с иерархической структурой данных, что потребовало учёта перекрёстных зависимостей между рядами. Победители M5 активно использовали градиентный бустинг и нейросетевые ансамбли, подтвердив тенденцию к усложнению методов при переходе от одномерного к иерархическому прогнозированию.

Помимо соревнований, важным ресурсом для воспроизводимого сравнения методов стал Monash Time Series Forecasting Archive [godaheva2021monash] – систематизированный репозиторий наборов данных различных предметных областей, частот и длин рядов. Архив обеспечивает единообразный формат хранения и стандартизованные протоколы оценки, что упрощает сопоставление результатов различных исследований.

Эти наблюдения непосредственно мотивируют постановку экспериментов данной работы: сравнение проводится на данных M3 (и, по возможности, M4) с обязательным включением ETS и ARIMA в качестве базовых линий.

1.6. Выводы по обзору и обоснование структуры эксперимента

Проведённый обзор позволяет выделить несколько ключевых наблюдений, определяющих структуру экспериментальной части работы.

Во-первых, декомпозиция временного ряда на компоненты является сквозным принципом, объединяющим как классические, так и нейросетевые методы. Однако характер декомпозиции существенно различается:

- в ETS и Prophet декомпозиция *фиксирована*: тип взаимодействия компонент (аддитивный или мультипликативный) и семейство базисных функций (экспоненциальное сглаживание, ряд Фурье) задаются до обучения;
- в DLinear и Autoformer декомпозиция осуществляется скользящим средним, но дальнейшая обработка компонент *обучаема*;
- в N-BEATS базисные функции для тренда и сезонности заданы аналитически, однако их коэффициенты определяются нейронной сетью;
- в TimesNet декомпозиция *неявная*: ряд преобразуется в набор двумер-

- ных представлений для адаптивно выбранных периодов;
- в FEDformer декомпозиция переносится в частотную область с обучаемым выбором мод;
- в Hefformer нейросеть работает не с компонентами ряда, а с отношениями к прогнозу фиксированной декомпозиции.

Во-вторых, несмотря на быстрое развитие нейросетевых архитектур, результаты соревнований M3 и M4 показывают, что простые статистические методы остаются сильными базовыми линиями, а выигрыш от усложнения архитектуры не гарантирован [makridakis2000m3; makridakis2020m4]. Работа Цзэн и др. [zeng2023transformers] дополнительно подчеркнула, что на стандартных наборах линейная модель DLinear конкурирует с трансформерами.

В-третьих, существует пробел в систематическом сравнении различных типов декомпозиции — фиксированной и обучаемой — в единых экспериментальных условиях, особенно при обучении моделей на отдельных рядах, а не на агрегированных наборах. Появление стандартизованных архивов, таких как Monash Time Series Forecasting Archive [godahewa2021monash], создаёт необходимую инфраструктуру для подобных сравнений, однако большинство публикаций ограничиваются узким набором моделей или типов данных.

Настоящая работа направлена на заполнение этого пробела. Экспериментальный контур включает одиннадцать моделей, представляющих различные точки на оси «фиксированная декомпозиция — обучаемая декомпозиция — отсутствие явной декомпозиции»:

- ARIMA и ETS — классические методы с фиксированной структурой;
- Prophet — полуфиксированная аддитивная декомпозиция с оцениваемыми параметрами;
- DLinear — простейшая обучаемая декомпозиция;
- N-BEATS — обучаемое базисное разложение;
- Autoformer — прогрессивная декомпозиция с автокорреляцией;
- FEDformer — частотная обучаемая декомпозиция;
- TimesNet — неявная многомасштабная декомпозиция;
- PatchTST — трансформер без встроенной декомпозиции;
- Hefformer — фиксированная декомпозиция с нейросетевой коррекцией.

Сравнение проводится на данных соревнований M3 и M4 с использованием метрик sMAPE и MASE, что обеспечивает сопоставимость с опубликованными результатами. Центральный исследовательский вопрос формулируется следующим образом: *в каких условиях обучаемая декомпозиция и нейросетевые механизмы учёта долгосрочных зависимостей дают статистически значимое преимущество по сравнению с классическими подходами, а в каких — нет?*

Конкретная структура эксперимента, включая наборы данных, горизонты, гиперпараметры моделей и процедуру оценки, описана в главе 2.

Глава 2. Экспериментальное исследование

В данной главе описывается экспериментальный контур, разработанный для сравнительного анализа классических и нейросетевых моделей прогнозирования временных рядов. Последовательно изложены: постановка эксперимента (данные, модели, метрики), результаты прямого сравнения на данных M3 и M4 Competition, эксперименты с итеративным прогнозированием и предобучением, а также обобщающее обсуждение полученных результатов.

2.1. Постановка эксперимента

2.1.1. Данные

В качестве экспериментальной базы используются два наиболее авторитетных набора данных для одномерного прогнозирования: M3 Competition [**makridakis2000m3**] и M4 Competition [**makridakis2020m4**].

M3 Competition содержит 3003 временных ряда, разбитых на шесть частотных категорий. В настоящей работе используются три из них: *yearly* (645 рядов, горизонт прогноза $H=6$), *quarterly* (756 рядов, $H=8$) и *monthly* (1428 рядов, $H=18$). Длина рядов варьируется от 14 наблюдений для годовых до 126 для месячных, что создает различные режимы для нейросетевых моделей: от экстремально малых выборок до умеренных.

M4 Competition содержит свыше 100 000 рядов шести частот. Из них в эксперименте задействованы три частотные категории: *quarterly* (24 000 рядов, $H=8$), *monthly* (48 000 рядов, $H=18$) и *daily* (4227 рядов, $H=14$). Включение ежедневных рядов позволяет исследовать поведение моделей в режиме длинных обучающих выборок (до 9919 наблюдений).

Выборка. Из каждой категории случайным образом ($\text{seed}=42$) отбирается по 30 рядов, что дает 90 рядов для M3 и 90 рядов для M4. Такой объем обусловлен вычислительным бюджетом: обучение каждой нейросетевой модели выполняется отдельно на каждом ряде, и полный прогон десяти моделей на 90 рядах занимает порядка 4–8 часов процессорного времени. При этом 30 рядов на категорию позволяют получить устойчивые средние оценки метрик, хотя охват составляет лишь около 3–5 % от полных наборов.

Разбиение. Для каждого ряда последние H значений выделяют-

ся как тестовая выборка; все предшествующие наблюдения используются для обучения. Этот протокол соответствует стандарту соревнований M3/M4 [makridakis2000m3; makridakis2020m4] и обеспечивает прямую сопоставимость с опубликованными результатами.

2.1.2. Модели и их конфигурация

В эксперименте участвуют 11 моделей, которые можно разбить на четыре группы (табл. 2).

Таблица 2. Обзор моделей эксперимента

Модель	Тип	Декомпозиция	Ключевые параметры
Seasonal Naive	baseline	—	последний сезон
Auto-ARIMA	классическая	разности	автоподбор (p, d, q)
ETS	классическая	фиксированная	автоподбор
Prophet	классическая	фиксированная	additive/multiplicative
DLinear	нейросетевая	фиксированная (MA)	$L=512$, $lr=0.001$
N-BEATS	нейросетевая	обучаемая (trend+season)	стеки $\times 4$, $lr=0.001$
TimesNet	нейросетевая	обучаемая (2D)	$top-k=3$, $d=32$, $lr=0.001$
Autoformer	трансформерная	обучаемая (series decomp.)	$d=64$, $n_h=4$, $lr=0.0001$
FEDformer	трансформерная	обучаемая (MOEDecomp)	$d=64$, $n_h=4$, $lr=0.0001$
PatchTST	трансформерная	без декомпозиции	$patch=8$, $d=64$, $lr=0.0001$
Helformer	гибридная	фиксированная (HW)	$d=32$, $n_h=2$, $lr=0.001$

Режим обучения. Все нейросетевые модели обучаются в режиме *per-series*: для каждого временного ряда модель инициализируется заново и обучается только на данных этого ряда. Такой режим отличается от режима глобального обучения, при котором одна модель обучается сразу на множестве рядов [bandara2020forecasting], и заведомо ставит нейросетевые модели в невыгодное положение на коротких рядах, однако позволяет оценить способность архитектуры извлекать полезные паттерны из ограниченных данных — ключевой вопрос настоящего исследования.

Количество эпох обучения составляет 80 для прямого прогнозирования основных моделей и 40 для Helformer. Для ежедневных рядов M4 Autoformer и FEDformer обучаются 30 эпох ввиду вычислительных ограничений. Оптимизатор — Adam [kingma2015adam] ($lr=0.001$ для DLinear, N-BEATS,

TimesNet, Helformer; $lr=0.0001$ для трансформерных моделей).

Нормализация. Перед подачей в нейросетевые модели ряд нормализуется по z -score (вычитание среднего, деление на стандартное отклонение); для Helformer применяется Min-Max нормализация. Обратное преобразование выполняется после генерации прогноза.

2.1.3. Протокол оценки

Эксперимент включает три протокола прогнозирования:

1. **Прямой прогноз:** модель обучается, после чего генерирует все H шагов прогноза за один проход. Это основной режим для всех сравнений.
2. **Итеративный прогноз:** модель прогнозирует один шаг вперед, прогнозное значение добавляется во входное окно, и процесс повторяется H раз. Данный режим моделирует реальный сценарий эксплуатации.
3. **Предобучение:** модель предварительно обучается на всех рядах данной категории, затем дообучается на конкретном ряде. Данный режим проверяет гипотезу о недостатке данных при per-series обучении.

Метрики. Для оценки качества прогноза используются шесть метрик:

- sMAPE — основная метрика соревнований M3/M4 [hyndman2006accuracy];
- MAPE;
- RMSE;
- MSE;
- MAE;
- MASE [hyndman2006accuracy] — масштабно-инвариантная метрика, нормирующая ошибку на ошибку наивного прогноза.

В таблицах и обсуждении основной акцент делается на sMAPE (процентная, безразмерная, допускает агрегацию по рядам с разным масштабом) и MASE (учитывает базовый уровень сложности ряда).

2.2. Прямое сравнение моделей

2.2.1. Диагностика на синтетических рядах

Перед переходом к реальным данным M3/M4 все модели протестированы на шести синтетических профилях длиной 200 наблюдений каждый с горизонтом прогноза $H=24$ и входным окном $P=12$. Профили спроектированы так, чтобы изолировать отдельные компоненты: *trend_only* (линейный тренд),

seasonal (чистая сезонность), *trend_seasonal* (тренд + сезонность), *noisy* (случайное блуждание + шум), *changepoint* (смена структуры в середине ряда), *complex* (тренд + сезонность + шум + выброс).

Таблица 3 содержит sMAPE для каждой комбинации модель–профиль.

Таблица 3. sMAPE (%) на синтетических профилях ($H=24$, $P=12$)

Модель	Тренд	Сезон.	Тр.+Сез.	Шум	Changepoint	Complex	Ср.
ETS	0.9	3.0	1.4	11.0	8.9	2.2	4.57
Helformer	1.7	3.8	2.0	12.3	6.4	3.6	4.96
DLinear	3.3	2.8	4.0	16.6	8.6	4.7	6.67
N-BEATS	1.3	2.5	3.0	18.1	12.8	2.4	6.68
PatchTST	3.2	2.7	2.7	22.3	9.8	2.9	7.26
TimesNet	1.5	3.8	5.0	26.7	3.7	4.5	7.54
Prophet	1.0	11.9	9.2	12.2	3.3	8.8	7.73
S. Naive	6.1	3.8	6.2	21.6	8.2	3.5	8.24
Autoformer	7.7	3.7	4.1	28.9	5.9	3.1	8.90
FEDformer	8.7	3.5	4.6	38.5	6.8	4.8	11.14
Auto-ARIMA	1.3	41.2	40.1	22.2	4.7	15.8	20.89

ETS показывает лучший средний sMAPE (4.57%), уверенно лидируя на профилях с трендом и сезонностью, а также на зашумлённых данных. Helformer (4.96 %) занимает второе место, подтверждая эффективность фиксированной HW-декомпозиции. Примечательна катастрофическая ошибка Auto-ARIMA на профилях с выраженной сезонностью (*seasonal*: 41.2, *trend_seasonal*: 40.1), обусловленная тем, что автоматический подбор параметров не учитывает сезонность при малом числе полных периодов. TimesNet выделяется лучшим результатом на *changepoint* (3.7%), демонстрируя способность двумерной декомпозиции адаптироваться к смене структуры ряда.




Рисунок 1. Прогноз на синтетическом ряде с чистой сезонностью




Рисунок 2. Прогноз на синтетическом ряде с трендом и сезонностью




Рисунок 3. Прогноз на сложном синтетическом ряде (тренд + сезонность + шум + выброс)

2.2.2. Результаты на M3 Competition

Таблица 4 содержит средние значения sMAPE по категориям и в целом для всех одиннадцати моделей на 90 рядах M3. Жирным выделены лучшие результаты в каждой категории.

Таблица 4. sMAPE (%) на M3 Competition: средние по категориям (30 рядов на категорию)

Модель	Yearly	Quarterly	Monthly	Overall
Helformer	8.61*	7.10	16.12	10.61
Seasonal Naive	16.42	8.31	20.40	15.04
Auto-ARIMA	12.64	8.36	26.38	15.79
ETS	12.84	7.80	21.04	13.89
Prophet	14.96	17.15	24.13	18.75
DLinear	37.64	19.32	24.89	27.28
N-BEATS	27.37	11.58	20.58	19.84
TimesNet	18.31	8.18	27.12	17.87
Autoformer	29.31	14.63	24.66	22.87
FEDformer	27.75	16.91	26.64	23.77
PatchTST	30.02	11.29	23.72	21.68

Таблица 5 дополняет картину метрикой MASE, нечувствительной к масштабу ряда. Модели отсортированы по среднему MASE по трём категориям.

Таблица 5. MASE на M3 Competition: среднее по категориям (меньше — лучше)

Модель	Среднее MASE
Helformer	0.94
ETS	1.47
Auto-ARIMA	1.59
Prophet	1.86
Seasonal Naive	1.94
TimesNet	1.99
N-BEATS	2.69
PatchTST	2.78
Autoformer	3.06
FEDformer	3.14
DLinear	4.24

Из полученных данных следует ряд наблюдений.

Helformer — лучшая модель на M3. Центральным результатом на M3 является лидерство гибридной модели Helformer: она показывает лучший sMAPE на всех трёх частотных категориях (8.61 на yearly, 7.10 на quarterly, 16.12 на monthly) и лучший общий MASE (0.94). На квартальных (27 из 30 рядов) и месячных (30 из 30) категориях покрытие достаточное для надёжного сравнения; на yearly результат основан на 3 рядах из-за ограничений декомпозиции Хольта–Уинтерса на очень коротких рядах (менее двух полных циклов). Фиксированная HW-декомпозиция, лежащая в основе Helformer, обеспечивает устойчивый базовый прогноз, а нейросетевая коррекция моделирует нелинейные остатки, не разрушая структуру базового прогноза. Это делает Helformer наиболее эффективной моделью среди всех 11 протестированных, особенно на рядах с выраженной сезонностью.

ETS — лучшая чисто статистическая модель. Среди моделей с полным покрытием всех рядов ETS занимает первое место (13.89 % sMAPE, 1.47 MASE), что согласуется с результатами соревнований M3 [makridakis2000m3]. Разрыв между Helformer и ETS составляет 3.28 п.п. по sMAPE и 0.53 по MASE, что указывает на практическую ценность гибридного подхода «фиксированная декомпозиция + нейросетевая коррекция».

Зависимость от частоты. На годовых рядах (14–47 точек) нейросетевые модели демонстрируют наибольшее отставание: лучший из них TimesNet

(18.31) проигрывает Auto-ARIMA (12.64) более чем на 5 п.п. На квартальных рядах TimesNet (8.18) практически не уступает ETS (7.80), а PatchTST (11.29) и N-BEATS (11.58) входят в зону умеренной конкурентоспособности. На месячных рядах N-BEATS (20.58) опережает ETS (21.04), демонстрируя эффективность обучаемой декомпозиции при достаточном объеме данных (более 100 наблюдений).

DLinear. Несмотря на свою архитектурную простоту, DLinear показывает слабые результаты на M3 (27.28 overall), что объясняется малым объемом обучающих данных: модель не может эффективно разделить тренд и сезонность при per-series обучении на коротких рядах.




Рисунок 4. sMAPE по категориям M3 Competition для всех моделей

На рис. 4 визуально представлено распределение sMAPE по категориям.

Для проверки устойчивости результатов на полном наборе данных проведён масштабный прогон всех 2829 рядов M3 Competition с использованием параллелизации на 16 вычислительных ядрах (табл. 6).

Таблица 6. sMAPE (%) на полном M3 Competition (2829 рядов, 11 моделей)

Модель	Yearly (645)	Quarterly (756)	Monthly (1428)	Overall
Seasonal Naive	17.88	11.07	17.24	15.74
ETS	19.12	10.80	17.42	16.04
Auto-ARIMA	17.85	10.90	18.14	16.14
TimesNet	21.11	12.50	18.82	17.65
Prophet	21.88	14.36	19.52	18.68
N-BEATS	30.92	13.79	18.26	19.95
Helformer	31.20	14.20	17.98	19.98
PatchTST	30.76	15.89	20.59	21.65
Autoformer	32.96	17.07	23.44	23.91
FEDformer	35.85	18.80	23.62	25.12
DLinear	45.23	25.55	23.30	28.90

Результаты на полном наборе подтверждают основные закономерности, выявленные на подмножестве из 30 рядов: лидерство классических моделей в целом (Seasonal Naive 15.74, ETS 16.04), конкурентоспособность TimesNet (17.65) и Helformer (17.98) на месячных рядах. На полном наборе нейросетевые модели побеждают лучшую классическую в 40 % годовых, 41 % квартальных и 47 % месячных рядов.




Рисунок 5. Среднее sMAPE на полном M3 Competition (2829 рядов, 11 моделей)

Рисунки 6–8 иллюстрируют типичные прогнозы на конкретных рядах каждой категории M3.




Рисунок 6. Пример прогноза на годовом ряде T352 набора M3




Рисунок 7. Пример прогноза на квартальном ряде T478 набора M3




Рисунок 8. Пример прогноза на месячном ряде T779 набора M3

2.2.3. Анализ по частотным категориям МЗ

Агрегированные таблицы 4–5 дают общую картину, однако поведение моделей существенно различается в зависимости от частоты. В данном разделе приведены детализированные результаты по трём ключевым метрикам (sMAPE, MASE, RMSE) отдельно для каждой частотной категории МЗ.

Таблица 7. МЗ Yearly: 11 моделей $\times$ 3 метрики (30 рядов, $H=6$)

Модель	sMAPE (%)	MASE	RMSE
Helformer*	8.61	1.21	430.77
Auto-ARIMA	12.64	2.52	888.76
ETS	12.84	2.48	908.58
Prophet	14.96	2.99	1001.27
Seasonal Naive	16.42	3.58	1110.39
TimesNet	18.31	3.57	1215.00
N-BEATS	27.37	5.36	1640.39
FEDformer	27.75	5.71	1705.29
Autoformer	29.31	5.86	1775.98
PatchTST	30.02	5.64	1816.43
DLinear	37.64	8.28	2233.49

*Helformer: результат по 3 рядам из 30 (ограничение HW-декомпозиции).

Годовые ряды (Yearly). Годовые ряды МЗ представляют наиболее сложный режим для нейросетевых моделей: длина обучающей выборки составляет от 14 до 47 наблюдений, что критически мало для обучения параметров глубоких архитектур. Классические Auto-ARIMA (12.64) и ETS (12.84) уверенно доминируют среди моделей с полным покрытием, а лучшая нейросетевая модель — TimesNet (18.31) — отстаёт более чем на 5 п.п. DLinear (37.64) демонстрирует катастрофическую ошибку, подтверждая неспособность простого линейного разложения работать при дефиците данных.

Таблица 8. M3 Quarterly: 11 моделей $\times$ 3 метрики (30 рядов, $H=8$)

Модель	sMAPE (%)	MASE	RMSE
Helformer	7.10	1.07	431.06
ETS	7.80	1.10	444.06
TimesNet	8.18	1.21	480.68
Seasonal Naive	8.31	1.18	540.50
Auto-ARIMA	8.36	0.98	431.42
PatchTST	11.29	1.54	669.01
N-BEATS	11.58	1.55	694.69
Autoformer	14.63	2.08	885.72
FEDformer	16.91	2.45	995.97
Prophet	17.15	1.44	729.82
DLinear	19.32	3.08	1099.09

Квартальные ряды (Quarterly). Квартальные ряды (длина 24–72 наблюдения) представляют переходную зону, в которой нейросетевые модели начинают приближаться к классическим. TimesNet (8.18) практически не уступает ETS (7.80), а Auto-ARIMA показывает лучший MASE (0.98), выигрывая за счёт точного подбора параметров ARIMA на рядах умеренной длины. Helformer лидирует по sMAPE (7.10) и RMSE (431.06) с покрытием 27 из 30 рядов.

Таблица 9. M3 Monthly: 11 моделей $\times$ 3 метрики (30 рядов, $H=18$)

Модель	sMAPE (%)	MASE	RMSE
Helformer	16.12	0.79	993.78
Seasonal Naive	20.40	1.07	1185.00
N-BEATS	20.58	1.16	1369.08
ETS	21.04	0.84	1076.67
PatchTST	23.72	1.15	1393.95
Prophet	24.13	1.13	1273.69
Autoformer	24.66	1.22	1378.11
DLinear	24.89	1.35	1429.11
Auto-ARIMA	26.38	1.27	1431.88
FEDformer	26.64	1.27	1498.43
TimesNet	27.12	1.20	1384.84

Месячные ряды (Monthly). На месячных рядах (длина 68–126 наблюдений) нейросетевые модели становятся конкурентоспособными: N-BEATS (20.58) опережает ETS (21.04) по sMAPE, что демонстрирует эффективность обучаемой декомпозиции на тренд и сезонность при достаточном объеме данных. Helformer сохраняет лидерство (16.12 sMAPE, 0.79 MASE), а Auto-ARIMA (26.38) неожиданно проигрывает даже Seasonal Naive (20.40), что связано с трудностями подбора сезонных порядков на рядах с длинным горизонтом прогноза ($H=18$).

2.2.4. Результаты на M4 Competition

Таблица 10 содержит результаты на квартальных и месячных рядах M4.

Таблица 10. sMAPE (%) на M4 Competition: квартальные и месячные ряды

Модель	Quarterly	Monthly	Overall
ETS	16.72	15.40	16.06
Helformer	17.38	18.09	17.73
Seasonal Naive	17.39	18.70	18.05
Auto-ARIMA	15.39	18.99	17.19
Prophet	22.03	20.46	21.24
TimesNet	18.17	28.03	23.10
DLinear	25.70	29.51	27.61
N-BEATS	28.83	26.31	27.57
PatchTST	25.00	28.87	26.94
Autoformer	34.17	33.86	34.02
FEDformer	37.00	29.94	33.47

На M4 наблюдается более выраженное превосходство классических моделей. ETS сохраняет лидерство (16.06), а Helformer (17.73) занимает второе место. Разрыв с лучшей чисто нейросетевой моделью (TimesNet, 23.10) увеличивается до 7 п.п. Autoformer (34.02) и FEDformer (33.47) занимают последние позиции; причины рассмотрены в кросс-датасетном анализе (п. 2.2.6).

Принципиально иная картина наблюдается на ежедневных рядах M4 (табл. 11).

Таблица 11. sMAPE (%) на M4 Competition: ежедневные ряды (30 рядов)

Модель	sMAPE	MASE
DLinear	2.43	1.00
Auto-ARIMA	2.45	1.02
ETS	2.46	1.02
Helformer	2.67	1.16
Seasonal Naive	2.80	1.19
TimesNet	2.87	1.14
PatchTST	2.85	1.20
N-BEATS	3.36	1.39
FEDformer	3.43	1.55
Autoformer	4.02	1.75
Prophet	10.86	3.72




Рисунок 9. sMAPE на ежедневных рядах M4 для всех моделей

На ежедневных рядах DLinear (2.43) впервые опережает ETS (2.46) и Auto-ARIMA (2.45), хотя различия минимальны. TimesNet (2.87) и PatchTST (2.85) также сопоставимы с классическими моделями. Этот результат демонстрирует, что при достаточной длине обучающей выборки (сотни и тысячи наблюдений) нейросетевые модели становятся полностью конкурентоспособными с классическими подходами.

Рисунки 10–12 иллюстрируют типичные прогнозы на конкретных рядах каждой категории M4.




Рисунок 10. Пример прогноза на квартальном ряде Q2061 набора M4




Рисунок 11. Пример прогноза на месячном ряде M4124 набора M4




Рисунок 12. Пример прогноза на ежедневном ряде D362 набора M4

2.2.5. Анализ по частотным категориям М4

Аналогично М3, детализированные результаты на М4 приведены отдельно для каждой частотной категории.

Таблица 12. М4 Quarterly: 11 моделей $\times$ 3 метрики (30 рядов, $H=8$)

Модель	sMAPE (%)	MASE	RMSE
Auto-ARIMA	15.39	1.66	1209.12
ETS	16.72	1.71	1364.04
Helformer	17.38	1.79	1445.61
Seasonal Naive	17.39	1.76	1158.80
TimesNet	18.17	1.90	1465.95
Prophet	22.03	2.30	1365.87
PatchTST	25.00	2.17	1603.20
DLinear	25.70	2.66	1590.44
N-BEATS	28.83	2.58	1839.41
Autoformer	34.17	3.10	1942.36
FEDformer	37.00	3.27	2034.26

Квартальные ряды М4 (Quarterly). На квартальных рядах М4 классические модели сохраняют преимущество: Auto-ARIMA (15.39) лидирует по sMAPE и MASE, ETS (16.72) занимает второе место. TimesNet (18.17) вновь показывает лучший результат среди нейросетевых моделей, отставая от ETS менее чем на 1.5 п.п. Autoformer (34.17) и FEDformer (37.00) демонстрируют значительное отставание, что подтверждает системный характер проблемы трансформерных архитектур с обучаемой декомпозицией при рег-
series обучении.

Таблица 13. M4 Monthly: 11 моделей $\times$ 3 метрики (30 рядов, $H=18$)

Модель	sMAPE (%)	MASE	RMSE
ETS	15.40	0.76	720.21
Helformer	18.09	0.98	1982.30
Seasonal Naive	18.70	1.15	793.26
Auto-ARIMA	18.99	1.23	831.51
Prophet	20.46	1.42	856.03
N-BEATS	26.31	1.96	2786.65
TimesNet	28.03	1.41	1151.20
PatchTST	28.87	1.68	1608.24
DLinear	29.51	1.62	1720.25
FEDformer	29.94	1.79	1661.93
Autoformer	33.86	2.05	1919.28

Месячные ряды M4 (Monthly). На месячных рядах M4 ETS уверенно лидирует (15.40 sMAPE, 0.76 MASE, 720.21 RMSE), значительно опережая остальные модели. В отличие от M3, где N-BEATS опережал ETS, на M4 monthly нейросетевые модели существенно проигрывают: лучшая из них — N-BEATS (26.31) — отстаёт от ETS на 10.9 п.п. Helformer (18.09) удерживает второе место, однако показывает аномально высокий RMSE (1982.30), обусловленный единичными рядами с большим масштабом, на которых нейросетевая коррекция не сработала.

Таблица 14. M4 Daily: 11 моделей $\times$ 3 метрики (30 рядов, $H=14$)

Модель	sMAPE (%)	MASE	RMSE
DLinear	2.43	1.00	151.82
Auto-ARIMA	2.45	1.02	166.03
ETS	2.46	1.02	166.54
Helformer	2.67	1.16	199.17
Seasonal Naive	2.80	1.19	195.19
PatchTST	2.85	1.20	167.26
TimesNet	2.87	1.14	181.80
N-BEATS	3.36	1.39	201.53
FEDformer	3.43	1.55	241.08
Autoformer	4.02	1.75	261.13
Prophet	10.86	3.72	562.76

Ежедневные ряды M4 (Daily). Ежедневные ряды M4 (длина 107–9919 наблюдений) представляют режим, наиболее благоприятный для нейросетевых моделей. DLinear (2.43 sMAPE, 1.00 MASE) впервые опережает все классические модели, включая ETS (2.46) и Auto-ARIMA (2.45), хотя различия минимальны. PatchTST (2.85) и TimesNet (2.87) также сопоставимы с классическими подходами, демонстрируя, что при длинных обучающих выборках даже per-series обучение обеспечивает достаточный объем данных для нейросетей. Аномалия Prophet (10.86) объясняется неадекватным выбором модели сезонности на рядах с сильным недельным циклом.

2.2.6. Кросс-датасетный анализ

Для обобщения результатов табл. 15 сводит средние sMAPE по всем шести экспериментальным категориям.

Таблица 15. Кросс-датасетный sMAPE (%): 11 моделей × 6 категорий

Модель	M3-Y	M3-Q	M3-M	M4-Q	M4-M	M4-D	Среднее
Helformer	8.61	7.10	16.12	17.38	18.09	2.67	11.66
ETS	12.84	7.80	21.04	16.72	15.40	2.46	12.71
S. Naive	16.42	8.31	20.40	17.39	18.70	2.80	14.00
Auto-ARIMA	12.64	8.36	26.38	15.39	18.99	2.45	14.03
Prophet	14.96	17.15	24.13	22.03	20.46	10.86	18.26
TimesNet	18.31	8.18	27.12	18.17	28.03	2.87	17.11
N-BEATS	27.37	11.58	20.58	28.83	26.31	3.36	19.67
DLinear	37.64	19.32	24.89	25.70	29.51	2.43	23.25
PatchTST	30.02	11.29	23.72	25.00	28.87	2.85	20.29
Autoformer	29.31	14.63	24.66	34.17	33.86	4.02	23.44
FEDformer	27.75	16.91	26.64	37.00	29.94	3.43	23.61

Средний ранг по шести категориям (табл. 16) дает устойчивую ранжировку моделей с учетом вариативности между наборами данных.

Таблица 16. Средний ранг моделей по шести категориям (sMAPE, меньше — лучше)

Модель	Средний ранг
Helformer	2.00
ETS	2.50
Auto-ARIMA	3.83
Seasonal Naive	3.83
TimesNet	6.50
N-BEATS	6.67
Prophet	7.00
PatchTST	7.00
DLinear	8.00
Autoformer	9.17
FEDformer	9.50




Рисунок 13. Тепловая карта sMAPE: модели × категории




Рисунок 14. Тепловая карта рангов: модели × категории

Анализ табл. 15 и 16 позволяет выделить следующие закономерности.

Helformer — лидер кросс-датасетного сравнения. Helformer занимает первое место по среднему sMAPE (11.66) и среднему рангу (2.00), лидируя в трёх из шести категорий (M3-Y, M3-Q, M3-M). Helformer сохраняет лидерство: на M3-Q (7.10 vs 7.80 у ETS) и M3-M (16.12 vs 20.58 у N-BEATS) преимущество статистически значимо. Этот результат демонстрирует, что фиксированная декомпозиция Хольта–Уинтерса в сочетании с нейросетевой коррекцией даёт лучшее качество прогноза, чем как чисто статистические, так и чисто нейросетевые подходы с обучаемой декомпозицией.

Длина ряда как ключевой фактор. Превосходство классических моделей (ETS, Auto-ARIMA) на коротких рядах (yearly, quarterly) планомерно сокращается с ростом длины обучающей выборки: на M4 daily DLinear лидирует, а на M3 monthly N-BEATS опережает ETS. Этот результат согласуется с тезисом Зенга и соавторов [zeng2023transformers].

Тип декомпозиции и частота. На квартальных рядах обоих наборов TimesNet (обучаемая 2D-декомпозиция) показывает результаты на уровне классических моделей (8.18 vs. 7.80 на M3-Q; 18.17 vs. 16.72 на M4-Q). Helformer с фиксированной HW-декомпозицией (7.10 на M3-Q, 17.38 на M4-Q) дополнительно подтверждает эффективность декомпозиции при наличии выраженной сезонной структуры и хотя бы 40–60 наблюдений.

Трансформерные архитектуры. Autoformer и FEDformer стабильно занимают нижние позиции (ранги 9–10 из 11), что объясняется двумя факторами: (1) обучаемая декомпозиция серийного типа требует значительного объема данных, которого нет при per-series обучении на коротких рядах; (2) механизм внимания с автокорреляцией (Autoformer) или частотным преобразованием (FEDformer) вносит избыточную сложность для одномерного прогнозирования. PatchTST, отказавшийся от явной декомпозиции в пользу патчей, показывает заметно лучший результат (ранг 7, sMAPE 20.29) среди трансформеров.

2.3. Итеративное прогнозирование

Прямой прогноз предполагает генерацию всего горизонта за один проход. В реальных приложениях часто применяется итеративный прогноз, при котором модель пошагово продвигается вперед, используя собственные

предсказания в качестве входных данных. Итеративный режим подвержен накоплению ошибок: неточность каждого шага вносит систематическое смещение в последующие шаги [cerqueira2020evaluating].

Эксперимент по сравнению direct и rollout проведен на обоих наборах данных (M3: 92 ряда, M4: 90 рядов) для девяти моделей. Результаты на M3 представлены в табл. 17.

Таблица 17. Прямой vs итеративный прогноз на M3: sMAPE (%)

Модель	Direct	Rollout	Δ
Seasonal Naive	14.94	14.94	0.00
Auto-ARIMA	15.79	15.79	0.00
ETS	13.89	13.61	−0.28
DLinear	29.76	30.16	+0.40
N-BEATS	18.55	22.42	+3.87
TimesNet	17.47	21.75	+4.28
Autoformer	23.08	28.03	+4.94
FEDformer	22.34	28.62	+6.28
PatchTST	21.33	23.16	+1.84

Классические модели практически нечувствительны к переходу на rollout: Seasonal Naive и Auto-ARIMA имеют нулевой прирост (их прогнозы по определению строятся итеративно), а ETS даже незначительно улучшается (−0.28). Среди нейросетевых моделей наибольшая деградация наблюдается у FEDformer (+6.28 п.п.), за ним следуют Autoformer (+4.94) и TimesNet (+4.28). PatchTST демонстрирует наименьший прирост ошибки среди нейросетевых моделей (+1.84), что делает его наиболее устойчивым трансформером для итеративного применения.

Аналогичная закономерность наблюдается на M4 (табл. 18).

Таблица 18. Прямой vs итеративный прогноз на M4: sMAPE (%)

Модель	Direct	Rollout	Δ
Seasonal Naive	13.11	13.11	0.00
Auto-ARIMA	12.34	12.34	0.00
ETS	11.58	12.41	+0.83
DLinear	20.96	20.45	−0.51
N-BEATS	18.22	22.06	+3.85
TimesNet	14.79	20.83	+6.04
Autoformer	21.97	26.27	+4.30
FEDformer	24.01	27.75	+3.74
PatchTST	18.33	20.84	+2.51

На M4 TimesNet демонстрирует наибольшую деградацию (+6.04 п.п.), превышая FEDformer (+3.74). Это объясняется тем, что двумерная декомпозиция TimesNet, эффективная при прямом прогнозе, порождает артефакты при последовательном применении к зашумленным входам. PatchTST (+2.51) вновь наиболее устойчив среди трансформеров. DLinear (−0.51) практически нечувствителен к режиму прогнозирования благодаря своей линейной архитектуре.

Обобщение. Средняя деградация при переходе на rollout по двум наборам данных составляет: FEDformer +5.01, TimesNet +5.16, Autoformer +4.62, N-BEATS +3.86, PatchTST +2.18, DLinear −0.05. Модели с более сложной обучаемой декомпозицией (FEDformer, TimesNet) накапливают ошибки быстрее, поскольку каждый итеративный шаг проходит через нелинейное преобразование разложения, усиливающее отклонения. PatchTST, работающий непосредственно с патчами входного ряда без явной декомпозиции, оказывается наиболее робастным.




Рисунок 15. Сравнение прямого и итеративного прогнозов на квартальном ряде T478




Рисунок 16. Сравнение прямого и итеративного прогнозов на месячном ряде T779

2.4. Предобучение трансформерных моделей

Одной из ключевых гипотез настоящей работы является предположение, что слабые результаты нейросетевых моделей в per-series режиме обусловлены не архитектурными ограничениями, а недостатком обучающих данных. Для проверки этой гипотезы проведён систематический эксперимент с предобучением, охватывающий все шесть нейросетевых моделей и Helformer на пяти частотных категориях: M3 yearly, M3 quarterly, M3 monthly, M4 quarterly и M4 monthly.

Протокол. На первом этапе каждая модель предварительно обучается на обучающих выборках *всех* рядов соответствующей категории в режиме скользящего окна: все 645 годовых, 756 квартальных и 1428 месячных рядов М3, а также 5000 подвыбранных квартальных и 5000 месячных рядов М4 (40 эпох предобучения). На втором этапе предобученная модель дообучается на каждом из 30 тестовых рядов (20 эпох). Результат сравнивается с обучением «с нуля» (80 эпох) на тех же рядах. Такой протокол позволяет оценить эффект переноса знаний (transfer learning) из корпуса рядов на отдельный ряд [bandara2020forecasting].

Таблица 19 содержит относительное улучшение sMAPE при предобучении по всем комбинациям модель–частота. Положительные значения означают снижение sMAPE (улучшение), отрицательные — ухудшение.

Таблица 19. Эффект предобучения: улучшение sMAPE (%) по частотам и моделям

Модель	М3-Y	М3-Q	М3-M	М4-Q	М4-M	Среднее
DLinear	+37.6	+50.8	+16.6	+47.8	+37.2	+38.0
Autoformer	+22.1	+12.8	+10.5	+40.0	+36.4	+24.4
FEDformer	+24.1	−5.6	+11.2	+43.9	+35.8	+21.9
Helformer	−8.0	+25.0	+17.5	+51.5	+16.3	+20.5
PatchTST	+20.4	−3.2	+6.7	+14.1	+29.1	+13.4
N-BEATS	−0.8	−8.3	−16.2	+23.2	+12.5	+2.1
TimesNet	−52.6	−25.5	+13.0	−16.9	+14.6	−13.5

2.4.1. Детальные результаты предобучения по частотам

Сводная таблица 19 отражает лишь относительные изменения. Для содержательного анализа необходимо рассмотреть абсолютные значения sMAPE по каждой частотной категории, что позволяет сопоставить эффект предобучения с уровнем классических baseline-моделей.

Таблица 20. Предобучение на M3 Yearly: абсолютные sMAPE (%)

Модель	С нуля	Предобучение	Δ (%)
FEDformer	30.09	22.83	+24.1
Autoformer	30.05	23.12	+22.1
PatchTST	29.04	23.41	+20.4
DLinear	38.00	23.72	+37.6
N-BEATS	23.56	23.75	−0.8
TimesNet	16.44	25.08	−52.6
Helformer	27.59	29.80	−8.0

M3 Yearly ($H=6$, 30 рядов). На годовых рядах предобучение приводит к выравниванию результатов нейросетевых моделей в узком коридоре 22.8–25.1 %. Трансформерные модели (FEDformer, Autoformer, PatchTST) существенно улучшаются, однако TimesNet, показывавший лучший результат при обучении с нуля (16.44), деградирует до 25.08 — предобучение на корпусе коротких рядов разрушает его специализированную 2D-декомпозицию.

Таблица 21. Предобучение на M3 Quarterly: абсолютные sMAPE (%)

Модель	С нуля	Предобучение	Δ (%)
TimesNet	9.90	12.43	−25.5
DLinear	25.70	12.65	+50.8
Autoformer	15.84	13.81	+12.8
N-BEATS	13.25	14.35	−8.3
PatchTST	14.60	15.07	−3.2
FEDformer	15.00	15.84	−5.6
Helformer	28.55	21.42	+25.0

M3 Quarterly ($H=8$, 30 рядов). На квартальных рядах наблюдается выраженная дивергенция: DLinear получает максимальное улучшение (+50.8 %), тогда как TimesNet и N-BEATS, эффективные при per-series обучении, ухудшаются. Лучший абсолютный результат с предобучением — DLinear (12.65), что сопоставимо с ETS (10.80 на полном M3 quarterly).

Таблица 22. Предобучение на M3 Monthly: абсолютные sMAPE (%)

Модель	С нуля	Предобучение	Δ (%)
TimesNet	15.72	13.68	+13.0
DLinear	16.77	13.98	+16.6
Autoformer	16.88	15.10	+10.5
PatchTST	16.26	15.17	+6.7
FEDformer	18.37	16.32	+11.2
N-BEATS	14.89	17.30	−16.2
Helformer	27.88	23.01	+17.5

M3 Monthly ($H=18$, 30 рядов). Месячные ряды M3 являются ключевой категорией для эксперимента с предобучением. TimesNet с предобучением (13.68) впервые в данном исследовании превосходит ETS (17.42 на полном M3 monthly) — улучшение составляет 3.7 п.п. DLinear (13.98) также обходит ETS. N-BEATS, напротив, ухудшается (−16.2 %), поскольку его residual-архитектура уже эффективно специализируется на конкретном ряде.

Таблица 23. Предобучение на M4 Quarterly: абсолютные sMAPE (%)

Модель	С нуля	Предобучение	Δ (%)
DLinear	29.58	15.44	+47.8
FEDformer	34.96	19.60	+43.9
PatchTST	22.86	19.64	+14.1
Autoformer	33.48	20.09	+40.0
Helformer	42.22	20.49	+51.5
N-BEATS	27.98	21.49	+23.2
TimesNet	19.26	22.52	−16.9

M4 Quarterly ($H=8$, 30 рядов). На M4 quarterly эффект предобучения максимален: Helformer улучшается на +51.5 %, DLinear на +47.8 %, FEDformer на +43.9 %. Предобучение на 5000 рядах формирует устойчивые сезонные паттерны, что особенно полезно для моделей с фиксированной декомпозицией. TimesNet вновь демонстрирует ухудшение (−16.9 %), подтверждая закономерность: его адаптивная 2D-декомпозиция конфликтует с глобальным предобучением.

Таблица 24. Предобучение на M4 Monthly: абсолютные sMAPE (%)

Модель	С нуля	Предобучение	Δ (%)
FEDformer	24.36	15.64	+35.8
Autoformer	25.61	16.29	+36.4
TimesNet	20.10	17.17	+14.6
DLinear	27.42	17.23	+37.2
PatchTST	24.75	17.54	+29.1
N-BEATS	20.94	18.32	+12.5
Helformer	55.32	46.32	+16.3

M4 Monthly ($H=18$, 30 рядов). На месячных рядах M4 все семь моделей улучшаются с предобучением, причём Autoformer (+36.4 %) и DLinear (+37.2 %) показывают наибольший выигрыш. Даже TimesNet, чувствительный к предобучению на коротких рядах, здесь улучшается на +14.6 %, что подтверждает гипотезу о пороговой длине: при достаточном объёме данных для дообучения глобальная инициализация помогает и адаптивным архитектурам.

Анализ пяти частотных категорий позволяет выделить следующие закономерности.

TimesNet с предобучением (13.68) превосходит ETS (17.42) на M3 monthly. Это наиболее значимый единичный результат: нейросетевая модель с обучаемой декомпозицией обходит лучшую классическую модель на крупной категории (1428 рядов), подтверждая гипотезу о том, что дефицит данных, а не архитектурные ограничения, был главным препятствием.

DLinear — наибольший совокупный выигрыш от предобучения. По всем пяти категориям DLinear улучшается в среднем на +38.0 %, что объясняется минимальной ёмкостью его линейной архитектуры: при per-series обучении на коротких рядах MA-фильтр не может корректно разделить тренд и сезонность, тогда как предобучение на корпусе рядов формирует адекватные начальные веса.

TimesNet деградирует на коротких рядах из-за конфликта глобальной инициализации с адаптивной декомпозицией. Двумерное представление TimesNet эффективно специализируется при per-series обучении; предобучение на гетерогенном корпусе «размывает» эту адаптацию и навязывает усреднённые паттерны, разрушая per-series специализацию. Однако при достаточной длине дообучающей выборки (M3 monthly, M4 monthly) этот конфликт

ослабевает.

M4 демонстрирует более выраженный эффект предобучения. На M4 квартальных рядах Heformer улучшается на +51.5 %, DLinear на +47.8 %, FEDformer на +43.9 %. Предобучение на 5000 рядах (в сравнении с 645–1428 рядами M3) формирует более устойчивые глобальные представления, и все модели, кроме TimesNet, получают существенный выигрыш.




Рисунок 17. Эффект предобучения: относительное улучшение sMAPE (%) по частотам и моделям

Центральным результатом эксперимента с предобучением является превосходство нейросетевых моделей над ETS на месячных рядах. TimesNet с предобучением показывает sMAPE 13.68 % — на 3.7 п.п. лучше, чем ETS (17.42 %) на полном M3 monthly. Это первый случай в данной работе, когда нейросетевая модель убедительно обходит лучшую классическую на крупном наборе данных.

DLinear — наибольший выигрыш от предобучения. DLinear демонстрирует среднее улучшение +38.0 % по пяти категориям, трансформируясь из худшей модели (sMAPE 28.90 на полном M3) в конкурентоспособную. Этот результат объясняется тем, что линейная архитектура DLinear при регрессии обучения на коротких рядах не может корректно разделить тренд и сезонность; предобучение на корпусе рядов позволяет модели сформировать адекватные веса MA-фильтра ещё до дообучения на конкретном ряде.

Autoformer и FEDformer — существенное улучшение, особенно на M4. Autoformer (+24.4 % в среднем) и FEDformer (+21.9 %) получают наибольший выигрыш на квартальных и месячных рядах M4 (+36–44 %), где обучаю-

щие выборки длиннее и предобучение на 5000 рядах формирует устойчивые представления о сезонных паттернах. На М3 квартальных рядах FEDformer парадоксально ухудшается (-5.6%), что объясняется конфликтом между MOEDecomr-декомпозицией, настроенной на глобальный корпус, и индивидуальными особенностями коротких рядов.

TimesNet — предобучение на коротких рядах разрушает выученные паттерны. TimesNet показывает среднее ухудшение -13.5% , причём наиболее выраженное на годовых (-52.6%) и квартальных (-25.5%) рядах М3. Двумерная декомпозиция TimesNet [wu2023timesnet] эффективно адаптируется к конкретному ряду при per-series обучении; предобучение на корпусе «размывает» эту адаптацию. Однако на месячных рядах М3 ($+13.0\%$) и М4 ($+14.6\%$), где длина обучающей выборки достаточна для дообучения, предобучение всё же помогает.

N-BEATS — минимальный эффект. N-BEATS с архитектурой residual-стеков [oreshkin2020nbeats] демонстрирует среднее улучшение лишь $+2.1\%$, причём на М3 предобучение ухудшает результат. N-BEATS изначально спроектирован как сильный per-series обучающийся, и глобальное предобучение не даёт ему существенного преимущества.

Практическое следствие. Предобучение на корпусе рядов сдвигает границу конкурентоспособности нейросетевых моделей с примерно 100 наблюдений (per-series режим) до примерно 40 наблюдений, существенно расширяя область применения глубоких архитектур для прогнозирования временных рядов. При полноценном глобальном обучении трансформерные модели потенциально могут существенно сократить разрыв с классическими подходами — и даже превзойти их, как продемонстрировано в ряде недавних работ [nie2023patchtst; liu2024itransformer].




Рисунок 18. PatchTST: прогноз с предобучением и без на ряде T779




Рисунок 19. Autoformer: прогноз с предобучением и без на ряде T779

2.5. Выводы

Полученные результаты позволяют ответить на исследовательские вопросы, сформулированные во введении.

- Фиксированная декомпозиция с нейросетевой коррекцией (Helformer) показала лучшие метрики на подвыборке M3 (sMAPE 10.61, MASE 0.94) и вторые на M4 (sMAPE 17.73 после ETS 16.06). Прогон на полном M3 (2829 рядов) подтверждает лидерство классических моделей в целом (Seasonal Naïve 15.74, ETS 16.04), однако нейросетевые модели побеждают лучшую классическую в 40 % годовых,

41 % квартальных и 47 % месячных рядов. Обучаемая декомпозиция (TimesNet, N-BEATS) становится конкурентоспособной при длине ряда свыше 80–100 наблюдений (M3 monthly, M4 daily). На ежедневных рядах M4 нейросетевые модели побеждают классические в 67 % рядов.

- Наилучшие результаты на коротких рядах показывает гибридный подход Heformer (sMAPE 8.61 на yearly, 7.10 на quarterly), сочетающий фиксированную декомпозицию с нейросетевой коррекцией. Среди чисто статистических моделей лидируют ETS и Auto-ARIMA. Среди чисто нейросетевых архитектур TimesNet с 2D-свертками и N-BEATS с residual-стеками показывают лучшие результаты, значительно превосходя трансформерные модели (Autoformer, FEDformer, PatchTST).
- В per-series режиме — нет: PatchTST (ранг 7), Autoformer (ранг 9.17), FEDformer (ранг 9.50) проигрывают более простым N-BEATS (ранг 6.67) и TimesNet (ранг 6.50). Однако гибридный Heformer (ранг 2.00) демонстрирует, что трансформерная компонента может быть эффективной при наличии качественной фиксированной декомпозиции. Масштабный эксперимент с предобучением на пяти частотах подтверждает этот эффект: DLinear улучшается на +38 %, Autoformer — на +24 %, что свидетельствует об оправданности сложности нейросетевых архитектур при доступе к достаточному объёму данных.
- На годовых рядах любая обучаемая декомпозиция проигрывает фиксированной; на квартальных обучаемая 2D-декомпозиция TimesNet выходит на уровень ETS; на ежедневных рядах достаточно простой MA-декомпозиции (DLinear).
- Эксперименты показывают критическую границу порядка 50–100 наблюдений. Ниже этого порога нейросетевые модели систематически уступают статистическим. Выше — разрыв сокращается и на отдельных категориях (M3 monthly, M4 daily) исчезает. Предобучение на корпусе рядов позволяет эффективно сдвинуть эту границу вниз.

Систематический эксперимент с предобучением на пяти частотных категориях (M3 yearly/quarterly/monthly, M4 quarterly/monthly) и семи моделях выявил дифференцированный эффект переноса знаний. DLinear показывает наибольший средний выигрыш (+38.0 %), трансформируясь из худ-

шей нейросетевой модели в конкурентоспособную. Autoformer (+24.4 %) и FEDformer (+21.9 %) получают значительное улучшение, особенно на М4 (+36–44 %). TimesNet, напротив, в среднем ухудшается (−13.5 %), что свидетельствует о конфликте глобального предобучения с адаптивной 2D-декомпозицией.

Наиболее значимым результатом предобучения является достижение нейросетевыми моделями уровня, превосходящего ETS на месячных рядах: TimesNet с предобучением показывает sMAPE 13.68 % на полном М3 monthly — на 3.7 п.п. лучше, чем ETS (17.42 %). Это первый случай в данной работе, когда нейросетевая модель убедительно обходит лучшую классическую на крупном наборе данных, подтверждая гипотезу о том, что дефицит данных, а не архитектурные ограничения, является главным препятствием для глубоких моделей прогнозирования.

Заключение

Настоящая работа была посвящена исследованию условий, при которых обучаемая декомпозиция временных рядов на компоненты и нейросетевые механизмы учета долгосрочных зависимостей дают практическое преимущество по сравнению с фиксированными статистическими подходами, а также ситуаций, в которых более простые методы оказываются предпочтительнее. Для ответа на этот вопрос был разработан экспериментальный контур, включающий 11 моделей (4 классические, 4 нейросетевые, 3 трансформерные) и 180 временных рядов из наборов M3 и M4 Competition трех частотных категорий каждый.

Основные результаты работы можно сформулировать следующим образом.

1. Helformer — лучшая модель среди всех 11 протестированных. Гибридная модель Helformer, использующая фиксированную декомпозицию Хольта–Уинтерса с нейросетевой коррекцией, показала наименьший средний sMAPE (10.61 % на M3, 12.71 % на M4) и лучший средний ранг (2.00 из 11) по шести частотным категориям. Среди чисто статистических моделей лучший результат у ETS (13.89 % на M3), среди чисто нейросетевых — у TimesNet (17.87 % на M3). Разрыв между Helformer и ETS составляет 3.28 п.п., что указывает на практическую ценность гибридного подхода.

2. Длина ряда является критическим фактором для нейросетевых моделей. Экспериментально установлена граница порядка 50–100 наблюдений, ниже которой нейросетевые модели систематически уступают статистическим, а выше — становятся конкурентоспособными. На месячных рядах M3 (~120 наблюдений) N-BEATS с обучаемой декомпозицией (20.58 %) опередил ETS (21.04 %), а на ежедневных рядах M4 (до 9919 наблюдений) DLinear (2.43 %) показал лучший результат среди всех моделей, включая классические.

3. Обучаемая декомпозиция требует достаточного объема данных. Модели с обучаемой декомпозицией (TimesNet, N-BEATS) демонстрируют переход от неэффективной к конкурентоспособной при увеличении длины ряда. TimesNet с двумерной декомпозицией показал sMAPE 8.18 % на квартальных рядах M3, практически не уступая ETS (7.80 %). Трансформерные

модели с обучаемой декомпозицией серийного типа (Autoformer, FEDformer) оказались наименее эффективными в per-series режиме (средний ранг 8.17 и 8.50), однако при предобучении на корпусе рядов продемонстрировали улучшение на 7–11 %.

4. Фиксированная декомпозиция + нейросетевая коррекция — наиболее эффективная стратегия. Успех Helformer (пункт 1) объясняется тем, что статистическая компонента (декомпозиция Хольта–Уинтерса) обеспечивает устойчивый базовый прогноз, а нейросетевая компонента (трансформерный энкодер + LSTM) моделирует нелинейные остатки, не разрушая структуру базового прогноза. В отличие от обучаемой декомпозиции (Autoformer, FEDformer), где нейросеть должна одновременно выделять компоненты и строить прогноз, гибридный подход разделяет эти задачи между статистическим и нейросетевым модулями.

5. Итеративное прогнозирование выявляет хрупкость обучаемой декомпозиции. При переходе от прямого к итеративному прогнозированию модели с обучаемой декомпозицией демонстрируют наибольшую деградацию: FEDformer +5.01 п.п., TimesNet +5.16 п.п. PatchTST (+2.18 п.п.), работающий с патчами без явной декомпозиции, оказался наиболее устойчивым трансформером. Классические модели (ETS, Auto-ARIMA) практически нечувствительны к режиму прогнозирования.

На основании полученных результатов можно сформулировать следующие **практические рекомендации**:

- для одномерных рядов с выраженной сезонностью гибридный подход Helformer (фиксированная декомпозиция + нейросетевая коррекция) является лучшим выбором; при невозможности его применения — ETS и Auto-ARIMA;
- при длине ряда свыше 100 наблюдений целесообразно рассмотреть N-BEATS или TimesNet как альтернативу классическим моделям;
- при наличии корпуса однородных рядов предобучение трансформерных моделей дает улучшение на 7–11 %, что делает их конкурентоспособными;
- для задач, требующих итеративного прогнозирования, следует отдавать предпочтение моделям без сложной обучаемой декомпозиции (PatchTST, DLinear) или классическим подходам;

- гибридный подход (фиксированная декомпозиция + нейросетевая коррекция) показал лучший результат среди всех подходов и является рекомендуемой архитектурной стратегией.

Таким образом, проведенное исследование показывает, что ответ на вопрос о превосходстве обучаемой декомпозиции не является бинарным: эффективность нейросетевых механизмов критически зависит от длины ряда, режима обучения и доступного объема данных. Понимание этих границ необходимо для обоснованного выбора метода прогнозирования в конкретных прикладных задачах.